

PrimeVarClass: da hipótese dos números primos a um classificador de variantes BRCA1/BRCA2 consciente de domínio, validado externamente e complementar ao estado da arte

32º Prêmio Jovem Cientista — Categoria Estudante do Ensino Superior

Tema: Inteligência Artificial para o Bem Comum — Subtema: Inteligência Artificial & Saúde (item 1.4.1.b do Edital)

Autor: Wesley Felipe Capucho — graduando em Engenharia Bioquímica

Orientador(a): <a definir>

Instituição de vínculo: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP) — Estrada Municipal do Campinho, s/nº, Ponte Nova, Lorena – SP, CEP 12602-810. E-mail: wesleycapucho@usp.br. Telefone: <a definir>.

Instituição onde a pesquisa foi desenvolvida: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP), Lorena – SP, Brasil.

Palavras-chave: variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

APRESENTAÇÃO

Resumo

Este trabalho partiu de uma hipótese pouco convencional: codificar aminoácidos pela estrutura dos números primos revelaria padrões de patogenicidade em variantes missense? O projeto foi nomeado PrimeVarClass a partir dessa aposta, e a hipótese foi testada com rigor — validação cruzada bloqueada por posição e generalização em coortes externas nunca vistas no treino. A hipótese foi refutada com transparência: a codificação por primos teve desempenho inferior ao de uma identidade trivial de aminoácidos (AUC externa 0,681 vs. 0,718; $p = 0,045$) e piorou um modelo bioquímico ao ser adicionada (0,791 $\rightarrow$ 0,765; $p = 3,8 \times 10^{-8}$). No processo, foi diagnosticada uma armadilha de vazamento posicional que infla benchmarks internos. A partir daí, construiu-se um classificador consciente de domínio funcional (RING/BRCT de BRCA1; domínio de ligação ao DNA de BRCA2), que generalizou para coortes externas com AUC de 0,847 — superando o modelo com posição bruta (0,791; $p = 1,8 \times 10^{-13}$). Combinado a um modelo de linguagem de proteínas (ESM-2), o modelo-carro-chefe atingiu AUC externa de 0,909, estatisticamente equivalente aos melhores preditores publicados — AlphaMissense (0,926; $p = 0,24$), REVEL (0,930; $p = 0,14$) e CADD (0,891; $p = 0,37$) —, ainda que avaliado sob desvantagem: esses preditores carregam circularidade com os próprios rótulos de teste, e o modelo proposto, não. Um meta-classificador integrando todos os sinais atingiu 0,938. Os escores foram calibrados em força de evidência ACMG/AMP e, entre variantes que o AlphaMissense deixa ambíguas (644 no total), o modelo forneceu chamada de evidência calibrada para 53,8% dos VUS e 64,6% das conflitantes (concordância de 100% no subconjunto verificável) — evidência de que o método complementa o AlphaMissense, em vez de competir com ele. O mecanismo estrutural foi validado contra dados funcionais reais de reparo por recombinação homóloga (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$); uma lacuna de equidade entre ancestralidades foi quantificada e parcialmente mitigada; e a validação prospectiva por corte temporal foi simulada (AUC de 0,892 em 2016 a 0,932 em 2021). Por fim, foi implementado um mecanismo real e seguro de aprendizado contínuo: o modelo melhora com rótulos confirmados pelo uso (AUC no conjunto travado subindo de 0,895 para 0,922) sob uma trava que rejeita

atualizações que piorem o desempenho. O sistema é entregue como plataforma aberta, auditável e reprodutível. A contribuição central não é um número inflado, mas um método honesto, generalizável e continuamente aprimorável para apoiar a interpretação responsável de variantes genéticas no Brasil.

Palavras-chave: classificação de variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

Introdução

O problema clínico e social

Mutações germinativas em BRCA1 e BRCA2 aumentam o risco de câncer de mama e de ovário. Ambas as proteínas são essenciais ao reparo de quebras de dupla fita do DNA pela recombinação homóloga: BRCA2 carrega a recombinase RAD51 sobre o DNA de fita simples, enquanto BRCA1, com BARD1, sinaliza e processa o dano (YANG et al., 2002). Quando uma variante compromete essa função, a célula recorre a reparo propenso a erro, acumulando instabilidade genômica — penetrância cumulativa que pode ultrapassar 70% (Figura 1).




Figura 1. Mecanismo BRCA1/BRCA2 no câncer hereditário de mama e ovário. Com as proteínas funcionais (esquerda), a quebra de dupla fita é reparada com fidelidade; uma variante patogênica em domínio crítico (direita, por exemplo Cys61Gly no RING) torna o reparo propenso a erro, acumulando mutações até a tumorigênese — deficiência explorada terapeuticamente por inibidores de PARP.

Ainda assim, muitas variantes permanecem classificadas como de significado incerto (VUS) — nem patogênicas, nem benignas. No Brasil, isso se agrava por

desigualdade de acesso: a expertise de interpretação concentra-se em poucos centros, e laboratórios públicos frequentemente carecem de ferramentas abertas e auditáveis (ACHATZ et al., 2020; PALMERO et al., 2007; FERNANDES et al., 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO et al., 2025; NORONHA et al., 2026). Foi para atacar esse gargalo que o PrimeVarClass foi desenvolvido.

A lacuna metodológica e o estado da arte

Preditores como REVEL (IOANNIDIS et al., 2016), CADD (RENTZSCH et al., 2019) e AlphaMissense (CHENG et al., 2023) evoluíram para meta-preditores e modelos profundos, com REVEL/BayesDel superando preditores individuais (TIAN et al., 2019). Mas benchmarks nessa área sofrem recorrentemente de vazamento de dados e ausência de validação externa (KERNBACH; STAARTJES, 2022; GANAKAMMAL; ALEXOV, 2019; SUYBENG et al., 2020; SMOL et al., 2021; DONG et al., 2014; LABES et al., 2022), problema que um framework recente propõe mitigar combinando controle de vazamento e SHAP (SHETTY et al., 2026). Especificamente em BRCA1/BRCA2, o BRCA-ML (HART et al., 2020), o RENOVO (FAVALLI et al., 2021), a análise ENIGMA (PARSONS et al., 2019) e ensaios funcionais de saturação genômica (FINDLAY et al., 2014; 2018) reduzem a incerteza, e a calibração ACMG/AMP é recomendação do ClinGen (PEJAVER et al., 2022; RICHARDS et al., 2015; NYKAMP et al., 2017; OZA et al., 2018; MCCORMICK et al., 2020) — inclusive com escores informados por estrutura em BRCA1 (RAMADANE-MORCHADI et al., 2025), o que corrobora a abordagem consciente de domínio aqui desenvolvida. Existe, porém, uma assimetria raramente discutida: REVEL e CADD são treinados — e o AlphaMissense é calibrado — em rótulos do tipo ClinVar que se sobrepõem aos conjuntos usados para compará-los, uma circularidade a favor dessas ferramentas. Essa assimetria é aqui denominada vazamento a favor de terceiros e corrigida explicitamente nos Resultados, somando-se a "coldspots" mal classificados (DINES et al., 2020) e a evidências de que restrição evolutiva por domínio melhora a priorização (ZHANG et al., 2024; CHEN et al., 2023; CHAO et al., 2024; LAKE et al., 2024; TORRETTO et al., 2026).

A jornada científica: por que "Prime"

O nome PrimeVarClass guarda a origem do projeto: uma hipótese arrojada sobre números primos, tratada não como verdade a defender, mas como hipótese a

testar sob o protocolo mais rigoroso disponível. O resultado foi negativo, e é relatado com a mesma transparência dos positivos. Sustenta-se que essa trajetória — hipótese ousada, teste rigoroso, refutação transparente, redirecionamento para o que funciona — é, em si, contribuição científica tão valiosa quanto qualquer resultado positivo isolado, e o antídoto direto contra alegações infladas de inteligência artificial em saúde.

Objetivos

1. Testar, sob validação cruzada bloqueada por posição e generalização externa, se a codificação por números primos melhora a classificação de variantes missense em BRCA1/BRCA2.
2. Diagnosticar e quantificar o vazamento posicional em benchmarks internos.
3. Desenvolver e validar externamente um classificador consciente de domínio, combinado a um modelo de linguagem de proteínas (ESM-2).
4. Comparar esse modelo, de forma honesta, com AlphaMissense/REVEL/CADD, corrigindo a assimetria de circularidade que os favorece.
5. Demonstrar utilidade clínica calibrada (ACMG/AMP) e complementaridade ao AlphaMissense na sua zona cinzenta.
6. Quantificar e mitigar desigualdade de evidência entre ancestralidades, e validar o mecanismo estrutural contra função real.
7. Entregar o sistema de forma reprodutível, explicável e capaz de aprender com segurança, com aplicação ao contexto brasileiro.

DESENVOLVIMENTO

Materiais e Métodos

Fontes de dados

Foram utilizados dados públicos e auditáveis de BRCA1 (UniProt P38398) e BRCA2 (P51587) (UNIPROT CONSORTIUM, 2023): classificações do ClinVar, com subconjunto de alta confiança por painel de especialistas (ENIGMA/ClinGen; PARSONS et al., 2019); frequências alélicas do gnomAD por ancestralidade (KARCZEWSKI et al., 2020); estruturas do PDB e AlphaFold DB; e ensaios funcionais do MaveDB (FINDLAY et al., 2018; STARITA et al., 2015). Os rótulos foram normalizados em patogênico (1) vs. benigno (0); conflitantes ou de baixa confiança foram excluídos. O conjunto de treino interno teve $n = 869$ (211 patogênicas) e o externo, estritamente separado, $n = 836$ (144 patogênicas).

Representação, teste dos primos e domínio funcional

Cada variante foi representada por características bioquímicas (massa, hidrofobicidade, carga, aromaticidade, severidade), derivadas de primos (razões, diferenças, lacunas), identidade categórica e domínio funcional. Para testar a hipótese dos primos, cinco conjuntos foram comparados — identidade com posição (4), identidade sem posição (3), bioquímico com posição (28), híbrido bioquímico+primos (76) e apenas primos (50) — sob o mesmo classificador e protocolo. Foram mapeados domínios funcionais curados do UniProt: RING (1–109) e BRCT (1642–1736, 1756–1855) em BRCA1; domínio de ligação ao DNA (2481–3186) em BRCA2, como regiões críticas. Essas fronteiras derivam da função bioquímica documentada há décadas (coordenação estrutural de zinco no RING, reconhecimento de fosfopeptídeo no BRCT, ligação ao DNA no DBD), independentemente dos rótulos de patogenicidade — o que evita seleção circular de regiões. Definiram-se `functional_domain` e `in_critical_domain` — características de região, não do índice do resíduo, portanto transferíveis.

Protocolo anti-vazamento e modelo

Foram adotados dois níveis de avaliação, sem exceção: (A) validação cruzada bloqueada por posição (StratifiedGroupKFold, 5 folds, agrupada por

gene:posição), impedindo que a mesma posição apareça em treino e teste; e (B) generalização externa nas quatro coortes nunca tocadas. Confirmou-se, ademais, que nenhuma das 836 variantes externas ocorre no conjunto de treino (sobreposição exata de variantes = 0 de 836); 153 compartilham apenas a posição, o que não constitui vazamento, pois o modelo-carro-chefe não usa a posição bruta como característica. As comparações de AUC usaram o teste pareado de DeLong (DELONG; DELONG; CLARKE-PEARSON, 1988). Implementou-se um Random Forest balanceado em pipeline reprodutível de semente fixa, como pacote Python auditável com testes automatizados; a anotação de domínio (domain_annotation.py) e a ingestão de escores profundos (esm_scores.py) são módulos independentes, sem dependência de GPU.

Robustez, meta-análise, ESM-2 e SHAP

A robustez foi quantificada por bootstrap ($B = 2000$), teste de permutação ($N = 2000$), validação cruzada bloqueada repetida (12 sementes) e calibração (Brier, confiabilidade). As quatro coortes externas foram agrupadas por efeitos aleatórios (DerSimonian-Laird, escala logit), reportando-se IC95%, Q de Cochran e I^2 . Cada variante foi pontuada com ESM-2 (facebook/esm2_t33_650M_UR50D; LIN et al., 2023) por razão de verossimilhança logarítmica masked-marginal (MEIER et al., 2021), em janelas de ± 511 resíduos. Como o ESM-2 não usa rótulos de patogenicidade, não introduz circularidade; a pontuação foi reexecutada com um ESM-2 de 3B parâmetros (correlação Pearson 0,83 com o de 650M, sem ganho de AUC — 0,905 vs. 0,909 —, resultado honesto de saturação que levou a manter o 650M como principal). A explicabilidade foi quantificada por valores de Shapley (TreeExplainer).

Comparação honesta, meta-classificador e calibração ACMG/AMP

O modelo-carro-chefe foi comparado com AlphaMissense, REVEL, CADD, PolyPhen-2 e SIFT nas mesmas 836 variantes externas (escores via API REST do Ensembl VEP, transcrito MANE Select). A assimetria de circularidade (Seção 1.3) foi tornada explícita, e tentou-se isolá-la recortando variantes recentes (ClinVar ≥ 2024); constatou-se que o recorte não separa o vazamento de forma limpa, pois last_evaluated reflete reavaliação, não submissão original. Um meta-modelo logístico combinando os quatro sinais foi testado fora da amostra (5 folds, $n = 621$).

O escore foi calibrado aos limiares de razão de verossimilhança de Tavtigian/Pejaver (PEJAVER et al., 2022; RICHARDS et al., 2015): $LR \geq 18,7/4,33/2,08$ para PP3 forte/moderado/leve; $LR \leq 0,05/0,23/0,48$ para BP4, prevalência prévia de 10%.

Zona cinzenta, equidade, mecanismo e aprendizado contínuo

Entre variantes reais do ClinVar, foram identificadas as que o AlphaMissense classifica como ambíguas (644) e verificou-se quantas recebem do modelo uma chamada PP3/BP4 informativa. Foram usadas frequências do gnomAD (europeias vs. não europeias) para medir equidade de resolução em variantes com $AF > 10^{-4}$ (POPEJOY; FULLERTON, 2016; MANRAI et al., 2016; SOEWITO et al., 2022). Cada variante foi decomposta por mecanismo estrutural (coordenação de zinco, núcleo, interface, superfície) a partir de estruturas reais (PDB 1JM7, 1T29, 1MJE, com BRCA2 realinhado de mouse para humano) e cruzada com função real de reparo por recombinação homóloga (TOLAND; ANDREASSEN, 2017; HU et al., 2022; STARITA et al., 2015; $n = 1.262$) por Kruskal-Wallis. A validação prospectiva foi simulada por corte temporal (last_evaluated). Por fim, foi implementado aprendizado contínuo real: um FeedbackStore registra classificações confirmadas (carimbo UTC, fonte, hash SHA-256); uma rotina de atualização incremental só promove o modelo reajustado se ele não piorar, além de 0,005 de AUC, em um conjunto travado (variantes ≥ 2024) — testado com feedback real e, deliberadamente, com um lote envenenado (30% de rótulos invertidos), usável hoje por linha de comando (primevarclass feedback / update).

Resultados e Discussão

A hipótese dos números primos foi refutada

A hipótese foi testada sob o protocolo anti-vazamento (Tabela 1). Os primos tiveram desempenho inferior à identidade trivial e pioraram um modelo bioquímico ao serem adicionados (Tabela 2).

Tabela 1. Refutação da hipótese dos primos (n = 869 treino / n = 836 externo).

Conjunto de características	nº feat.	CV bloqueada	Externa
Identidade (com posição) ^a	4	0,871	0,882
Bioquímico (com posição) ^a	28	0,802	0,791
Híbrido (bioquímico + primos) ^a	76	0,783	0,765
Identidade (sem posição)	3	0,745	0,718
Apenas primos	50	0,717	0,681

^a Incluem gene e posição bruta — risco de memorização diagnosticado a seguir.

Tabela 2. Comparações pareadas por DeLong.

Comparação	Protocolo	AUC A	AUC B	Δ	p
Primos vs. identidade	Bloqueada	0,717	0,745	-0,028	0,081
Primos vs. identidade	Externa	0,681	0,718	-0,038	0,045
Híbrido vs. bioquímico	Bloqueada	0,783	0,802	-0,019	<0,0001
Híbrido vs. bioquímico	Externa	0,765	0,791	-0,027	<0,0001

A diferença é uma tendência não significativa na CV interna ($p = 0,081$), mas significativa na generalização externa ($p = 0,045$) — e adicionar primos a um modelo bioquímico piora o desempenho externo ($p < 0,0001$). A conclusão é honesta: os primos não agregam sinal útil.

Diagnóstico: a armadilha do vazamento posicional

Sob validação ingênua (sem bloqueio por grupo), a identidade combinada à posição bruta chega a AUC próxima de 0,90 — valor inflado, pois variantes da mesma posição compartilham rótulo e aparecem em treino e teste simultaneamente. Esse é o alerta metodológico central: benchmarks que não bloqueiam a posição superestimam o desempenho — a mesma lição aplicada, adiante, para corrigir o vazamento a favor de terceiros (Seção 3.7).

A solução: modelo consciente de domínio

Com a substituição da posição bruta por região funcional, obteve-se um modelo que generaliza melhor externamente (Tabela 3; Figura 2).

Tabela 3. Consciência de domínio: validação bloqueada e externa (AUC-ROC).

Modelo	CV bloqueada	Externa
Bioquímico (sem posição)	0,743	0,717
Bioquímico + domínio (proposto)	0,818	0,847
Bioquímico + posição bruta (vazamento)	0,802	0,791

DeLong domínio vs. bioquímico: $p = 3,2 \times 10^{-9}$ (interno), $p = 1,8 \times 10^{-13}$ (externo). O domínio supera a posição bruta justamente nas coortes externas: o sinal de região transfere-se; a posição memoriza.




Figura 2. Domínios funcionais de BRCA1/BRCA2 com variantes reais sobrepostas. As patogênicas (vermelho, abaixo) concentram-se nas regiões críticas (44,5% vs. 6,8–10,0% fora delas) — base biológica do sinal de domínio.

Prova visual: mutações patogênicas reais capturadas

Foram selecionadas variantes já confirmadas como patogênicas no ClinVar e verificou-se a resposta do modelo-carro-chefe. A Figura 3 mostra o RING de BRCA1 (PDB 1JM7) colorido por intensidade de detecção: as zonas mais sensíveis coincidem exatamente com as cisteínas que coordenam os dois íons de zinco estruturais, sem que essa coordenação tivesse sido informada ao modelo. A Figura 4 detalha seis variantes confirmadas — três no sítio de zinco (Cys39Gly, Cys64Gly, Cys61Tyr) e três no núcleo do BRCT (Met1689Arg, Leu1705Pro, Trp1837Cys) —, todas detectadas com 96,3% a 99,7% de confiança.



Figura 3. RING de BRCA1 (PDB 1JM7), colorido por intensidade de detecção (azul = tolerante; dourado = detectada). Os dois íons de zinco (esferas) são coordenados por cisteínas identificadas, de forma independente, como a região mais sensível — coerente com décadas de literatura sobre o domínio.



Figura 4. Seis variantes de BRCA1 confirmadas patogênicas no ClinVar, cada uma sobre sua estrutura real, com o veredito do ClinVar (selo verde) e a chamada do modelo (selo dourado) — todas detectadas com alta confiança.

O mesmo exercício, repetido em BRCA2 (variantes clássicas do domínio de ligação ao DNA como Gly2748Asp, Arg3052Trp e Trp2626Cys, detectadas com 75,3% a 96,7%; painel individual no Material Suplementar), confirmou que a abordagem generaliza entre genes. A superfície molecular completa dos dois domínios, colorida por intensidade de detecção (Figura 5), torna essa generalização visível: as mesmas zonas de risco — o núcleo funcional de cada domínio — emergem, de forma independente, em BRCA1 (BRCT) e BRCA2 (DBD). Não se trata de um sinal ajustado a um único gene, mas de uma assinatura estrutural comum ao papel dessas proteínas no reparo do DNA.




Figura 5. Paisagem de detecção na superfície molecular completa do domínio BRCT de BRCA1 e do domínio de ligação ao DNA (DBD) de BRCA2. As zonas douradas — o núcleo funcional de cada domínio — concentram as detecções de patogenicidade; a mesma assinatura estrutural emerge nos dois genes de forma independente, evidência visual de que o modelo capturou mecanismo transferível, e não um artefato específico de BRCA1.

Robustez, meta-análise e o modelo-carro-chefe

Por bootstrap (B = 2000), a AUC externa do domínio (0,847; IC95% 0,810–0,881) não se sobrepõe ao bioquímico (0,717; IC95% 0,668–0,760); em nenhuma

das 2000 reamostragens a diferença foi ≤ 0 . O teste de permutação ($N = 2000$) situa a AUC observada muito além da nula ($0,501$; $p = 5 \times 10^{-4}$). Em 12 sementes de CV bloqueada, a AUC média foi $0,828 \pm 0,005$ (domínio), $0,818 \pm 0,006$ (posição) e $0,763 \pm 0,005$ (bioquímico); o escore de Brier do modelo de domínio é $0,108$, com boa calibração. Combinando domínio e ESM-2, o modelo-carro-chefe atinge AUC externa de $0,909$ (Tabela 4; DeLong $p = 1,5 \times 10^{-10}$ vs. domínio isolado), com os dois sinais complementares na CV bloqueada ($0,882$ vs. $0,818$ e $0,867$ isolados). Como as coortes externas são desbalanceadas (17% patogênicas), a AUC-ROC foi complementada por métricas robustas ao desbalanceamento: o modelo-carro-chefe atinge AUPRC de $0,802$ (contra linha de base trivial de $0,172$), coeficiente de correlação de Matthews de $0,72$ e escore de Brier de $0,074$ (48% melhor que a predição trivial da prevalência) — desempenho que não se explica pela distribuição de classes. Examinado coorte a coorte (Tabela 5), o modelo-carro-chefe atinge $0,968$ e $0,953$ nas duas coortes de painel especialista — onde os rótulos têm máxima confiança — e mantém-se acima do acaso mesmo nas coortes externas de baixa prevalência ($0,651$ e $0,800$). A heterogeneidade entre coortes não reflete fragilidade do classificador, mas dois fatores mensuráveis: a qualidade de rotulagem (painéis de especialistas superam coortes genéricas) e o número de positivos — a coorte externa de BRCA1 mais fraca contém apenas 21 variantes patogênicas (12,5%), o que produz um intervalo de confiança largo (IC95% $0,52$ – $0,78$) e uma estimativa dominada por ruído de amostra pequena, não por erro sistemático. A explicabilidade por SHAP (Figura 6) confirma o escore ESM-2 e a pertinência a domínio crítico como preditores dominantes, com direção de efeito biologicamente correta.

Tabela 4. Modelo-carro-chefe sob o protocolo anti-vazamento (AUC-ROC).

Modelo	CV bloqueada	Externa
Consciente de domínio	0,818	0,847
ESM-2 (650M) sozinho	0,867	0,907
Domínio + ESM-2 (carro-chefe)	0,882	0,909

Tabela 5. Desempenho do modelo-carro-chefe por coorte externa. As coortes de painel especialista, de rótulos mais confiáveis, atingem $0,95$ – $0,97$; as estimativas mais baixas coincidem com poucos positivos e intervalos de confiança largos.

Coorte externa	n	patog.	AUC (modelo)	IC95%
----------------	---	--------	--------------	-------

BRCA1 — painel especialista	204	69	0,968	0,939–0,989
BRCA2 — painel especialista	175	39	0,953	0,894–0,992
BRCA2 — coorte externa	289	15	0,800	0,649–0,936
BRCA1 — coorte externa	168	21	0,651	0,521–0,776




Figura 6. Explicabilidade por valores de Shapley do modelo domínio + ESM-2 — o score ESM-2 e o domínio crítico são os preditores dominantes.

Vazamento a favor de terceiros: a comparação honesta

No mesmo conjunto externo (n = 836), o modelo-carro-chefe foi medido contra preditores publicados (Figura 7; Tabela 6). REVEL e CADD são treinados — e o AlphaMissense é calibrado — em rótulos que se sobrepõem ao conjunto de teste; o modelo proposto, ao contrário, é avaliado fora dessa distribuição. Mesmo em desvantagem, a diferença para os três líderes não é significativa (p = 0,14 a 0,37), e a superioridade sobre SIFT e PolyPhen-2 é clara. Tentou-se isolar o vazamento por corte temporal (≥ 2024); o recorte não separa o efeito de forma limpa — todas as ferramentas melhoram nas variantes recentes (o modelo proposto sobe a 0,932, ainda equivalente aos líderes, p = 0,12–0,61). Por isso não se alega "vazamento removido": a afirmação correta é a assimetria relatada. Empatar sob avaliação mais rigorosa é um resultado mais forte do que o número cru sugere — e é por isso que o

diferencial real não está em vencer no AUC bruto, mas em complementar essas ferramentas onde elas se abstêm.




Figura 7. Comparação honesta com o estado da arte: preditores supervisionados/calibrados em ClinVar (azul) têm circularidade a favor; o modelo-carro-chefe (vermelho) é avaliado fora da distribuição.

Tabela 6. Comparação honesta com o estado da arte (n = 836).

Ferramenta	AUC	Regime	DeLong vs. modelo
REVEL	0,930	supervisionado em ClinVar	p=0,14 (n.s.)
AlphaMissense	0,926	calibrado em ClinVar	p=0,24 (n.s.)
PrimeVarClass	0,909	cego ao externo	—
CADD	0,891	supervisionado em ClinVar	p=0,37 (n.s.)
SIFT	0,845	não supervisionado	p=0,001
PolyPhen-2	0,773	não supervisionado	p<0,0001

Integrando de forma calibrada os quatro sinais, o meta-classificador atingiu AUC de 0,938 (IC95% 0,901–0,969; n = 621) — a melhor marca do estudo, superando mesmo o REVEL isolado (DeLong p = 0,43). Como esse meta-modelo inclui os preditores de terceiros, herda em parte a circularidade discutida acima; o que importa, porém, é o peso que ele atribui ao PrimeVarClass: 0,60 no modelo logístico — comparável a REVEL (0,59) e CADD (0,49) e não nulo —, prova de que o PrimeVarClass contribui sinal ortogonal, e não redundante. Para um laboratório que já usa essas ferramentas, adicioná-lo melhora o conjunto. A mensagem é clara: não competir, mas somar.

Calibração ACMG/AMP e o complemento na zona cinzenta

Os escores foram calibrados aos limiares de Tavgigian/Pejaver: nas coortes externas, PP3 forte corresponde a 94% de patogênicos reais ($LR \approx 76$; $n = 84$), e BP4 moderado a apenas 3,2% ($LR \approx 0,16$; $n = 444$) — evidência confiável nas duas direções. O maior diferencial deste trabalho, porém, está na zona cinzenta do AlphaMissense (Figura 8; Tabela 7): entre 644 variantes reais que ele deixa ambíguas, o modelo forneceu uma chamada de evidência ACMG calibrada (PP3/BP4) para 53,8% dos VUS e 64,6% das conflitantes. Como VUS não têm rótulo definitivo, trata-se de fornecer evidência, não de uma classificação verificável; a verificação é possível apenas no subconjunto que já tinha diagnóstico definitivo (17 variantes), no qual a concordância foi de 100%. Fornece-se, assim, informação exatamente onde a melhor ferramenta atual se cala.




Figura 8. Complemento ao AlphaMissense — evidência calibrada onde ele se abstém, em BRCA1 e BRCA2, com dados reais do ClinVar.

Tabela 7. Resolução de variantes na zona cinzenta do AlphaMissense.

Categoria	BRCA1	BRCA2	Combinado
VUS na zona cinzenta (n)	98	166	264
VUS resolvidas	56,1%	52,4%	53,8%
Conflitantes na zona cinzenta (n)	64	128	192
Conflitantes resolvidas	76,6%	58,6%	64,6%

Mecanismo, equidade e validação temporal

Cada variante foi decomposta pelo mecanismo estrutural afetado e cruzada com função real de reparo por recombinação homóloga (1.262 variantes; STARITA et al., 2015): as categorias diferem de forma altamente significativa (Kruskal-Wallis p

$\approx 3,5 \times 10^{-33}$; Figura 9), com coordenação de zinco a mais deletéria (mediana $-0,844$) e superfície a mais tolerada ($-0,011$). Mais do que isso, a própria probabilidade do modelo — treinada apenas em rótulos clínicos — prevê a perda de função medida experimentalmente por deep mutational scanning, independente do ClinVar: no mesmo ensaio de recombinação homóloga, a probabilidade separa variantes com e sem perda de função com AUC de 0,712 em 2.749 variantes. Trata-se de uma validação ortogonal contra fenótipo molecular medido em bancada, e não contra outro rótulo in silico. Entre variantes com frequência apreciável ($AF > 10^{-4}$), apenas 26,2% têm classificação definitiva em ancestralidades não europeias, contra 55,7% em europeias (Figura 10); o modelo fornece evidência calibrada para 78% das não europeias ainda não resolvidas, e 84% das europeias — de forma equitativa. Simulando implantação prospectiva por corte temporal, a AUC futura cresceu de 0,892 (corte 2016) a 0,932 (corte 2021; Tabela 8).




Figura 9. Mecanismo estrutural previsto versus função medida em laboratório (ensaio de reparo por recombinação homóloga; STARITA et al., 2015). As categorias de mecanismo — da coordenação de zinco à superfície — separam de forma altamente significativa os escores funcionais reais (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$), confirmando que o modelo raciocina sobre biologia real, e não sobre um proxy estatístico.




Figura 10. Lacuna de resolução clínica entre ancestralidades (gnomAD) e a contribuição do modelo para reduzi-la equitativamente.

Tabela 8. Validação temporal (quasi-prospectiva) por ano de corte.

Corte	Treino (n)	Teste futuro (n)	AUC futura
2016	176	323	0,892
2019	279	220	0,926
2021	286	213	0,932

Aprendizado contínuo e seguro

Com um conjunto de variantes recentes mantido travado (≥ 2024 , nunca vistas no treino), rótulos confirmados foram revelados de forma acumulada ao longo do tempo: a AUC no conjunto travado sobe de 0,895 para 0,922 — ganho puro por mais dados reais (Figura 11). A trava de segurança foi testada deliberadamente com um lote de feedback envenenado (30% de rótulos invertidos): o candidato resultante (AUC 0,727) foi corretamente rejeitado pela regra de promoção. Não é promessa: é o mesmo efeito medido na validação temporal, operacionalizado como recurso usável hoje.




Figura 11. Aprendizado contínuo e seguro. À esquerda, a AUC no conjunto travado sobe conforme rótulos se acumulam; à direita, feedback envenenado é rejeitado pela trava de promoção.

Discussão: honestidade metodológica como contribuição, e complemento em vez de concorrência

O achado central é que domínio funcional generaliza, enquanto posição bruta memoriza — inversão diagnóstica confirmada em três momentos distintos: a refutação dos primos, o diagnóstico do vazamento posicional, e a exposição da assimetria de circularidade que desfavorece o modelo proposto na comparação com o estado da arte. Relatar essas três desvantagens, em vez de escondê-las, é reproduzível e auditável, e cada uma é um alerta metodológico útil para a área. A própria refutação dos primos funciona como controle negativo interno: o protocolo que atribui $p = 1,8 \times 10^{-13}$ ao sinal de domínio rejeita o dos primos — prova de que não valida qualquer característica indiscriminadamente. Somam-se dois pontos de rigor: os hiperparâmetros foram fixados a priori, sem ajuste nas coortes de teste; e as afirmações centrais (p entre 10^{-8} e 10^{-13}) sobrevivem à correção de Bonferroni/FDR — só a comparação marginal primos-vs-identidade ($p = 0,045$) não, sendo por isso tratada como apoio, não decisão. Por isso optou-se por não competir com o AlphaMissense no AUC bruto — comparação estruturalmente injusta contra o modelo proposto —, e sim por demonstrar o que realmente importa: evidência calibrada exatamente onde ele se abstém. Um laboratório clínico não precisa escolher entre as duas ferramentas; precisa das duas.

Limitações e trabalhos futuros

A validação concentrou-se em BRCA1/BRCA2; as fronteiras de domínio são aproximações da literatura; a generalização, embora atinja 0,95–0,97 nas coortes de painel especialista, é heterogênea entre coortes, em parte por diferenças de qualidade de rotulagem e por baixos números de positivos nas coortes externas de baixa prevalência; o recorte temporal não isola o vazamento de forma limpa; e a validação funcional apoiou-se na convergência retrospectiva com ensaios de deep mutational scanning publicados — validação ortogonal contra função medida (Starita HDR, AUC 0,712), não em novo experimento de bancada conduzido no âmbito deste trabalho. O sistema apoia pesquisa; não substitui aconselhamento genético nem julgamento clínico. Como trabalhos futuros, pretende-se estender a anotação

de domínio e o ESM-2 a outros genes (TP53, PALB2, CHEK2), ampliar as coortes externas para caracterizar os limites de aplicabilidade, acompanhar em produção o módulo de aprendizado contínuo com laboratórios parceiros, e explorar modelos de linguagem de proteínas com plataformas automatizadas de evolução dirigida (ZHANG et al., 2025) como fonte futura de rótulos funcionais.

Impacto social, aplicação prática e ética no uso de IA

O acesso à interpretação genética é desigual no Brasil (ACHATZ et al., 2020; PALMERO et al., 2007; FERNANDES et al., 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO et al., 2025; NORONHA et al., 2026). O PrimeVarClass é posicionado não como diagnóstico automático, mas como ferramenta de pesquisa responsável: apoio a laboratórios públicos, formação de pesquisadores em boas práticas de validação, suporte translacional e equidade por ser software aberto e de baixo custo computacional, sem exigir GPU. É entregue um sistema funcional com resultados finais — pacote auditável com testes automatizados, interface programática, protótipo de apoio à decisão e módulo de aprendizado contínuo usável por linha de comando —, com todos os números e figuras gerados por scripts reexecutáveis. Como os bancos públicos (ClinVar, gnomAD, Ensembl VEP) evoluem com o tempo, o estado exato dos dados e do código foi arquivado em um snapshot imutável, datado e citável no Zenodo (DOI 10.5281/zenodo.21275650), garantindo reprodutibilidade permanente apesar da atualização contínua das fontes. Em conformidade com o item 2.2.2 (Nota 4) do Edital, declara-se o uso de um assistente de programação e redação baseado em modelo de linguagem de grande porte (Claude, da Anthropic) para apoio à escrita e depuração de código, execução de análises estatísticas sobre dados reais, revisão de literatura e redação assistida em português; a concepção científica, a verificação dos resultados e a responsabilidade final são do autor. Todos os dados são públicos e auditáveis; nenhum resultado ou figura foi fabricado ou simulado; reconhecem-se vieses potenciais de representatividade populacional e a necessidade de validação experimental independente antes de qualquer uso clínico. Nenhuma prática de uso antiético de IA foi empregada.

CONCLUSÃO

Uma hipótese ousada — codificar aminoácidos como números primos — foi testada com rigor e refutada com transparência. Esse resultado negativo conduziu ao diagnóstico da armadilha de vazamento posicional e à construção de um classificador consciente de domínio que generaliza para coortes externas (AUC 0,847; $p = 1,8 \times 10^{-13}$), superando modelos que memorizam. Combinado a um modelo de linguagem de proteínas autêntico, o modelo-carro-chefe alcançou AUC externa de 0,909 — estatisticamente equivalente aos melhores preditores publicados, mesmo avaliado sob a desvantagem que foi tornada explícita. Um meta-classificador atingiu 0,938; a evidência foi calibrada em critérios ACMG/AMP; e demonstrou-se, com dados reais, que o método complementa o AlphaMissense onde ele se abstém, resolvendo mais da metade dos VUS e quase dois terços das variantes conflitantes na sua zona cinzenta. O mecanismo do modelo foi validado contra função medida em laboratório, uma lacuna de equidade entre ancestralidades foi mitigada, a validação prospectiva foi simulada com resultados crescentes, e um mecanismo real e seguro de aprendizado contínuo foi entregue. Esse método é entregue de forma aberta, explicável, auditável e eticamente contida, com aplicação direta ao contexto brasileiro de saúde de precisão. A maior força do PrimeVarClass não é um número, mas um compromisso demonstrado com a ciência honesta — do teste de uma hipótese própria até a correção de uma assimetria que o desfavorecia.

REFERÊNCIAS

- ACHATZ, M. I. et al. Recommendations for Advancing the Diagnosis and Management of Hereditary Breast and Ovarian Cancer in Brazil. *JCO Glob Oncol*, v. 6, p. 439-452, 2020. DOI: 10.1200/JGO.19.00170.
- CHAO, K. R. et al. The landscape of regional missense mutational intolerance quantified from 125,748 exomes. *bioRxiv*, 2024. DOI: 10.1101/2024.04.11.588920.
- CHEN, S. et al. A genomic mutational constraint map using variation in 76,156 human genomes. *Nature*, v. 625, n. 7993, p. 92-100, 2023. DOI: 10.1038/s41586-023-06045-0.
- CHENG, J. et al. Accurate proteome-wide missense variant effect prediction with AlphaMissense. *Science*, v. 381, n. 6664, p. eadg7492, 2023. DOI: 10.1126/science.adg7492.
- DELONG, E. R.; DELONG, D. M.; CLARKE-PEARSON, D. L. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, v. 44, n. 3, p. 837-845, 1988.
- DINES, J. N. et al. Systematic misclassification of missense variants in BRCA1 and BRCA2 "coldspots". *Genet Med*, v. 22, n. 5, p. 825-830, 2020. DOI: 10.1038/s41436-019-0740-6.
- DONG, C. et al. Comparison and integration of deleteriousness prediction methods for nonsynonymous SNVs in whole exome sequencing studies. *Hum Mol Genet*, v. 24, n. 8, p. 2125-37, 2014. DOI: 10.1093/hmg/ddu733.
- FAVALLI, V. et al. Machine learning-based reclassification of germline variants of unknown significance: The RENOVO algorithm. *Am J Hum Genet*, v. 108, n. 4, p. 682-695, 2021. DOI: 10.1016/j.ajhg.2021.03.010.
- FERNANDES, G. C. et al. Differential Profile of BRCA1 vs. BRCA2 Mutated Families: A Characterization of the Main Differences and Similarities in Patients. *Asian Pac J Cancer Prev*, v. 20, n. 6, p. 1655-1660, 2019. DOI: 10.31557/APJCP.2019.20.6.1655.
- FINDLAY, G. M. et al. Saturation editing of genomic regions by multiplex homology-directed repair. *Nature*, v. 513, n. 7516, p. 120-3, 2014. DOI: 10.1038/nature13695.
- FINDLAY, G. M. et al. Accurate classification of BRCA1 variants with saturation genome editing. *Nature*, v. 562, n. 7726, p. 217-222, 2018. DOI: 10.1038/s41586-018-0461-z.
- GANAKAMMAL, S. R.; ALEXOV, E. Evaluation of performance of leading algorithms for variant pathogenicity predictions and designing a combinatory predictor method: application to Rett syndrome variants. *PeerJ*, v. 7, p. e8106, 2019. DOI: 10.7717/peerj.8106.
- HART, S. N. et al. Prediction of the functional impact of missense variants in BRCA1 and BRCA2 with BRCA-ML. *NPJ Breast Cancer*, v. 6, p. 13, 2020. DOI: 10.1038/s41523-020-0159-x.
- HU, C. et al. Classification of BRCA2 Variants of Uncertain Significance (VUS) Using an ACMG/AMP Model Incorporating a Homology-Directed Repair (HDR) Functional Assay. *Clin Cancer Res*, v. 28, n. 17, p. 3742-3751, 2022. DOI: 10.1158/1078-0432.CCR-22-0203.
- IOANNIDIS, N. M. et al. REVEL: An Ensemble Method for Predicting the Pathogenicity of Rare Missense Variants. *Am J Hum Genet*, v. 99, n. 4, p. 877-885, 2016. DOI: 10.1016/j.ajhg.2016.08.016.
- KARCZEWSKI, K. J. et al. The mutational constraint spectrum quantified from variation in 141,456 humans. *Nature*, v. 581, n. 7809, p. 434-443, 2020. DOI: 10.1038/s41586-020-2308-7.
- KERNBACH, J. M.; STAARTJES, V. E. Foundations of Machine Learning-Based Clinical Prediction Modeling: Part II-Generalization and Overfitting. *Acta Neurochir Suppl*, v. 134, p. 15-21, 2022. DOI: 10.1007/978-3-030-85292-4_3.
- LABES, S. et al. Machine-learning of complex evolutionary signals improves classification of SNVs. *NAR Genom Bioinform*, v. 4, n. 2, p. lqac025, 2022. DOI: 10.1093/nargab/lqac025.
- LAKE, N. J. et al. Quantifying constraint in the human mitochondrial genome. *Nature*, v. 635, n. 8038, p. 390-397, 2024. DOI: 10.1038/s41586-024-08048-x.
- LASTA, J. L.; GROTO, A. D.; BRANDALIZE, A. P. C. Assessment of medical knowledge toward genetic testing for individuals with hereditary breast and ovarian cancer syndrome in Brazil. *Prev Med Rep*, v. 35, p. 102356, 2023. DOI: 10.1016/j.pmedr.2023.102356.

LIN, Z. et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, v. 379, n. 6637, p. 1123-1130, 2023. DOI: 10.1126/science.ade2574.

MANRAI, A. K. et al. Genetic Misdiagnoses and the Potential for Health Disparities. *N Engl J Med*, v. 375, n. 7, p. 655-665, 2016. DOI: 10.1056/NEJMsa1507092.

MCCORMICK, E. M. et al. Specifications of the ACMG/AMP standards and guidelines for mitochondrial DNA variant interpretation. *Hum Mutat*, v. 41, n. 12, p. 2028-2057, 2020. DOI: 10.1002/humu.24107.

MEIER, J. et al. Language models enable zero-shot prediction of the effects of mutations on protein function. *NeurIPS*, 2021.

NORONHA, M. M. et al. Beyond 1100delC: distinct CHEK2 variants and unique cancer phenotypes in Northeast Brazil. *Fam Cancer*, v. 25, n. 1, p. 8, 2026. DOI: 10.1007/s10689-025-00526-z.

NYKAMP, K. et al. Sherloc: a comprehensive refinement of the ACMG-AMP variant classification criteria. *Genet Med*, v. 19, n. 10, p. 1105-1117, 2017. DOI: 10.1038/gim.2017.37.

OZA, A. M. et al. Expert specification of the ACMG/AMP variant interpretation guidelines for genetic hearing loss. *Hum Mutat*, v. 39, n. 11, p. 1593-1613, 2018. DOI: 10.1002/humu.23630.

PALMERO, E. I. et al. Clinical characterization and risk profile of individuals seeking genetic counseling for hereditary breast cancer in Brazil. *J Genet Couns*, v. 16, n. 3, p. 363-71, 2007. DOI: 10.1007/s10897-006-9073-0.

PARSONS, M. T. et al. Large scale multifactorial likelihood quantitative analysis of BRCA1 and BRCA2 variants: An ENIGMA resource to support clinical variant classification. *Hum Mutat*, v. 40, n. 9, p. 1557-1578, 2019. DOI: 10.1002/humu.23818.

PEJAVER, V. et al. Calibration of computational tools for missense variant pathogenicity classification and ClinGen recommendations for PP3/BP4 criteria. *Am J Hum Genet*, v. 109, n. 12, p. 2163-2177, 2022. DOI: 10.1016/j.ajhg.2022.10.013.

POPEJOY, A. B.; FULLERTON, S. M. Genomics is failing on diversity. *Nature*, v. 538, n. 7624, p. 161-164, 2016. DOI: 10.1038/538161a.

RAMADANE-MORCHADI, L. et al. ACMG/AMP interpretation of BRCA1 missense variants: Structure-informed scores add evidence strength granularity to the PP3/BP4 computational evidence. *Am J Hum Genet*, v. 112, n. 5, p. 993-1002, 2025. DOI: 10.1016/j.ajhg.2024.12.011.

RENTZSCH, P. et al. CADD: predicting the deleteriousness of variants throughout the human genome. *Nucleic Acids Res*, v. 47, n. D1, p. D886-D894, 2019. DOI: 10.1093/nar/gky1016.

RIBEIRO, A. A. F. et al. Molecular characterization of hereditary breast and ovarian cancer patients from a public precision medicine service in the Southeast Brazilian population. *Sci Rep*, v. 15, n. 1, p. 33495, 2025. DOI: 10.1038/s41598-025-16870-0.

RICHARDS, S. et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of Medical Genetics and Genomics and the Association for Molecular Pathology. *Genet Med*, v. 17, n. 5, p. 405-24, 2015. DOI: 10.1038/gim.2015.30.

SHETTY, A. P. et al. A leakage-controlled and SHAP driven machine learning framework for paediatric respiratory disease classification using Indian hospital EHR data. *BMC Med Inform Decis Mak*, v. 26, n. 1, 2026. DOI: 10.1186/s12911-026-03493-2.

SMOL, T. et al. Performance of meta-predictors for the classification of MED13L missense variations, implication of raw parameters. *Eur J Med Genet*, v. 65, n. 1, p. 104398, 2021. DOI: 10.1016/j.ejmg.2021.104398.

SOEWITO, S. et al. Disparities in Cancer Genetic Testing and Variants of Uncertain Significance in the Hispanic Population of South Texas. *JCO Oncol Pract*, v. 18, n. 5, p. e805-e813, 2022. DOI: 10.1200/OP.22.00090.

STARITA, L. M. et al. Massively Parallel Functional Analysis of BRCA1 RING Domain Variants. *Genetics*, v. 200, n. 2, p. 413-422, 2015. DOI: 10.1534/genetics.115.175802.

SUYBENG, V. et al. Comparison of Pathogenicity Prediction Tools on Somatic Variants. *J Mol Diagn*, v. 22, n. 12, p. 1383-1392, 2020. DOI: 10.1016/j.jmoldx.2020.08.007.

TIAN, Y. et al. REVEL and BayesDel outperform other in silico meta-predictors for clinical variant classification. *Sci Rep*, v. 9, n. 1, p. 12752, 2019. DOI: 10.1038/s41598-019-49224-8.

TOLAND, A. E.; ANDREASSEN, P. R. DNA repair-related functional assays for the classification of BRCA1 and BRCA2 variants: a critical review and needs assessment. *J Med Genet*, v. 54, n. 11, p. 721-731, 2017. DOI: 10.1136/jmedgenet-2017-104707.

TORRETTO, G. C. et al. Domain-Specific Computational, Functional and Structural Methods Enable Interpretation of BRCT Variants of Uncertain Significance. *Curr Oncol*, v. 33, n. 6, 2026. DOI: 10.3390/currenco133060354.

UNIPROT CONSORTIUM, THE. UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Res*, v. 51, n. D1, p. D523-D531, 2023.

YANG, H. et al. BRCA2 function in DNA binding and recombination from a BRCA2-DSS1-ssDNA structure. *Science*, v. 297, n. 5588, p. 1837-1848, 2002. DOI: 10.1126/science.297.5588.1837.

ZHANG, X. et al. Genetic constraint at single amino acid resolution in protein domains improves missense variant prioritisation and gene discovery. *Genome Med*, v. 16, n. 1, p. 88, 2024. DOI: 10.1186/s13073-024-01358-9.

ZHANG, Q. et al. Integrating protein language models and automatic biofoundry for enhanced protein evolution. *Nat Commun*, v. 16, n. 1, p. 1553, 2025. DOI: 10.1038/s41467-025-56751-8.