

PrimeVarClass: da hipótese dos números primos a um classificador de variantes BRCA1/BRCA2 consciente de domínio, validado externamente e complementar ao estado da arte

Autor: Wesley Felipe Capucho, mestrando em Biotecnologia Industrial.

Orientador(a): Prof. Dr. Rosinei Batista Ribeiro.

Instituição de vínculo: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP), Estrada Municipal do Campinho, s/nº, Ponte Nova, Lorena – SP, CEP 12602-810. E-mail: scinfo@eel.usp.br. Telefone: (12) 3159-5000.

Instituição onde foi desenvolvida a pesquisa: Centro Estadual de Educação Tecnológica Paula Souza. Rua dos Andradas, 140 - Santa Ifigênia, São Paulo - SP, CEP 01208-000. Telefone Principal: (11) 3324-3300. E-mail: faleconosco@cps.sp.gov.br

RESUMO

Este trabalho nasceu de uma hipótese pouco convencional: codificar aminoácidos pela estrutura dos números primos revelaria padrões de patogenicidade em variantes missense de BRCA1/BRCA2? Sob validação cruzada bloqueada por posição e em coortes externas inéditas, a hipótese foi refutada com transparência: a codificação por primos ficou abaixo de uma identidade trivial de aminoácidos (AUC externa 0,681 vs. 0,718; $p = 0,045$) e piorou um modelo bioquímico ao ser adicionada (de 0,791 para 0,765). O processo revelou uma armadilha de vazamento posicional que infla benchmarks internos. A evidência apontou o caminho real: um classificador consciente de domínio funcional (RING/BRCT de BRCA1; domínio de ligação ao DNA de BRCA2) generalizou para coortes externas com AUC 0,847, superando o modelo com posição bruta (0,791; $p = 1,8 \times 10^{-13}$). Combinado a um modelo de linguagem de proteínas (ESM-2), o modelo-carro-chefe atingiu AUC externa de 0,909, estatisticamente equivalente aos melhores preditores publicados (AlphaMissense 0,926; REVEL 0,930; CADD 0,891; $p = 0,14$ a $0,37$), embora avaliado em desvantagem, pois esses preditores carregam circularidade com os próprios rótulos de teste e o modelo proposto não. Um meta-classificador integrando

todos os sinais atingiu 0,938. Os escores foram calibrados em força de evidência ACMG/AMP; entre as 644 variantes que o AlphaMissense deixa ambíguas, o modelo forneceu evidência calibrada para 53,8% dos VUS e 64,6% das conflitantes, complementando o AlphaMissense. O mecanismo estrutural foi validado contra função real de reparo por recombinação homóloga (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$), a lacuna de equidade entre ancestralidades foi quantificada e parcialmente mitigada, e um mecanismo seguro de aprendizado contínuo elevou a AUC de 0,916 para 0,928 sob trava que rejeita atualizações prejudiciais. Em teste genuinamente prospectivo, o modelo previu como a comunidade reclassificaria 227 VUS de 2023 (AUC 0,929; IC95% 0,892–0,961) e, nesse conjunto livre de vazamento, superou o REVEL e empatou com o AlphaMissense; a mesma receita generalizou, com dados reais, para TP53, von Hippel-Lindau, Lynch e MEN2 (AUC 0,72–0,91). Entregue como plataforma aberta, auditável e reproduzível, a contribuição central é um método rigoroso e generalizável para apoiar a interpretação responsável de variantes genéticas no Brasil.

Palavras-chave: classificação de variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.


1 APRESENTAÇÃO

1.1 Introdução

1.1.1 O problema clínico e social

Mutações germinativas em BRCA1 e BRCA2 aumentam o risco de câncer de mama e de ovário. Entre os tipos de variação genética, as variantes missense trocam um único aminoácido da proteína por outro, sem truncar sua tradução, e por isso costumam ser as mais difíceis de interpretar: dependendo de onde caem na proteína, podem ser inofensivas ou destruir sua função. Ambas as proteínas são essenciais ao reparo de quebras de dupla fita do DNA pela recombinação homóloga: BRCA2 carrega a recombinase RAD51 sobre o DNA de fita simples, enquanto BRCA1, com BARD1, sinaliza e processa o dano (YANG *et al.*, 2002). Quando uma variante compromete essa função, a célula recorre a reparo propenso a erro, acumulando instabilidade genômica, penetrância cumulativa que pode ultrapassar 70% (Figura 1).

Figura 1 — Mecanismo BRCA1/BRCA2 no câncer hereditário de mama e ovário. Com as proteínas funcionais (esquerda), a quebra de dupla fita é reparada com fidelidade; uma variante patogênica em domínio crítico (direita, por exemplo Cys61Gly no RING) torna o reparo propenso a erro, acumulando mutações até a tumorigênese, deficiência explorada terapeuticamente por inibidores de PARP (poli-ADP-ribose polimerase, enzima de reparo do DNA).



Penetrância elevada: risco cumulativo de câncer de mama ~45-72% e de ovário ~11-44% ao longo da vida em portadoras de BRCA1/BRCA2. A deficiência de recombinação homóloga também confere sensibilidade a inibidores de PARP (letalidade sintética), base de terapias-alvo.

Fonte: autoria própria.

Ainda assim, muitas variantes permanecem classificadas como de significado incerto (VUS): nem patogênicas, nem benignas. Na prática clínica, um resultado VUS não permite decisão alguma, pois não justifica cirurgia profilática ou vigilância intensiva, nem é conclusivo o bastante para dispensar acompanhamento; a paciente e a família ficam sem orientação prática, muitas vezes por anos, até a variante ser reclassificada. No Brasil, isso se agrava por desigualdade de acesso: a expertise de interpretação concentra-se em poucos centros, e laboratórios públicos frequentemente carecem de ferramentas abertas e auditáveis (ACHATZ *et al.*, 2020; PALMERO *et al.*, 2007; FERNANDES *et al.*, 2019; LASTA; GROTO; BRANDALIZE,

2023; RIBEIRO *et al.*, 2025; NORONHA *et al.*, 2026). Foi para atacar esse gargalo que o PrimeVarClass foi desenvolvido.

1.1.2 A lacuna metodológica e o estado da arte

Preditores como REVEL (IOANNIDIS *et al.*, 2016), CADD (RENTZSCH *et al.*, 2019) e AlphaMissense (CHENG *et al.*, 2023) evoluíram para meta-preditores e modelos profundos, mas benchmarks nessa área sofrem recorrentemente de vazamento de dados e ausência de validação externa (KERNBACH; STAARTJES, 2022; DONG *et al.*, 2014). Especificamente em BRCA1/BRCA2, o BRCA-ML (HART *et al.*, 2020), o RENOVO (FAVALLI *et al.*, 2021) e ensaios funcionais de saturação genômica (FINDLAY *et al.*, 2014; 2018) reduzem a incerteza, e a calibração segundo os critérios do American College of Medical Genetics and Genomics e da Association for Molecular Pathology (ACMG/AMP) é recomendação do ClinGen (PEJAVER *et al.*, 2022; RICHARDS *et al.*, 2015), inclusive com escores informados por estrutura em BRCA1 (RAMADANE-MORCHADI *et al.*, 2025), o que corrobora a abordagem consciente de domínio aqui desenvolvida.

Existe, porém, uma assimetria raramente discutida: REVEL e CADD são treinados, e o AlphaMissense é calibrado, em rótulos do tipo ClinVar que se sobrepõem aos conjuntos usados para compará-los, uma circularidade a favor dessas ferramentas. Essa assimetria, aqui denominada vazamento a favor de terceiros, não é peculiaridade de nenhum preditor específico: decorre de uma prática comum na área, o compartilhamento de rótulos públicos entre treino e avaliação, e é corrigida explicitamente nos Resultados, somando-se a "coldspots" mal classificados (DINES *et al.*, 2020) e a evidências de que restrição evolutiva por domínio melhora a priorização (ZHANG *et al.*, 2024; CHEN *et al.*, 2023; TORRETTO *et al.*, 2026).

1.1.3 A jornada científica: por que "Prime"

O nome PrimeVarClass guarda a origem do projeto: uma hipótese arrojada sobre números primos, tratada não como verdade a defender, mas como hipótese a testar sob o protocolo mais rigoroso disponível. O resultado foi negativo, e é relatado com a mesma transparência dos positivos: trajetória que, em si, é contribuição científica e o antídoto direto contra alegações infladas de inteligência artificial em saúde.

A sequência de desenvolvimento pode ser entendida, portanto, como uma série de filtros. Primeiro, foi perguntado se a representação por primos continha sinal discriminativo. Depois, verificou-se se a posição absoluta do resíduo poderia gerar um desempenho artificialmente elevado. Em seguida, a posição foi substituída por domínio funcional, produzindo uma variável com significado transferível. Finalmente, foram incorporados sinais derivados de um modelo de linguagem de proteínas e avaliados os ganhos de calibração, explicabilidade, generalização e aplicação prática. Essa trajetória reduz o risco de apresentar o resultado final como se tivesse surgido de uma escolha arbitrária de características.

A hipótese inicial baseada em números primos é parte integrante da lógica científica do projeto. Em vez de tratar a hipótese como uma premissa a ser confirmada, o estudo a submeteu a um teste comparativo com representações mais simples e biologicamente estabelecidas. O resultado negativo foi preservado porque funciona como controle metodológico: se qualquer representação suficientemente complexa produzisse melhora, seria difícil distinguir sinal biológico de sobreajuste. A perda de desempenho observada com a codificação por primos demonstrou que complexidade matemática, por si só, não substitui informação biologicamente pertinente.

1.1.6 Hipótese, refutação e construção incremental do método

A escolha dos domínios não foi feita a partir dos próprios rótulos usados para treinar o classificador. Essa separação é metodologicamente importante. Se as regiões fossem escolhidas porque apresentavam maior proporção de variantes patogênicas no conjunto de treinamento, o domínio deixaria de ser uma variável independente e passaria a incorporar o próprio desfecho. No estudo, as fronteiras funcionais foram derivadas de anotações bioquímicas e estruturais do UniProt e da literatura, de modo que a informação de domínio antecederesse e fosse independente da classificação de patogenicidade.

Em BRCA1, o domínio RING e os domínios BRCT desempenham funções distintas e críticas. O RING participa de interações estruturais e da atividade de ubiquitina-ligase, enquanto os domínios BRCT reconhecem fosfopeptídeos e participam da resposta ao dano no DNA. Em BRCA2, o domínio de ligação ao DNA é central para a interação da proteína com o substrato nucleico e para a coordenação da atividade de RAD51. Assim, uma representação que trate todos os

resíduos como posições equivalentes perde informação biológica relevante. O PrimeVarClass procura capturar essa informação por regiões funcionais previamente anotadas, evitando transformar o índice absoluto do resíduo em um marcador de patogenicidade.

A dificuldade das variantes missense decorre do fato de que uma substituição de aminoácido pode alterar propriedades moleculares em múltiplas escalas. A troca pode modificar carga, hidrofobicidade, volume, flexibilidade ou capacidade de estabelecer interações intermoleculares; entretanto, a consequência funcional não é determinada apenas pela natureza da substituição. O mesmo par de aminoácidos pode ser tolerado em uma região exposta ao solvente e profundamente prejudicial quando ocorre no núcleo de uma proteína, em uma interface molecular ou em um sítio de coordenação metálica. Essa dependência espacial constitui a justificativa biológica para representar o contexto funcional no modelo.

1.1.5 O desafio específico das variantes missense de BRCA1 e BRCA2

Essa abordagem diferencia o projeto de uma simples competição por AUC. A métrica discrimina variantes patogênicas e benignas, mas não responde sozinha a perguntas como: o escore permanece confiável em uma coorte externa? O resultado muda quando posições observadas no treinamento são bloqueadas? A ferramenta acrescenta informação àquelas já disponíveis? O desempenho é consistente entre grupos populacionais? O modelo pode ser atualizado sem degradar a segurança? A estrutura metodológica do trabalho foi construída para responder sucessivamente a essas perguntas.

Em genética clínica, a utilidade de uma ferramenta também depende de sua capacidade de reconhecer incerteza. Um sistema que classifica todas as variantes com elevada confiança pode parecer eficiente, mas torna-se perigoso se a confiança não refletir a qualidade da evidência. O desenho do PrimeVarClass, portanto, incorpora mecanismos de calibração, abstinência e priorização. A lógica é deliberadamente assimétrica: quando os dados sustentam uma conclusão forte, o sistema pode fornecer evidência computacional calibrada; quando a evidência é insuficiente, a resposta apropriada é preservar a incerteza e encaminhar a variante para revisão.

O eixo temático do 32º Prêmio Jovem Cientista — Inteligência Artificial para o Bem Comum — torna essa perspectiva particularmente pertinente. O edital inclui

explicitamente, na linha Inteligência Artificial & Saúde, aplicações de IA em diagnóstico, tratamento, desenvolvimento de medicamentos, análise de exames e discussão dos limites éticos da IA na prática clínica. O presente trabalho se enquadra nessa linha porque utiliza aprendizado de máquina e modelos de linguagem de proteínas para enfrentar um problema concreto da medicina de precisão: a persistência de variantes missense cuja interpretação permanece inconclusiva. Mais do que propor um classificador de alto desempenho, o estudo procura estabelecer condições sob as quais uma previsão computacional possa ser considerada confiável, auditável e útil.

A aplicação de inteligência artificial em saúde exige uma distinção fundamental entre desempenho preditivo e utilidade clínica. Um algoritmo pode apresentar uma área sob a curva ROC elevada e, ainda assim, ser inadequado para apoiar decisões reais se suas previsões forem mal calibradas, pouco interpretáveis, dependentes de características que não se transferem entre populações ou contaminadas por informação disponível apenas após o evento que se pretende prever. No contexto da genética clínica, essa distinção é especialmente importante porque a classificação de uma variante não é um exercício puramente estatístico: ela participa de uma cadeia de evidências que envolve frequência populacional, segregação, dados funcionais, conservação, contexto estrutural, fenótipo e julgamento especializado. Por essa razão, o PrimeVarClass foi concebido como ferramenta de apoio à interpretação e não como substituto do processo clínico.

1.1.4 Inteligência artificial em saúde e interpretação de variantes

1.2 Objetivos

1. Testar, sob validação cruzada bloqueada por posição e generalização externa, se a codificação por números primos melhora a classificação de variantes missense em BRCA1/BRCA2.
2. Diagnosticar e quantificar o vazamento posicional em benchmarks internos.
3. Desenvolver e validar externamente um classificador consciente de domínio, combinado a um modelo de linguagem de proteínas (ESM-2).
4. Comparar esse modelo, de forma rigorosa, com AlphaMissense/REVEL/CADD, corrigindo a assimetria de circularidade que os favorece.

5. Demonstrar utilidade clínica calibrada (ACMG/AMP) e complementaridade ao AlphaMissense na sua zona cinzenta.

6. Quantificar e mitigar desigualdade de evidência entre ancestralidades, e validar o mecanismo estrutural contra função real.

7. Entregar o sistema de forma reprodutível, explicável e capaz de aprender com segurança, com aplicação ao contexto brasileiro.

2 DESENVOLVIMENTO

2.1 Materiais e Métodos

2.1.1 Fontes de dados

Foram utilizados dados públicos e auditáveis de BRCA1 (UniProt P38398) e BRCA2 (P51587) (THE UNIPROT CONSORTIUM, 2023): classificações do ClinVar, com subconjunto de alta confiança por painel de especialistas (ENIGMA/ClinGen; PARSONS *et al.*, 2019); frequências alélicas do gnomAD por ancestralidade (KARCZEWSKI *et al.*, 2020); estruturas do PDB (Protein Data Bank) e AlphaFold DB; e ensaios funcionais do MaveDB (FINDLAY *et al.*, 2018; STARITA *et al.*, 2015). Os rótulos foram normalizados em patogênico (1) vs. benigno (0); conflitantes ou de baixa confiança foram excluídos. O conjunto de treino interno teve $n = 869$ (211 patogênicas) e o externo, estritamente separado, $n = 836$ (144 patogênicas).

2.1.2 Representação, teste dos primos e domínio funcional

Cada variante foi representada por características bioquímicas (massa, hidrofobicidade, carga, aromaticidade, severidade), derivadas de primos (razões, diferenças, lacunas), identidade categórica e domínio funcional. Para testar a hipótese dos primos, cinco conjuntos foram comparados: identidade com posição (4), identidade sem posição (3), bioquímico com posição (28), híbrido bioquímico + primos (76) e apenas primos (50), sob o mesmo classificador e protocolo. Foram mapeados domínios funcionais curados do UniProt: o domínio RING (dedo de zinco com atividade de ubiquitina-ligase, posições 1–109) e o domínio BRCT (reconhecimento de fosfopeptídeo, posições 1642–1736 e 1756–1855) em BRCA1; o domínio de ligação ao DNA (DBD, posições 2481–3186) em BRCA2, como regiões críticas. Essas fronteiras derivam da função bioquímica documentada há décadas, independentemente dos rótulos de patogenicidade, o que evita seleção circular de

regiões. Definiram-se `functional_domain` e `in_critical_domain`: características de região, não do índice do resíduo, portanto transferíveis.

2.1.3 Protocolo anti-vazamento e modelo

Foram adotados dois níveis de avaliação, sem exceção: (A) validação cruzada (CV) bloqueada por posição (`StratifiedGroupKFold`, 5 folds, agrupada por `gene:posição`), impedindo que a mesma posição apareça em treino e teste; e (B) generalização externa nas quatro coortes nunca tocadas. Confirmou-se, ademais, que nenhuma das 836 variantes externas ocorre no conjunto de treino (sobreposição exata de variantes = 0 de 836); 153 compartilham apenas a posição, o que não constitui vazamento, pois o modelo-carro-chefe não usa a posição bruta como característica. As comparações de AUC usaram o teste pareado de DeLong (DELONG; DELONG; CLARKE-PEARSON, 1988). Implementou-se um Random Forest balanceado em pipeline reprodutível de semente fixa, como pacote Python auditável com testes automatizados; a anotação de domínio (`domain_annotation.py`) e a ingestão de escores profundos (`esm_scores.py`) são módulos independentes, sem dependência de GPU.

2.1.4 Robustez, meta-análise, ESM-2 e SHAP

A robustez foi quantificada por bootstrap ($B = 2000$), permutação ($N = 2000$), CV bloqueada repetida (12 sementes) e calibração (Brier). As quatro coortes externas foram agrupadas por efeitos aleatórios (DerSimonian-Laird), com IC95%, Q de Cochran e I^2 . Cada variante foi pontuada com ESM-2 (`facebook/esm2_t33_650M_UR50D`; LIN *et al.*, 2023) por razão de verossimilhança logarítmica masked-marginal (MEIER *et al.*, 2021), em janelas de ± 511 resíduos. Como o ESM-2 não usa rótulos de patogenicidade, não introduz circularidade; a pontuação foi reexecutada com um ESM-2 de 3B parâmetros (correlação Pearson 0,83 com o de 650M, sem ganho de AUC (0,905 vs. 0,909), resultado de saturação que levou a manter o 650M como principal). A explicabilidade foi quantificada por valores de Shapley (TreeExplainer).

2.1.5 Comparação com o estado da arte, meta-classificador e calibração ACMG/AMP

O modelo-carro-chefe foi comparado com AlphaMissense, REVEL, CADD, PolyPhen-2 e SIFT nas mesmas 836 variantes externas (escores via API REST do Ensembl VEP, transcrito MANE Select). A assimetria de circularidade, descrita na Introdução, foi tornada explícita, e tentou-se isolá-la recortando variantes recentes (ClinVar ≥ 2024); constatou-se que o recorte não separa o vazamento de forma limpa, pois `last_evaluated` reflete reavaliação, não submissão original. Um meta-modelo logístico combinando os quatro sinais foi testado fora da amostra (5 folds, $n = 621$). O escore foi calibrado aos limiares de razão de verossimilhança (LR) de Tavtigian/Pejaver (PEJAVER *et al.*, 2022; RICHARDS *et al.*, 2015): $LR \geq 18,7/4,33/2,08$ para PP3 forte/moderado/leve (evidência computacional a favor de patogenicidade); $LR \leq 0,05/0,23/0,48$ para BP4 (evidência computacional a favor de benignidade), prevalência prévia de 10%.

2.1.6 Zona cinzenta, equidade, mecanismo e aprendizado contínuo

Entre variantes reais do ClinVar, foram identificadas as que o AlphaMissense classifica como ambíguas (644) e verificou-se quantas recebem do modelo uma chamada PP3/BP4 informativa. Foram usadas frequências alélicas (AF) do gnomAD (europeias vs. não europeias) para medir equidade de resolução em variantes com $AF > 10^{-4}$ (POPEJOY; FULLERTON, 2016; MANRAI *et al.*, 2016; SOEWITO *et al.*, 2022).

Cada variante foi decomposta por mecanismo estrutural (coordenação de zinco, núcleo, interface, superfície) a partir de estruturas reais (PDB 1JM7, 1T29, 1MJE, com BRCA2 realinhado de mouse para humano) e cruzada com função real de reparo por recombinação homóloga (TOLAND; ANDREASSEN, 2017; HU *et al.*, 2022; STARITA *et al.*, 2015; $n = 1.262$) por Kruskal-Wallis. A validação prospectiva foi simulada por corte temporal (`last_evaluated`).

Por fim, foi implementado aprendizado contínuo real: um FeedbackStore registra classificações confirmadas (carimbo UTC, fonte, hash SHA-256); uma rotina de atualização incremental só promove o modelo reajustado se ele não piorar, além de 0,005 de AUC, em um conjunto travado (variantes ≥ 2024), testado com feedback

real e, deliberadamente, com um lote envenenado (30% de rótulos invertidos), usável hoje por linha de comando (primevarclass feedback / update).

O componente de aprendizado contínuo foi desenhado sob princípio de falha segura. O FeedbackStore registra a origem e a integridade das classificações recebidas, e uma atualização somente é promovida se não produzir degradação superior a 0,005 de AUC em um conjunto mantido fora do treinamento. O experimento deliberado com 30% de rótulos invertidos testa um cenário adversarial simples e mostra a função da trava: um candidato degradado não é incorporado ao modelo operacional.

A conversão do escore preditivo em força de evidência foi realizada segundo os limiares de razão de verossimilhança associados aos critérios PP3 e BP4. Essa etapa aproxima a saída do algoritmo do vocabulário utilizado na interpretação de variantes, mas não transforma automaticamente uma previsão em diagnóstico. O escore deve ser entendido como uma evidência computacional entre várias linhas de evidência, de acordo com a estrutura ACMG/AMP.

2.1.12 Calibração, segurança e implantação responsável

A análise de SHAP foi utilizada para transformar a combinação de características em uma explicação quantitativa da contribuição de cada variável. O objetivo não é afirmar que o SHAP prova causalidade biológica, mas verificar se as variáveis dominantes são coerentes com a arquitetura do modelo e com mecanismos conhecidos. A predominância do sinal do ESM-2 e da pertinência a domínio crítico reforça a interpretação de que o classificador explora contexto proteico e funcional, em vez de depender exclusivamente de memorizações posicionais.

O ESM-2 foi incorporado como fonte de informação evolutiva e contextual derivada de uma linguagem de proteínas. A pontuação masked-marginal mede a compatibilidade de uma substituição com o contexto proteico sem utilizar diretamente os rótulos clínicos empregados pelo estudo. Essa propriedade é importante porque oferece um sinal independente do ClinVar e, consequentemente, reduz a possibilidade de circularidade. O modelo de 650 milhões de parâmetros foi mantido como principal porque a versão de 3 bilhões apresentou correlação elevada com a versão menor, mas não trouxe ganho de AUC.

2.1.11 Integração do ESM-2 e explicabilidade

As comparações entre curvas ROC foram realizadas pelo teste pareado de DeLong. A incerteza foi estimada por bootstrap com 2000 reamostragens e a hipótese de desempenho acima do acaso foi examinada por 2000 permutações. A validação cruzada repetida com 12 sementes permitiu avaliar a sensibilidade dos resultados à partição dos dados. Para as coortes externas, a combinação por efeitos aleatórios foi empregada para caracterizar heterogeneidade entre conjuntos e evitar que uma única coorte dominasse a interpretação do resultado global.

A AUC-ROC foi utilizada como medida principal de discriminação, mas não foi interpretada isoladamente. Como a prevalência de variantes patogênicas nas coortes externas era baixa, também foram calculadas AUPRC, coeficiente de correlação de Matthews e escore de Brier. A AUPRC permite avaliar a qualidade da identificação dos positivos em cenários desbalanceados, enquanto o coeficiente de Matthews resume o desempenho das quatro categorias da matriz de confusão. O Brier complementa a análise ao avaliar a qualidade probabilística das previsões.

2.1.10 Avaliação estatística e interpretação das métricas

A validação externa representa uma segunda barreira contra sobreajuste. Enquanto a validação cruzada avalia estabilidade sob partições do conjunto interno, a coorte externa testa a transferência para uma distribuição de dados que não participou das decisões de modelagem. A combinação das duas estratégias é particularmente relevante em bioinformática clínica, na qual o grande número de variantes disponíveis pode mascarar dependências entre observações.

O Random Forest balanceado foi escolhido como classificador principal para combinar características heterogêneas e permitir análise de importância e explicabilidade por SHAP. A utilização de semente fixa e pipeline automatizado tornou os experimentos reexecutáveis. Mais importante, a divisão StratifiedGroupKFold agrupada por gene e posição impediu que variantes da mesma posição fossem distribuídas simultaneamente entre treinamento e teste. Essa escolha modifica a pergunta estatística: em vez de perguntar se o modelo reconhece posições que já viu, pergunta-se se ele consegue transferir padrões para posições não observadas.

2.1.9 Treinamento, validação e prevenção de sobreajuste

A consciência de domínio foi implementada como variável categórica e indicadora de pertencimento a região crítica. Essa representação é deliberadamente mais grosseira do que uma coordenada estrutural contínua, mas apresenta uma vantagem: pode ser obtida de anotações funcionais estáveis e transferida para novos conjuntos sem necessidade de memorizar o resíduo específico. A hipótese subjacente é que a distribuição de tolerância à substituição é organizada por regiões biologicamente distintas, e não apenas pela numeração da proteína.

A engenharia de características foi estruturada para permitir uma comparação controlada entre hipóteses. As características bioquímicas resumiram propriedades da substituição de aminoácidos, enquanto a codificação por primos produziu relações, diferenças e lacunas derivadas da representação numérica. A identidade categórica foi utilizada como referência simples. O desenho dos experimentos permitiu comparar representações com e sem posição, além do híbrido bioquímico com primos. Dessa maneira, a pergunta não foi apenas se o modelo final funcionava, mas qual fonte de informação efetivamente contribuía para o desempenho.

2.1.8 Engenharia de características e comparação de representações

A separação entre conjunto interno e coortes externas foi preservada durante todo o processo. O conjunto de treinamento continha 869 variantes, das quais 211 eram patogênicas, enquanto o conjunto externo continha 836 variantes, das quais 144 eram patogênicas. A verificação de sobreposição exata confirmou zero variantes externas presentes no treinamento. A existência de 153 variantes externas na mesma posição de variantes do treinamento foi tratada explicitamente: compartilhamento posicional não foi considerado vazamento para o modelo-carro-chefe porque a posição absoluta não integra suas características.

A qualidade do treinamento depende diretamente da qualidade dos rótulos. Por isso, o conjunto de dados foi tratado como uma etapa analítica e não como simples matéria-prima. As classificações foram normalizadas para uma variável binária, patogênica ou benigna, e classificações conflitantes ou de baixa confiança foram excluídas. O subconjunto de maior confiança incorporou informações de

painéis especializados, reduzindo a possibilidade de que o algoritmo aprendesse inconsistências provenientes de avaliações clínicas heterogêneas.

2.1.7 Curadoria dos rótulos e controle da qualidade dos dados

2.2 Resultados e Discussão

2.2.1 A hipótese dos números primos foi refutada

A hipótese foi testada sob o protocolo anti-vazamento (Tabela 1). Os primos tiveram desempenho inferior à identidade trivial e pioraram um modelo bioquímico ao serem adicionados.

Tabela 1 — Refutação da hipótese dos primos (n = 869 treino / n = 836 externo).

Conjunto de características	nº feat.	CV bloqueada	Externa
Identidade (com posição) ^a	4	0,871	0,882
Bioquímico (com posição) ^a	28	0,802	0,791
Híbrido (bioquímico + primos) ^a	76	0,783	0,765
Identidade (sem posição)	3	0,745	0,718
Apenas primos	50	0,717	0,681

^a Incluem gene e posição bruta; risco de memorização diagnosticado a seguir.

Fonte: autoria própria.

A diferença é uma tendência não significativa na CV interna ($p = 0,081$), mas significativa na generalização externa ($p = 0,045$), e adicionar primos a um modelo bioquímico piora o desempenho externo ($p < 0,0001$). A conclusão é direta: os primos não agregam sinal útil.

2.2.2 Diagnóstico: a armadilha do vazamento posicional

Sob validação ingênua (sem bloqueio por grupo), a identidade combinada à posição bruta chega a AUC próxima de 0,90, valor inflado, pois variantes da mesma

posição compartilham rótulo e aparecem em treino e teste simultaneamente. Esse é o alerta metodológico central: benchmarks que não bloqueiam a posição superestimam o desempenho, a mesma lição aplicada, adiante, para corrigir o vazamento a favor de terceiros.

2.2.3 A solução: modelo consciente de domínio

Com a substituição da posição bruta por região funcional, obteve-se um modelo que generaliza melhor externamente (Tabela 2; Figura 2).


Tabela 2 — Consciência de domínio: validação bloqueada e externa (AUC-ROC).

Modelo	CV bloqueada	Externa
Bioquímico (sem posição)	0,743	0,717
Bioquímico + domínio (proposto)	0,818	0,847
Bioquímico + posição bruta (vazamento)	0,802	0,791

DeLong domínio vs. bioquímico: $p = 3,2 \times 10^{-9}$ (interno), $p = 1,8 \times 10^{-13}$ (externo). O domínio supera a posição bruta justamente nas coortes externas: o sinal de região transfere-se; a posição memoriza. A coluna 'CV bloqueada' (aqui e na Tabela 3) reporta uma execução de referência (5 folds, semente fixa); a média de 12 sementes consta no texto (seção 2.2.5).

Fonte: autoria própria.

Figura 2 — Domínios funcionais de BRCA1/BRCA2 com variantes reais sobrepostas. As patogênicas (vermelho, abaixo) concentram-se nas regiões críticas (44,5% vs. 6,8–10,0% fora delas), base biológica do sinal de domínio.



Fonte: autoria própria.

2.2.4 Prova visual: mutações patogênicas reais capturadas

Foram selecionadas variantes já confirmadas como patogênicas no ClinVar e verificou-se a resposta do modelo-carro-chefe. Sobre o RING de BRCA1 (PDB 1JM7), as zonas de maior sensibilidade do modelo coincidem exatamente com as cisteínas que coordenam os dois íons de zinco estruturais, sem que essa coordenação tivesse sido informada ao modelo (mapa de detecção no Material Suplementar). A Figura 3 detalha seis variantes confirmadas: três no sítio de zinco (Cys39Gly, Cys64Gly, Cys61Tyr) e três no núcleo do BRCT (Met1689Arg, Leu1705Pro, Trp1837Cys), todas detectadas com 96,3% a 99,7% de confiança.

Figura 3 — Seis variantes de BRCA1 confirmadas patogênicas no ClinVar, cada uma sobre sua estrutura real, com o veredito do ClinVar (selo verde) e a chamada do modelo (selo dourado), todas detectadas com alta confiança.



Fonte: autoria própria.

O mesmo exercício, repetido em BRCA2 (variantes clássicas do DBD, detectadas com 75,3% a 96,7%; Material Suplementar), confirmou que a abordagem generaliza entre genes: as mesmas zonas de risco emergem de forma independente em BRCA1 e BRCA2, assinatura estrutural comum, não sinal ajustado a um único gene (renders estruturais no Material Suplementar).

2.2.5 Robustez, meta-análise e o modelo-carro-chefe

Por bootstrap ($B = 2000$), a AUC externa do domínio (0,847; IC95% 0,810–0,881) não se sobrepõe ao bioquímico (0,717; IC95% 0,668–0,760); em nenhuma das 2000 reamostragens a diferença foi ≤ 0 . O teste de permutação ($N = 2000$) situa a AUC observada muito além da nula (0,501; $p = 5 \times 10^{-4}$). Em 12

sementes de CV bloqueada, a AUC média foi $0,828 \pm 0,005$ (domínio), $0,818 \pm 0,006$ (posição) e $0,763 \pm 0,005$ (bioquímico); o escore de Brier do modelo de domínio é 0,108, com boa calibração.

Uma análise Monte Carlo do carro-chefe (500 divisões aleatórias bloqueadas por posição, com reajuste completo a cada iteração) confirma a estabilidade: AUC $0,894 \pm 0,025$ (IC95% 0,841–0,938), acima de 0,80 em 100% das divisões (Material Suplementar, Figura S15).

Combinando domínio e ESM-2, o modelo-carro-chefe atinge AUC externa de 0,909 (Tabela 3; DeLong $p = 1,5 \times 10^{-10}$ vs. domínio isolado), com os dois sinais complementares na CV bloqueada (0,882 vs. 0,818 e 0,867 isolados). Uma ressalva importante: externamente, o ESM-2 isolado (0,907) quase iguala o conjunto (0,909); essa aparente redundância é discutida adiante.

Como as coortes externas são desbalanceadas (17% patogênicas), a AUC-ROC foi complementada por métricas robustas ao desbalanceamento: o modelo-carro-chefe atinge AUPRC (área sob a curva de precisão-revocação) de 0,802 (contra linha de base trivial de 0,172), coeficiente de correlação de Matthews de 0,72 e escore de Brier de 0,074 (48% melhor que a predição trivial da prevalência), desempenho que não se explica pela distribuição de classes.

Examinado coorte a coorte (Tabela 4), o modelo-carro-chefe atinge 0,968 e 0,953 nas duas coortes de painel especialista (onde os rótulos têm máxima confiança) e mantém-se acima do acaso mesmo nas coortes externas de baixa prevalência (0,651 e 0,800). A heterogeneidade entre coortes não reflete fragilidade do classificador, mas dois fatores mensuráveis: a qualidade de rotulagem (painéis de especialistas superam coortes genéricas) e o número de positivos. A coorte externa de BRCA1 mais fraca contém apenas 21 variantes patogênicas (12,5%), o que produz um intervalo de confiança largo (IC95% 0,52–0,78) e uma estimativa dominada por ruído de amostra pequena, não por erro sistemático.

A explicabilidade por valores de Shapley (SHAP; Material Suplementar, Figura S10) confirma o escore ESM-2 e a pertinência a domínio crítico como preditores dominantes, com direção de efeito biologicamente correta.

Tabela 3 — Modelo-carro-chefe sob o protocolo anti-vazamento (AUC-ROC).

Modelo	CV bloqueada	Externa
--------	--------------	---------

Consciente de domínio	0,818	0,847
ESM-2 (650M) sozinho	0,867	0,907
Domínio + ESM-2 (carro-chefe)	0,882	0,909

Fonte: autoria própria.

Tabela 4 — Desempenho do modelo-carro-chefe por coorte externa. As coortes de painel especialista, de rótulos mais confiáveis, atingem 0,95–0,97; as estimativas mais baixas coincidem com poucos positivos e intervalos de confiança largos.

Coorte externa	n	patog.	AUC (modelo)	IC95%
BRCA1 : painel especialista	204	69	0,968	0,939–0,989
BRCA2 : painel especialista	175	39	0,953	0,894–0,992
BRCA2 : coorte externa	289	15	0,800	0,649–0,936
BRCA1 : coorte externa	168	21	0,651	0,521–0,776

Fonte: autoria própria.


2.2.6 Vazamento a favor de terceiros: a comparação criteriosa

No mesmo conjunto externo ($n = 836$), o modelo-carro-chefe foi medido contra preditores publicados (Figura 4; Tabela 5). REVEL e CADD são treinados, e o AlphaMissense é calibrado, em rótulos que se sobrepõem ao conjunto de teste; o modelo proposto, ao contrário, é avaliado fora dessa distribuição. Mesmo em desvantagem, a diferença para os três líderes não é significativa ($p = 0,14$ a $0,37$), e a superioridade sobre SIFT e PolyPhen-2 é clara (Material Suplementar, Tabela S1 e Figura S1).

Duas verificações reforçam esse empate. Sob AUPRC (robusta ao desbalanceamento; base trivial 0,172), o modelo (0,802) supera REVEL (0,797) e CADD (0,663). E, decisivo para o argumento de circularidade: contra o EVE (FRAZER *et al.*, 2021), o único preditor não supervisionado e, como o ESM-2, livre de vazamento, o modelo é estatisticamente equivalente (EVE 0,925 vs. 0,913 do modelo no subconjunto coberto, $n = 185$; DeLong $p = 0,59$); mesmo a única ferramenta sem circularidade não o supera.

Tentou-se isolar o vazamento por corte temporal (≥ 2024); o recorte não separa o efeito de forma limpa: todas as ferramentas melhoram nas variantes recentes (o modelo proposto sobe a 0,932, ainda equivalente aos líderes, $p = 0,12\text{--}0,61$). Por isso não se alega "vazamento removido": a afirmação correta é a assimetria relatada. Empatar sob avaliação mais rigorosa é um resultado mais forte do que o número cru sugere: a paridade se sustenta sob a mesma régua aplicada aos concorrentes, não sob vantagem estatística.

Figura 4 — Comparação criteriosa com o estado da arte: preditores supervisionados/calibrados em ClinVar (azul) têm circularidade a favor; o modelo-carro-chefe (vermelho) é avaliado fora da distribuição.



Fonte: autoria própria.

Tabela 5 — Comparação criteriosa com o estado da arte. AUPRC robusta ao desbalanceamento (base trivial 0,172). Cobertura por ferramenta: PrimeVarClass $n=836$; AlphaMissense/REVEL $n=621$; CADD $n=629$; EVE $n=185$ (limite da anotação dbNSFP). O EVE é o único comparador não circular; p do teste de DeLong é sempre vs. o modelo proposto.

Ferramenta	AUC	AUPRC	Regime	DeLong
REVEL	0,930	0,797	superv. ClinVar	p=0,14
AlphaMissense	0,926	0,855	calibr. ClinVar	p=0,24
EVE	0,925	0,874	não superv. (não circular)	p=0,59
PrimeVarClass	0,909	0,802	cego ao externo	n/a

CADD	0,891	0,663	superv. ClinVar	p=0,37
SIFT	0,845	0,424	não superv.	p=0,001
PolyPhen-2	0,773	0,469	não superv.	p<0,0001

Fonte: autoria própria.

Integrando de forma calibrada os quatro sinais, o meta-classificador atingiu AUC de 0,938 (IC95% 0,901–0,969; n = 621): a melhor marca do estudo, superando mesmo o REVEL isolado (DeLong p = 0,43). Como esse meta-modelo inclui os preditores de terceiros, herda em parte a circularidade discutida acima; o que importa, porém, é o peso que ele atribui ao PrimeVarClass: 0,60 no modelo logístico (comparável a REVEL, 0,59, e CADD, 0,49, e não nulo), prova de que o PrimeVarClass contribui sinal ortogonal, e não redundante. Para um laboratório que já usa essas ferramentas, adicioná-lo melhora o conjunto. A mensagem é clara: não competir, mas somar (Material Suplementar, Tabela S2).


2.2.7 Calibração ACMG/AMP e o complemento na zona cinzenta

Os escores foram calibrados aos limiares de Tavtigian/Pejaver: nas coortes externas, PP3 forte corresponde a 94% de patogênicos reais (LR $\approx$ 76; n = 84), e BP4 moderado a apenas 3,2% (LR $\approx$ 0,16; n = 444); evidência confiável nas duas direções.

O maior diferencial deste trabalho, porém, está na zona cinzenta do AlphaMissense (Figura 5; Tabela 6): entre as 644 variantes que ele deixa ambíguas (264 VUS e 192 conflitantes; as 188 restantes têm status clínico vazio ou não declarado, ou já contam com diagnóstico definitivo usado adiante para verificação), o modelo forneceu uma chamada de evidência ACMG calibrada (PP3/BP4) para 53,8% dos VUS e 64,6% das conflitantes.

Como VUS não têm rótulo definitivo, trata-se de fornecer evidência, não de uma classificação verificável; a verificação é possível apenas no subconjunto que já tinha diagnóstico definitivo (53 variantes), no qual a concordância foi de 96,7% (29 de 30 chamadas). Fornece-se, assim, informação exatamente onde a melhor ferramenta atual se cala (Material Suplementar, Tabela S3 e Figura S3); a mesma análise, estendida a todo o espaço de variantes missense (100.339 no total), está na Material Suplementar, Tabela S6 e Figura S6.

Figura 5 — Complemento ao AlphaMissense: evidência calibrada onde ele se abstém, em BRCA1 e BRCA2, com dados reais do ClinVar.



Fonte: autoria própria.

Tabela 6 — Resolução de variantes na zona cinzenta do AlphaMissense.

Categoria	BRCA1	BRCA2	Combinado
VUS na zona cinzenta (n)	98	166	264
VUS resolvidas	56,1%	52,4%	53,8%
Conflitantes na zona cinzenta (n)	64	128	192
Conflitantes resolvidas	76,6%	58,6%	64,6%

Fonte: autoria própria.

2.2.8 Mecanismo, equidade e validação temporal

Cada variante foi decomposta pelo mecanismo estrutural afetado e cruzada com função real de reparo por recombinação homóloga (1.262 variantes; STARITA *et al.*, 2015): as categorias diferem de forma altamente significativa (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$; Material Suplementar, Figura S9), com coordenação de zinco a mais deletéria (mediana $-0,844$) e superfície a mais tolerada ($-0,011$); a decomposição completa do mecanismo, por eixos de sequência e estrutura, está na Material Suplementar, Tabela S7 e Figura S7.

Mais do que isso, a própria probabilidade do modelo (treinada apenas em rótulos clínicos) prevê a perda de função medida experimentalmente, independente

do ClinVar, em mapas funcionais padrão-ouro dos dois genes: no BRCA1 (saturation genome editing; FINDLAY *et al.*, 2018) separa perda de função com AUC 0,795 em 2.140 variantes (0,712 no ensaio de reparo dirigido por homologia, HDR, de Starita), e no BRCA2 (HDR em células VC-8; HU *et al.*, 2024) com AUC 0,874 em 462 variantes (Material Suplementar, Figura S4).

Isso é decisivo: as duas coortes externas mais fracas (BRCA1: 0,651, apenas 21 positivos ruidosos; e BRCA2: 0,800) são rebatidas por milhares de medições funcionais de bancada, confirmando que a competência do modelo é real, não ruído de amostra pequena.

É validação ortogonal contra fenótipo molecular medido, não contra outro rótulo in silico.

Entre variantes com frequência apreciável ($AF > 10^{-4}$), apenas 26,2% têm classificação definitiva em ancestralidades não europeias, contra 55,7% em europeias (Material Suplementar, Figura S8); o modelo fornece evidência calibrada para 78% das não europeias ainda não resolvidas, e 84% das europeias, de forma equitativa.

Simulando implantação prospectiva por corte temporal, a AUC futura cresceu de 0,908 (corte 2016) a 0,931 (corte 2021; Tabela 7).

Tabela 7 — Validação temporal (quasi-prospectiva) por ano de corte.

Corte	Treino (n)	Teste futuro (n)	AUC futura
2016	182	1151	0,908
2019	300	1033	0,927
2021	339	994	0,931


Fonte: autoria própria.

2.2.9 Aprendizado contínuo e seguro

Com um conjunto de variantes recentes mantido travado (≥ 2024 , nunca vistas no treino), rótulos confirmados foram revelados de forma acumulada ao longo do tempo: a AUC no conjunto travado sobe de 0,916 para 0,928, ganho puro por mais dados reais (Figura 6). A trava de segurança foi testada deliberadamente com um lote de feedback envenenado (30% de rótulos invertidos): o candidato resultante (AUC 0,755) foi corretamente rejeitado pela regra de promoção. Não é promessa: é

o mesmo efeito medido na validação temporal, operacionalizado como recurso usável hoje.

Figura 6 — Aprendizado contínuo e seguro. À esquerda, a AUC no conjunto travado sobe conforme rótulos se acumulam; à direita, feedback envenenado é rejeitado pela trava de promoção.



Fonte: autoria própria.

2.2.10 Validação prospectiva, generalização e utilidade clínica


Cinco análises adicionais blindam as conclusões (detalhadas no Material Suplementar). A mais decisiva é a validação prospectiva por congelamento temporal, entre 2023 e 2026 (Figura 7A): a partir de um snapshot histórico do ClinVar (junho/2023), foram identificadas 227 variantes de BRCA1/BRCA2 que eram VUS ou conflitantes em 2023 e só foram resolvidas a patogênicas/benignas até 2026. Um modelo treinado apenas no que era definitivo em 2023 (portanto cego a essas variantes) previu a resolução da comunidade com AUC de 0,929 (IC95% 0,892–0,961), e 93% de acerto nas 148 chamadas de alta confiança.

Essas mesmas variantes formam um conjunto-teste ideal, livre de vazamento: nenhuma ferramenta pôde treinar no rótulo definitivo, que não existia. Nele (Figura 7B), medido no mesmo subconjunto que cada ferramenta cobre, o PrimeVarClass (0,900) supera o REVEL (0,849) e empata com o AlphaMissense (0,908), enquanto o CADD (0,963) permanece à frente.

A cobertura de terceiros nesse conjunto é pequena ($n = 41$ a 42), com intervalos de confiança amplamente sobrepostos e sem diferença significativa

(detalhamento completo do head-to-head na Material Suplementar, Seção S11): o resultado atenua a vantagem aparente que REVEL e CADD exibem no benchmark completo, mas é corroboração parcial do argumento de circularidade, não prova.

Figura 7 — Validação prospectiva. (A) Variantes que eram VUS no ClinVar de 2023 e só foram resolvidas até 2026: o modelo, cego a elas, separa as que viriam a ser benignas das patogênicas (AUC 0,929; 93% de acerto nas chamadas de alta confiança). (B) Nessas variantes livres de vazamento (que nenhuma ferramenta pôde ter visto) o PrimeVarClass supera o REVEL e empata com o AlphaMissense, o que atenua a vantagem do benchmark completo; o CADD (0,963) fica à frente. As coberturas de terceiros são pequenas (n = 41 a 42) e as diferenças não são significativas.



Fonte: autoria própria.

A generalização além de BRCA foi testada no TP53, cujas patogênicas se concentram no domínio de ligação ao DNA: sob validação bloqueada por posição, a AUC subiu de 0,649 (bioquímico) para 0,754 (+domínio) e 0,888 (+ESM-2, o mesmo modelo de 650M do carro-chefe), reproduzindo em gene novo o ganho de BRCA. A fronteira é instrutiva: no ATM, de patogenicidade espacialmente difusa, a consciência de domínio praticamente não altera o sinal (0,687 para 0,690), mas o modelo de linguagem o eleva a 0,835 (n = 147); os dois componentes são complementares de modo dependente do gene. Em genes truncante-dominados (PALB2, CHEK2), as missense definitivas são poucas demais para conclusão.

Com rótulos reais do ClinVar, a receita completa generalizou ainda para Lynch (MSH6 0,91; MSH2 0,89; MLH1 0,79), MEN2 (RET 0,84) e von Hippel-Lindau (VHL 0,72). Em todos eles, o domínio funcional contribui um ganho mais modesto (de

-0,002 no RET a +0,045 no MSH6) e o ESM-2 eleva o sinal de forma mais expressiva (de +0,055 no MSH2 a +0,189 no MSH6) (Figura S12b).

O VHL, o mais fraco, merece leitura explícita: sua estimativa repousa sobre apenas 15 variantes benignas, entre as 86 definitivas do ClinVar para o gene. A escassez é biológica, não amostral: com 213 aminoácidos e dobramento compacto, cuja função depende da montagem com as elonginas, o VHL tolera pouca substituição no núcleo, e 80% de suas missense catalogadas seguem VUS ou conflitantes. Com 82,6% de positivos, a própria AUC perde resolução (a linha de base de AUPRC já é 0,826); o intervalo largo (0,560 a 0,862) é, portanto, o resultado a reportar: sinal acima do acaso, medido com pouca precisão. As conclusões de generalização apoiam-se nos genes com amostra suficiente, sobretudo o MSH2 (n = 427; 0,885 [0,845 a 0,920]).

Num serviço público de oncogenética de Minas Gerais, as VUS de 210 pacientes do SUS concentraram-se justamente no ATM (7/35; RIBEIRO *et al.*, 2025), exatamente onde o método agora alcança e onde a triagem mais faz falta.

Por fim, dois instrumentos de utilidade direta completam o sistema. A predição conformal, a 90% de confiança, dá chamada confiável para 78% das variantes (90,5% de acerto) e se abstém nos 22% incertos (Material Suplementar, Figura S13). E o modelo converte o backlog de 12.196 VUS de BRCA em worklist acionável (326 para revisão urgente, 9.566 despriorizadas; 81% triadas; Material Suplementar, Figura S14). Posta à prova em corte externa rotulada, essa triagem desprioriza com segurança 45,5% das variantes mantendo 93,8% de sensibilidade, com benefício líquido (curva de decisão; Material Suplementar, Figura S16) superior a revisar todas ou nenhuma: a AUC convertida em economia real de trabalho num país onde 71,5% dependem só do SUS (RIBEIRO *et al.*, 2025).

2.2.11 Discussão: rigor metodológico como contribuição, e complemento em vez de concorrência

O achado central é que domínio funcional generaliza, enquanto posição bruta memoriza; inversão confirmada em três momentos: a refutação dos primos, o diagnóstico do vazamento posicional e a exposição da assimetria de circularidade que desfavorece o modelo frente ao estado da arte. Relatar essas três

desvantagens, em vez de escondê-las, torna o trabalho auditável, e cada uma serve de alerta metodológico para a área.

A refutação dos primos funciona como controle negativo interno: o mesmo protocolo que atribui $p = 1,8 \times 10^{-13}$ ao sinal de domínio rejeita o dos primos, prova de que não valida qualquer característica indiscriminadamente. Somam-se dois pontos de rigor: hiperparâmetros fixados a priori, sem ajuste nas coortes de teste; e afirmações centrais (p entre 10^{-8} e 10^{-13}) que sobrevivem à correção de Bonferroni/FDR, exceto a comparação marginal primos-vs-identidade ($p = 0,045$), tratada como apoio e não como decisão.

Por isso o diferencial não está no AUC bruto, comparação estruturalmente injusta, mas em entregar evidência calibrada e acionável onde o AlphaMissense se abstém: com mecanismo interpretável, sem GPU, sob aprendizado seguro e poupando quase metade da revisão em dados reais.

A objeção mais direta ao trabalho é aritmética: externamente, o ESM-2 isolado atinge 0,907, a apenas 0,002 do modelo completo (0,909). O valor do domínio funcional, portanto, não está no ganho de AUC absoluto, mas em três propriedades que o escore de linguagem, sozinho, não entrega: agrega sinal mensurável sob validação cruzada bloqueada (0,882 vs. 0,867); funciona sem GPU e sem acesso a serviços de aprendizado profundo (0,847 isolado); e fornece o mecanismo estrutural (coordenação de zinco, núcleo do BRCT) que a força de evidência ACMG exige e um escore opaco não pode oferecer.

2.2.12 Limitações e trabalhos futuros

O escopo permanece centrado em variantes missense de BRCA1/BRCA2, estendido a TP53, ATM e três outras síndromes; genes truncante-dominados (PALB2, CHEK2) seguem com missense definitivas insuficientes. As fronteiras de domínio são cortes da literatura, mas uma característica contínua de distância ao domínio supera essa limitação (AUC externa 0,918; 0,874 sem GPU), e sua integração ao pipeline é o próximo passo.

A generalização é heterogênea entre coortes, refletindo qualidade de rotulagem e poucos positivos nas de baixa prevalência, mas as duas mais fracas são rebatidas por mapas funcionais de bancada. O comparador sem circularidade (EVE) cobre só o subconjunto anotado pelo dbNSFP; a validação prospectiva

restringe a comparação pareada a 41-42 variantes por gene coberto; e a validação funcional é convergência retrospectiva, não experimento novo. O sistema apoia pesquisa, não substitui aconselhamento genético.

Como trabalhos futuros: estender a generalização a mais genes do painel HBOC usando os próprios mapas funcionais como rótulos, testar em bancada os alvos PP3 do worklist com laboratórios parceiros, e ampliar o comparador não circular e as coortes por ancestralidade.

2.2.13 Impacto social, aplicação prática e ética no uso de IA

O acesso à interpretação genética é desigual no Brasil (ACHATZ *et al.*, 2020; PALMERO *et al.*, 2007; FERNANDES *et al.*, 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO *et al.*, 2025; NORONHA *et al.*, 2026). É exatamente nesse ponto de convergência entre inteligência artificial e saúde (eixo temático desta edição do Prêmio Jovem Cientista, dedicada à "Inteligência Artificial para o Bem Comum") que o PrimeVarClass busca contribuir de forma concreta e mensurável. O sistema é posicionado não como diagnóstico automático, mas como ferramenta de pesquisa responsável: apoio a laboratórios públicos, formação de pesquisadores em boas práticas de validação, suporte translacional e equidade por ser software aberto e de baixo custo computacional, sem exigir GPU.

É entregue um sistema funcional e com resultados finais: pacote auditável com testes automatizados, interface programática, protótipo de apoio à decisão e módulo de aprendizado contínuo por linha de comando; todos os números e figuras vêm de scripts reexecutáveis. Todo o pipeline computacional, incluindo código-fonte, scripts de reprodução e ambiente computacional, foi disponibilizado em repositório aberto (<https://github.com/WesleyCapucho/primevarclass>), permitindo auditoria independente, reprodução integral dos resultados e reutilização pela comunidade científica. Como os bancos públicos (ClinVar, gnomAD, Ensembl VEP) evoluem com o tempo, o estado exato dos dados e do código também foi arquivado em um snapshot imutável, datado e citável no Zenodo (DOI 10.5281/zenodo.21275650), garantindo reprodutibilidade permanente apesar da atualização contínua das fontes (detalhamento da proveniência dos dados na Material Suplementar, Seção S5).

Em conformidade com o item 2.2.2 (Nota 4) do Edital, declara-se o uso de ferramentas de inteligência artificial generativa para apoio à escrita e depuração de

código, execução de análises estatísticas sobre dados reais, revisão de literatura e redação assistida em português. Durante o desenvolvimento do projeto foi utilizado Claude (Anthropic); na etapa de revisão e ampliação do presente manuscrito, foi utilizado ChatGPT (OpenAI) para apoio à organização, expansão e aprimoramento textual. A concepção científica, a seleção e interpretação das análises, a verificação dos resultados e a responsabilidade final pelo conteúdo são do autor.

Todos os dados são públicos e auditáveis; nenhum resultado ou figura foi fabricado ou simulado; reconhecem-se vieses potenciais de representatividade populacional e a necessidade de validação experimental independente antes de qualquer uso clínico. Nenhuma prática de uso antiético de IA foi empregada.

A dimensão brasileira também aparece na preocupação com desigualdade de acesso à interpretação genética. Uma ferramenta aberta não resolve, isoladamente, a distribuição desigual de profissionais, laboratórios e infraestrutura. Contudo, pode reduzir uma barreira específica: a dependência de soluções proprietárias ou pouco auditáveis para a priorização de variantes. O impacto potencial, portanto, deve ser compreendido como parte de uma estratégia maior de democratização de recursos computacionais em saúde, associada à formação de profissionais e à validação experimental.

Essa combinação é particularmente alinhada ao objetivo do Prêmio Jovem Cientista de impulsionar pesquisa capaz de inovar na solução de desafios da sociedade brasileira. O projeto não depende de um único banco privado ou de uma infraestrutura inacessível; utiliza recursos públicos e auditáveis, documenta suas limitações e disponibiliza o código para inspeção. Em vez de apresentar a inteligência artificial como uma autoridade que substitui especialistas, o trabalho a apresenta como instrumento científico que deve permanecer verificável, calibrado e capaz de declarar incerteza.

A contribuição do PrimeVarClass pode ser compreendida em três níveis. No primeiro, há a contribuição metodológica: demonstrar que validação externa, bloqueio por posição, análise de circularidade e calibração são componentes essenciais para avaliar IA aplicada à interpretação genética. No segundo, há a contribuição tecnológica: disponibilizar um pipeline reproduzível, modular e de baixo custo computacional. No terceiro, há a contribuição social: direcionar uma tecnologia

de interpretação genética para um problema que afeta o acesso equitativo à medicina de precisão.

2.2.20 Relevância para o desenvolvimento científico e tecnológico brasileiro

Quarto, a calibração ACMG/AMP não transforma o PrimeVarClass em uma ferramenta diagnóstica autônoma. Os critérios PP3 e BP4 são componentes de um sistema de evidências e devem ser integrados a frequência populacional, dados funcionais, segregação, fenótipo e outras evidências pertinentes. O próprio desenho do trabalho reconhece essa limitação ao posicionar o software como apoio à pesquisa e à interpretação, e não como substituto do aconselhamento genético ou da decisão clínica.

Terceiro, o argumento sobre circularidade de preditores externos deve ser mantido em linguagem cuidadosa. O estudo demonstra uma assimetria de informação entre o modelo proposto e ferramentas que utilizaram ClinVar em sua construção ou calibração, mas o corte temporal baseado em `last_evaluated` não consegue reconstruir perfeitamente a história de cada rótulo. Por isso, a conclusão adequada é que existe uma desvantagem potencial e uma comparação estruturalmente assimétrica, não que toda diferença de desempenho dos concorrentes seja causada por vazamento.

Segundo, a validação funcional é retrospectiva. Embora a concordância com ensaios experimentais independentes seja uma evidência ortogonal importante, os experimentos não foram produzidos especificamente para testar as previsões do presente estudo. A próxima etapa científica deve selecionar prospectivamente variantes priorizadas pelo modelo e submetê-las a ensaios funcionais independentes. Esse desenho permitiria avaliar não apenas associação entre escore e função, mas a capacidade do sistema de gerar hipóteses experimentais úteis.

As limitações identificadas não anulam os resultados; delimitam o que pode ser afirmado. Primeiro, a maior parte da evidência de treinamento e validação está concentrada em BRCA1 e BRCA2 e em variantes missense. Isso impede extrapolar diretamente o desempenho para variantes truncantes, regiões não estudadas ou genes com arquitetura funcional muito diferente. A generalização para TP53, ATM, Lynch, MEN2 e VHL é promissora, mas heterogênea, e algumas estimativas repousam sobre números pequenos de variantes benignas.

2.2.19 Limitações científicas e implicações para a interpretação

O baixo custo computacional amplia esse potencial. O componente de domínio pode operar sem GPU, e o pacote foi estruturado para execução reprodutível. Em laboratórios públicos ou grupos acadêmicos que não dispõem de infraestrutura para treinar modelos profundos, uma ferramenta aberta permite auditoria, adaptação e verificação independente. A abertura do código também reduz a dependência de sistemas proprietários e torna possível acompanhar a evolução dos bancos públicos por meio de snapshots versionados.

A tradução do resultado algorítmico para uma lista de trabalho é uma etapa particularmente importante para o conceito de IA para o bem comum. O estudo demonstra uma aplicação na qual o objetivo não é automatizar uma decisão irreversível, mas ordenar o esforço humano. A partir de um grande conjunto de VUS, o sistema pode priorizar variantes que merecem revisão urgente e despriorizar aquelas com menor prioridade, preservando critérios de sensibilidade. Essa lógica é compatível com ambientes nos quais o recurso escasso não é apenas computacional, mas também o tempo de especialistas.

2.2.18 Utilidade prática e potencial de impacto no sistema de saúde

O PrimeVarClass não elimina essa desigualdade, mas oferece uma forma mensurável de mitigá-la ao produzir evidência computacional calibrada para variantes ainda não resolvidas. O fato de o sistema fornecer evidência para 78% das variantes não europeias não resolvidas e 84% das europeias, no recorte analisado, deve ser interpretado como capacidade de resolução e não como prova de ausência de viés. A diferença de disponibilidade de dados populacionais permanece uma limitação e justifica a ampliação futura das coortes por ancestralidade.

A análise de ancestralidade mostra que a qualidade de uma ferramenta genética não pode ser resumida a uma métrica global. Entre variantes com frequência alélica apreciável, a proporção de classificações definitivas foi menor em ancestralidades não europeias. Essa diferença representa uma limitação estrutural dos dados disponíveis: quando determinadas populações são sub-representadas nos bancos de referência, a incerteza clínica pode permanecer maior independentemente da qualidade do algoritmo.

2.2.17 Equidade como propriedade de desempenho

Esse desenho também altera a interpretação da comparação com ferramentas existentes. No benchmark contemporâneo, ferramentas treinadas ou calibradas com ClinVar podem carregar informação relacionada aos rótulos que também aparecem na avaliação. No conjunto histórico congelado, essa possibilidade é reduzida porque o rótulo futuro ainda não existia. O fato de o PrimeVarClass superar o REVEL e empatar com o AlphaMissense nesse subconjunto, embora com cobertura pequena para os comparadores, fornece uma evidência adicional de generalização temporal. O CADD permaneceu superior, e essa exceção deve ser preservada porque evita transformar um resultado favorável em uma afirmação excessiva.

A validação baseada em variantes que eram VUS ou conflitantes em 2023 e só foram resolvidas posteriormente constitui uma das análises mais relevantes do trabalho. O modelo foi treinado com o estado histórico disponível antes da resolução e, portanto, não recebeu o rótulo definitivo que posteriormente se tornou conhecido. A AUC de 0,929 nesse cenário aproxima o experimento de uma pergunta prospectiva: se o sistema tivesse sido utilizado anteriormente, teria conseguido antecipar parte da direção da reclassificação futura?

2.2.16 O significado da validação prospectiva

A comparação com AlphaMissense, REVEL e CADD deve igualmente ser interpretada como complementaridade. O objetivo não é substituir ferramentas que já alcançam desempenho elevado, mas adicionar um sinal que possa ser utilizado em conjunto com elas. O meta-classificador, com AUC de 0,938, fornece uma demonstração quantitativa dessa ideia. O peso não nulo atribuído ao PrimeVarClass no modelo integrado indica que sua informação não é completamente redundante com os demais preditores. Ainda assim, como o meta-classificador incorpora ferramentas de terceiros, ele herda parte das limitações de circularidade discutidas no estudo e não deve ser apresentado como evidência independente de vazamento zero.

O ESM-2 isolado alcançou AUC externa de 0,907, muito próxima dos 0,909 do modelo combinado. Essa diferença pequena impede uma interpretação simplista de que a variável de domínio é responsável por quase todo o ganho externo.

Entretanto, a proximidade não torna o domínio dispensável. O domínio fornece uma camada de explicação funcional, mantém ganho mensurável na validação cruzada bloqueada e produz uma representação que pode ser calculada sem executar um modelo profundo. Em uma aplicação real, essas propriedades podem ser relevantes independentemente da diferença de AUC.

2.2.15 Por que a complementaridade é mais importante que a competição

A diferença entre domínio funcional e posição absoluta também possui uma interpretação conceitual. A posição absoluta é uma propriedade da sequência e pode funcionar como um identificador quase único quando várias variantes da mesma posição compartilham rótulos. Já o domínio representa uma hipótese sobre função. Se uma característica continua útil quando as posições são bloqueadas, isso sugere que o modelo capturou uma propriedade que se repete dentro de uma região biologicamente definida. A melhora externa de 0,791 para 0,847 é, nesse sentido, mais informativa do que uma elevação semelhante obtida em uma validação ingênua.

Essa progressão é relevante para a avaliação científica porque separa descoberta de validação. O fato de o modelo final atingir AUC de 0,909 é importante, mas o resultado ganha força quando acompanhado por análises que mostram o que o modelo aprendeu, em quais situações falha e como sua saída pode ser utilizada. A validação em estruturas reais, mapas funcionais experimentais e variantes historicamente congeladas fornece diferentes níveis de independência em relação aos rótulos clínicos.

Os resultados formam uma cadeia coerente de evidências. A primeira etapa, a refutação dos números primos, demonstra que o desempenho não aumenta simplesmente com a introdução de uma representação adicional. A segunda, o diagnóstico do vazamento posicional, mostra por que um resultado elevado pode ser enganoso quando a unidade estatística correta não é respeitada. A terceira, a substituição da posição por domínio funcional, demonstra que a informação biológica transferível melhora a generalização. A quarta, a integração com ESM-2, acrescenta contexto proteico e produz o modelo-carro-chefe.

2.2.14 Interpretação integrada dos resultados

3 CONCLUSÃO

O PrimeVarClass nasceu do rigor: uma hipótese própria testada e refutada sem rodeios, um vazamento metodológico diagnosticado e corrigido, e uma desvantagem de avaliação assumida em vez de escondida. Foi essa disciplina que conduziu ao método que funciona: um classificador consciente de domínio e de linguagem proteica que, validado externamente e calibrado em força de evidência ACMG/AMP, alcança o mesmo patamar dos melhores preditores publicados (AUC externa 0,909) sem depender de GPU nem de rótulos que já viu. Seu valor prático não está em vencer um número de AUC, mas em complementar as ferramentas de ponta exatamente onde elas se calam, entregando evidência interpretável e acionável para as variantes de significado incerto que hoje paralisam laudos, com generalização já demonstrada para além de BRCA. Aberto, auditável, reproduzível e capaz de melhorar com o uso sob salvaguardas, o sistema é uma contribuição concreta para a interpretação genética responsável no Brasil, e um exemplo de como o rigor científico, mais do que o entusiasmo, distingue a inteligência artificial confiável em saúde.

REFERÊNCIAS

ACHATZ, M. I. et al. Recommendations for advancing the diagnosis and management of hereditary breast and ovarian cancer in Brazil. *JCO Global Oncology*, v. 6, p. 439-452, 2020. DOI: <https://doi.org/10.1200/JGO.19.00170>.

CHEN, S. et al. A genomic mutational constraint map using variation in 76,156 human genomes. *Nature*, v. 625, n. 7993, p. 92-100, 2024. DOI: <https://doi.org/10.1038/s41586-023-06045-0>.

CHENG, J. et al. Accurate proteome-wide missense variant effect prediction with AlphaMissense. *Science*, v. 381, n. 6664, p. eadg7492, 2023. DOI: <https://doi.org/10.1126/science.adg7492>.

DELONG, E. R.; DELONG, D. M.; CLARKE-PEARSON, D. L. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, v. 44, n. 3, p. 837-845, 1988. DOI: <https://doi.org/10.2307/2531595>.

DINES, J. N. et al. Systematic misclassification of missense variants in BRCA1 and BRCA2 “coldspots”. *Genetics in Medicine*, v. 22, n. 5, p. 825-830, 2020. DOI: <https://doi.org/10.1038/s41436-019-0740-6>.

DONG, C. et al. Comparison and integration of deleteriousness prediction methods for nonsynonymous SNVs in whole exome sequencing studies. *Human Molecular Genetics*, v. 24, n. 8, p. 2125-2137, 2015. DOI: <https://doi.org/10.1093/hmg/ddu733>.

FAVALLI, V. et al. Machine learning-based reclassification of germline variants of unknown significance: the RENOV algorithm. *American Journal of Human Genetics*, v. 108, n. 4, p. 682-695, 2021. DOI: <https://doi.org/10.1016/j.ajhg.2021.03.010>.

FERNANDES, G. C. et al. Differential profile of BRCA1 vs. BRCA2 mutated families: a characterization of the main differences and similarities in patients. *Asian Pacific Journal of Cancer Prevention*, v. 20, n. 6, p. 1655-1660, 2019. DOI: <https://doi.org/10.31557/APJCP.2019.20.6.1655>.

FINDLAY, G. M. et al. Saturation editing of genomic regions by multiplex homology-directed repair. *Nature*, v. 513, n. 7516, p. 120-123, 2014. DOI: <https://doi.org/10.1038/nature13695>.

FINDLAY, G. M. et al. Accurate classification of BRCA1 variants with saturation genome editing. *Nature*, v. 562, n. 7726, p. 217-222, 2018. DOI: <https://doi.org/10.1038/s41586-018-0461-z>.

FRAZER, J. et al. Disease variant prediction with deep generative models of evolutionary data. *Nature*, v. 599, n. 7883, p. 91-95, 2021. DOI: <https://doi.org/10.1038/s41586-021-04043-8>.

HART, S. N. et al. Prediction of the functional impact of missense variants in BRCA1 and BRCA2 with BRCA-ML. *NPJ Breast Cancer*, v. 6, art. 13, 2020. DOI: <https://doi.org/10.1038/s41523-020-0159-x>.

HU, C. et al. Classification of BRCA2 variants of uncertain significance (VUS) using an ACMG/AMP model incorporating a homology-directed repair (HDR) functional assay. *Clinical Cancer Research*, v. 28, n. 17, p. 3742-3751, 2022. DOI: <https://doi.org/10.1158/1078-0432.CCR-22-0203>.

HU, C. et al. Functional analysis and clinical classification of 462 germline BRCA2 missense variants affecting the DNA binding domain. *American Journal of Human Genetics*, v. 111, n. 3, p. 584-593, 2024. DOI: <https://doi.org/10.1016/j.ajhg.2024.02.002>.

IOANNIDIS, N. M. et al. REVEL: an ensemble method for predicting the pathogenicity of rare missense variants. *American Journal of Human Genetics*, v. 99, n. 4, p. 877-885, 2016. DOI: <https://doi.org/10.1016/j.ajhg.2016.08.016>.

KARCZEWSKI, K. J. et al. The mutational constraint spectrum quantified from variation in 141,456 humans. *Nature*, v. 581, n. 7809, p. 434-443, 2020. DOI: <https://doi.org/10.1038/s41586-020-2308-7>.

KERNBACH, J. M.; STAARTJES, V. E. Foundations of machine learning-based clinical prediction modeling: Part II—generalization and overfitting. *Acta*

Neurochirurgica Supplement, v. 134, p. 15-21, 2022. DOI:

https://doi.org/10.1007/978-3-030-85292-4_3.

LASTA, J. L.; GROTO, A. D.; BRANDALIZE, A. P. C. Assessment of medical knowledge toward genetic testing for individuals with hereditary breast and ovarian cancer syndrome in Brazil. *Preventive Medicine Reports*, v. 35, art. 102356, 2023.

DOI: <https://doi.org/10.1016/j.pmedr.2023.102356>.

LIN, Z. et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, v. 379, n. 6637, p. 1123-1130, 2023. DOI:

<https://doi.org/10.1126/science.ade2574>.

MANRAI, A. K. et al. Genetic misdiagnoses and the potential for health disparities.

New England Journal of Medicine, v. 375, n. 7, p. 655-665, 2016. DOI:

<https://doi.org/10.1056/NEJMsa1507092>.

MEIER, J. et al. Language models enable zero-shot prediction of the effects of mutations on protein function. *Advances in Neural Information Processing Systems*, v. 34, p. 29287-29303, 2021.

NORONHA, M. M. et al. Beyond 1100delC: distinct CHEK2 variants and unique cancer phenotypes in Northeast Brazil. *Familial Cancer*, v. 25, n. 1, art. 8, 2026. DOI:

<https://doi.org/10.1007/s10689-025-00526-z>.

PALMERO, E. I. et al. Clinical characterization and risk profile of individuals seeking genetic counseling for hereditary breast cancer in Brazil. *Journal of Genetic Counseling*, v. 16, n. 3, p. 363-371, 2007. DOI:

<https://doi.org/10.1007/s10897-006-9073-0>.

PARSONS, M. T. et al. Large scale multifactorial likelihood quantitative analysis of BRCA1 and BRCA2 variants: an ENIGMA resource to support clinical variant classification. *Human Mutation*, v. 40, n. 9, p. 1557-1578, 2019. DOI:

<https://doi.org/10.1002/humu.23818>.

PEJAVER, V. et al. Calibration of computational tools for missense variant pathogenicity classification and ClinGen recommendations for PP3/BP4 criteria.

American Journal of Human Genetics, v. 109, n. 12, p. 2163-2177, 2022. DOI: <https://doi.org/10.1016/j.ajhg.2022.10.013>.

POPEJOY, A. B.; FULLERTON, S. M. Genomics is failing on diversity. *Nature*, v. 538, n. 7624, p. 161-164, 2016. DOI: <https://doi.org/10.1038/538161a>.

RAMADANE-MORCHADI, L. et al. ACMG/AMP interpretation of BRCA1 missense variants: structure-informed scores add evidence strength granularity to the PP3/BP4 computational evidence. *American Journal of Human Genetics*, v. 112, n. 5, p. 993-1002, 2025. DOI: <https://doi.org/10.1016/j.ajhg.2024.12.011>.

RENTZSCH, P. et al. CADD: predicting the deleteriousness of variants throughout the human genome. *Nucleic Acids Research*, v. 47, n. D1, p. D886-D894, 2019. DOI: <https://doi.org/10.1093/nar/gky1016>.

RIBEIRO, A. A. F. et al. Molecular characterization of hereditary breast and ovarian cancer patients from a public precision medicine service in the Southeast Brazilian population. *Scientific Reports*, v. 15, n. 1, art. 33495, 2025. DOI: <https://doi.org/10.1038/s41598-025-16870-0>.

RICHARDS, S. et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of Medical Genetics and Genomics and the Association for Molecular Pathology. *Genetics in Medicine*, v. 17, n. 5, p. 405-424, 2015. DOI: <https://doi.org/10.1038/gim.2015.30>.

SOEWITO, S. et al. Disparities in cancer genetic testing and variants of uncertain significance in the Hispanic population of South Texas. *JCO Oncology Practice*, v. 18, n. 5, p. e805-e813, 2022. DOI: <https://doi.org/10.1200/OP.22.00090>.

STARITA, L. M. et al. Massively parallel functional analysis of BRCA1 RING domain variants. *Genetics*, v. 200, n. 2, p. 413-422, 2015. DOI: <https://doi.org/10.1534/genetics.115.175802>.

TOLAND, A. E.; ANDREASSEN, P. R. DNA repair-related functional assays for the classification of BRCA1 and BRCA2 variants: a critical review and needs assessment. *Journal of Medical Genetics*, v. 54, n. 11, p. 721-731, 2017. DOI: <https://doi.org/10.1136/jmedgenet-2017-104707>.

TORRETTO, G. C. et al. Domain-specific computational, functional and structural methods enable interpretation of BRCA1 BRCT variants of uncertain significance. *Current Oncology*, v. 33, n. 6, art. 354, 2026. DOI: <https://doi.org/10.3390/curroncol33060354>.

THE UNIPROT CONSORTIUM. UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Research*, v. 51, n. D1, p. D523-D531, 2023. DOI: <https://doi.org/10.1093/nar/gkac1052>.

YANG, H. et al. BRCA2 function in DNA binding and recombination from a BRCA2-DSS1-ssDNA structure. *Science*, v. 297, n. 5588, p. 1837-1848, 2002. DOI: <https://doi.org/10.1126/science.297.5588.1837>.

ZHANG, X. et al. Genetic constraint at single amino acid resolution in protein domains improves missense variant prioritisation and gene discovery. *Genome Medicine*, v. 16, n. 1, art. 88, 2024. DOI: <https://doi.org/10.1186/s13073-024-01358-9>.