

PrimeVarClass: da hipótese dos números primos a um classificador de variantes BRCA1/BRCA2 consciente de domínio e validade externamente

32º Prêmio Jovem Cientista (2026) — Categoria: Estudante do Ensino Superior.

Tema: *Inteligência Artificial para o Bem Comum* — Subtema: **Inteligência Artificial & Saúde** (item 1.4.1.b do Edital).

Autor: Wesley Felipe Capucho — graduando em Engenharia Bioquímica

Orientador(a): <nome do(a) orientador(a) — a preencher>

Instituição de vínculo: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP) — Estrada Municipal do Campinho, s/nº, Ponte Nova, Lorena – SP, CEP 12602-810.

Telefone: <a preencher>. E-mail: wesleycapucho@usp.br

Instituição onde a pesquisa foi desenvolvida: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP), Lorena – SP, Brasil.

Formatação: A4, fonte Arial, corpo 12, espaçamento 1,5, em Língua Portuguesa (item 2.2.2 do Edital). Campos restantes entre <...> (nome do orientador e telefone institucional) a preencher antes da submissão.

Resumo

A interpretação de variantes de significado incerto (VUS) em genes de predisposição ao câncer de mama e ovário, como *BRCA1* e *BRCA2*, é um gargalo clínico e de pesquisa: milhares de mutações *missense* permanecem sem classificação, o que limita o aconselhamento genético e o acesso equitativo à medicina de precisão no Brasil. Este trabalho apresenta o **PrimeVarClass**, um sistema de inteligência artificial explicável para priorização dessas variantes, desenvolvido sob um princípio central: **rigor metodológico e honestidade científica como fonte de valor**. Partimos de uma hipótese original — codificar aminoácidos como números primos para capturar padrões de patogenicidade — e a submetemos a um teste controlado com dados reais do ClinVar, painéis de especialistas e gnomAD, sob o mesmo protocolo rigoroso usado em todo o trabalho (validação cruzada bloqueada por posição e generalização em coortes externas). A hipótese foi **refutada de forma transparente**: mesmo nesse regime rigoroso, características derivadas de primos tiveram desempenho inferior ao de uma identidade trivial de aminoácidos sem posição (AUC externa 0,681 vs. 0,718; DeLong $p = 0,045$) e *reduziram* o desempenho ao serem adicionadas a um modelo bioquímico (AUC externa 0,791 $\rightarrow$ 0,765; DeLong $p < 0,0001$). No processo, diagnosticamos uma **armadilha de vazamento posicional**: a posição bruta do resíduo, quando avaliada sob

validação ingênua (sem bloqueio), memoriza os dados de treino (AUC de ~0,885) mas essa memorização não se sustenta sob validação rigorosa nem em coortes externas. A partir desse diagnóstico, construímos um classificador **consciente de domínio funcional**, que substitui a posição bruta por características de *região* anotadas a partir do UniProt (domínios RING/BRCT de BRCA1 e o domínio de ligação ao DNA de BRCA2). Esse modelo **generaliza para coortes externas independentes** com AUC de **0,847**, superando o modelo que usa posição bruta (0,791; DeLong $p = 1,8 \times 10^{-13}$) — evidência de que capturamos biologia transferível, não memorização. Ao combiná-lo com um modelo de linguagem de proteínas (**ESM-2**), avaliado sob o mesmo protocolo, o modelo-carro-chefe (domínio + ESM-2) atinge **AUC externa de 0,909** (DeLong $p = 1,5 \times 10^{-10}$), e sua explicabilidade é demonstrada por valores de Shapley. O sistema é entregue como plataforma aberta, reproduzível e auditável. A contribuição principal não é uma alegação inflada de desempenho, mas um **método honesto, auditável e generalizável** para apoiar a pesquisa genética responsável no país.

Palavras-chave: classificação de variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

1. Introdução

1.1 O problema clínico e social

Mutações germinativas em *BRCA1* e *BRCA2* aumentam substancialmente o risco de câncer de mama e de ovário. A identificação de portadores permite estratégias de redução de risco, rastreamento intensificado e decisões terapêuticas informadas. Contudo, uma fração expressiva das variantes encontradas em testes genéticos é classificada como **variante de significado incerto (VUS)** — não se sabe se são patogênicas ou benignas. Para o paciente e a família, uma VUS significa ansiedade e ausência de conduta clínica clara; para o sistema de saúde, significa exames que não se convertem em decisão.

A base biológica desse problema reside na função de BRCA1 e BRCA2 na manutenção da integridade do genoma. Ambas são essenciais ao reparo de quebras de dupla fita do DNA pela via de **recombinação homóloga (RH)**, de alta fidelidade: BRCA2 controla o carregamento da recombinase RAD51 sobre o DNA de fita simples, enquanto BRCA1, em complexo com BARD1, atua na sinalização e no processamento do dano. Quando uma variante germinativa compromete essa função, a RH torna-se deficiente e a célula recorre a mecanismos de reparo propensos a erro, acumulando mutações e instabilidade genômica — o substrato da transformação maligna. Clinicamente, isso se traduz em risco elevado e precoce de câncer de mama e de ovário, com penetrância

cumulativa que pode ultrapassar 70% ao longo da vida, e fundamenta tanto estratégias de redução de risco quanto terapias-alvo (inibidores de PARP). A Figura 1 sintetiza esse mecanismo.




Figura 1. Mecanismo biológico que conecta as proteínas BRCA1/BRCA2 ao câncer hereditário de mama e ovário (HBOC). À esquerda (verde), em uma célula com BRCA1/BRCA2 funcionais, uma quebra de dupla fita no DNA é reparada com fidelidade pela via de recombinação homóloga (RH) — na qual essas proteínas recrutam a recombinase RAD51 —, mantendo a estabilidade genômica e protegendo contra o câncer. À direita (vermelho), uma variante patogênica germinativa (por exemplo, Cys61Gly no domínio RING ou Met1775Arg no domínio BRCT do BRCA1) compromete um domínio funcional crítico, tornando a RH deficiente; o DNA passa a ser reparado por vias propensas a erro, com acúmulo de mutações, instabilidade genômica e, por fim, tumorigênese. A penetrância é elevada (risco cumulativo de câncer de mama de ~45–72% e de ovário de ~11–44% ao longo da vida em portadoras de BRCA1/BRCA2) e a deficiência de RH é explorada terapeuticamente por inibidores de PARP (letalidade sintética). Este é o contexto clínico que torna crítica a classificação precisa das variantes.

No Brasil, esse problema é agravado por desigualdade de acesso: a interpretação de variantes depende de expertise concentrada em poucos centros, e laboratórios públicos e universitários frequentemente carecem de ferramentas abertas, auditáveis e adaptadas à realidade nacional. Uma inteligência artificial que **acelere e organize** a interpretação de variantes — sem substituir o julgamento humano — tem potencial de impacto direto na formação de pesquisadores e no apoio à medicina de precisão pública.

1.2 A lacuna metodológica

Preditores computacionais de patogenicidade existem (REVEL, CADD, AlphaMissense, entre outros), mas muitos benchmarks sofrem de dois problemas recorrentes: **(i) vazamento de dados**, quando o modelo aprende atalhos que não se sustentam fora do conjunto de treino, e **(ii) falta de validação externa independente**, superestimando o desempenho real. Um sistema competitivo e cientificamente sólido precisa demonstrar

não o melhor número em um teste interno, mas **generalização honesta** para dados nunca vistos.

1.3 Estado da arte: preditores de patogenicidade e o problema do vazamento

O campo da predição computacional de patogenicidade evoluiu de escores de conservação isolados para *meta-preditores* e modelos de aprendizado profundo. Métodos de conjunto como o **REVEL** (Ioannidis et al., 2016) e escores integrativos como o **CADD** (Rentzsch et al., 2019) combinam dezenas de anotações; avaliações independentes indicam que REVEL e BayesDel frequentemente superam preditores individuais na classificação clínica (Tian et al., 2019). Mais recentemente, o **AlphaMissense** (Cheng et al., 2023) estendeu a predição a todo o proteoma humano com desempenho de referência. Especificamente para *BRCA1/BRCA2*, o **BRCA-ML** (Hart et al., 2020) e abordagens de aprendizado de máquina para reclassificação de VUS (RENOVO; Favalli et al., 2021) demonstraram utilidade, e recursos como a análise multifatorial da ENIGMA (Parsons et al., 2019) fornecem rótulos quantitativos de alta confiança. Ensaios funcionais de alto rendimento — *saturation genome editing* (Findlay et al., 2014) e ensaios de reparo por recombinação homóloga (Toland; Andreassen, 2017) — vêm reduzindo a incerteza sobre variantes específicas.

Dois desafios, porém, atravessam a literatura. O primeiro é a **calibração**: o ClinGen (Pejaver et al., 2022) mostrou que os escores brutos dos preditores precisam ser calibrados para serem usados como evidência na estrutura ACMG/AMP (Richards et al., 2015). O segundo, menos discutido mas crítico, é o **vazamento de dados** e a **superestimação por validação inadequada**, um problema reconhecido na modelagem preditiva clínica em geral (Kernbach; Staartjes, 2022). Modelos avaliados sem separação rigorosa entre treino e teste — por posição, por gene ou por família — reportam desempenhos que não se sustentam externamente. A observação de "coldspots" sistematicamente mal classificados em *BRCA1/BRCA2* (Dines et al., 2020) e evidências recentes de que a **restrição evolutiva em resolução de domínio** melhora a priorização (Zhang et al., 2024; Torretto et al., 2026) motivam diretamente a abordagem consciente de domínio deste trabalho. É nesse ponto — rigor de validação e sinal de origem biológica explícita — que buscamos contribuir.

1.4 A jornada científica deste trabalho

Este projeto nasceu de uma hipótese original e arrojada: e se a estrutura dos **números primos** — objetos matemáticos com propriedades de distribuição não triviais — pudesse codificar aminoácidos de forma a revelar padrões de patogenicidade? A ideia dá nome ao sistema (*PrimeVarClass*). Em vez de tratá-la como verdade a ser

defendida, nós a tratamos como **hipótese a ser testada**. Este manuscrito relata honestamente esse teste, seu **resultado negativo**, o **diagnóstico** que ele possibilitou, e a **solução generalizável** que dele emergiu. Sustentamos que essa trajetória — hipótese ousada, teste rigoroso, refutação transparente e modelo validado — é, em si, a contribuição científica mais valiosa e mais alinhada ao espírito da ciência.

1.5 Objetivos

1. Testar de forma controlada se a codificação por números primos melhora a classificação de variantes *missense* em *BRCA1/BRCA2*.
2. Investigar e quantificar o efeito de vazamento posicional em benchmarks internos.
3. Desenvolver e **validar externamente** um classificador consciente de domínio funcional que generalize para coortes independentes.
4. Entregar o sistema de forma reprodutível, explicável e eticamente responsável, com aplicação concreta ao contexto brasileiro de saúde e pesquisa.

2. Materiais e Métodos

2.1 Fontes de dados (reais e públicas)

Utilizamos exclusivamente dados públicos e auditáveis de variantes *missense* de *BRCA1* (UniProt P38398) e *BRCA2* (UniProt P51587), conforme a base de dados UniProt (UniProt Consortium, 2023):

- **ClinVar** — classificações clínicas, com subconjunto de alta confiança revisado por painel de especialistas (ENIGMA/ClinGen).
- **gnomAD** — frequências alélicas populacionais (Karczewski et al., 2020).
- **Coortes externas independentes** — variantes classificadas por especialistas de *BRCA1* e *BRCA2*, mantidas estritamente separadas do conjunto de treino para validação de generalização.

Rótulos foram normalizados em patogênico (1) vs benigno (0); classificações conflitantes ou de baixa confiança foram excluídas. Conjunto de treino: **n = 869**; conjunto externo: **n = 836**.

2.2 Representações de variante (características)

Cada substituição de aminoácido foi representada por famílias de características:

- **Bioquímicas**: variações de massa, hidrofobicidade, carga, polaridade, aromaticidade, mudança de classe química e escore de severidade bioquímica.
- **Hipótese dos primos**: aminoácidos mapeados a números primos, com derivações (razões, diferenças, densidade local, lacunas entre primos, resíduos módulo, etc.).

- **Identidade:** codificação categórica direta (gene, aminoácido de referência, aminoácido alternativo).
- **Domínio funcional** (proposta deste trabalho): rótulo categórico do domínio UniProt e indicador binário de domínio crítico (ver 2.4).
- **Preditores externos** (apenas como referência): quando disponíveis.

2.3 O teste da hipótese dos primos

Para avaliar a hipótese de forma justa, comparamos, sob **o mesmo classificador e o mesmo protocolo de validação**, conjuntos de características isolados: apenas-primos, apenas-bioquímico, apenas-identidade, e combinações (híbrido). A pergunta central foi operacionalizada em comparações pareadas: *os primos superam a identidade simples? e adicionar primos a um modelo bioquímico ajuda?*

2.4 Anotação de domínio funcional (UniProt)

Mapeamos cada posição de resíduo aos domínios funcionais curados das proteínas:

- **BRCA1 (P38398):** domínio RING (1–109; ligação a BARD1, E3-ligase) e as repetições BRCT (1642–1736 e 1756–1855) como regiões **críticas**; domínios SCD e *coiled-coil* de ligação a PALB2 como não críticos.
- **BRCA2 (P51587):** domínio de ligação ao DNA (DBD: helicoidal 2481–2667 e três folhas OB até 3186) como região **crítica**; repetições BRC de ligação a RAD51 e demais regiões como não críticas.

Definimos duas características: `functional_domain` (categórica) e `in_critical_domain` (binária). O ponto essencial é que essas características são funções de **região**, não do índice único do resíduo — portanto codificam biologia transferível em vez de memorizar quais posições exatas foram patogênicas no treino.

As proteínas-alvo e seus domínios funcionais são apresentados na Figura 2, a partir de estruturas experimentais reais depositadas no Protein Data Bank (PDB).




Figura 2. Estruturas tridimensionais experimentais das proteínas-alvo, em representação de cartoon (coordenadas reais do Protein Data Bank, renderizadas com PyMOL open-source). **BRCA1 — domínio RING** (PDB 1JM7): heterodímero BRCA1 (verde) / BARD1 (ciano); os íons de zinco (esferas roxas) são coordenados por cisteínas (bastões vermelhos) que formam o núcleo estrutural do domínio — região onde se concentram variantes patogênicas de perda de função (por exemplo, Cys61 e Cys64). **BRCA1 —**

repetições BRCT (PDB 1JNX): domínio crítico C-terminal de reconhecimento de fosfopeptídeos (coloração do N-terminal, azul, ao C-terminal, vermelho). **BRCA2 — domínio de ligação ao DNA (PDB 1MJE): BRCA2 (verde) em complexo com DSS1 (ciano) e ssDNA (laranja), conforme Yang et al. (2002).** As três regiões em destaque são os domínios funcionais críticos usados pelo modelo consciente de domínio.

A importância dessas regiões torna-se evidente ao observar o efeito estrutural de variantes patogênicas conhecidas (Figura 3). No domínio RING, cisteínas como Cys61 e Cys64 coordenam um íon de zinco estrutural; substituições como p.Cys61Gly e p.Cys64Gly removem esses ligantes, colapsam o domínio e abolem a atividade de E3-ligase e a interação com BARD1. No domínio BRCT, a variante p.Met1775Arg desestabiliza a interface entre as duas repetições e prejudica o reconhecimento de fosfopeptídeos. Ou seja, as mutações patogênicas danificam precisamente as regiões que o modelo consciente de domínio identifica como críticas — a base biológica que sustenta a abordagem.




Figura 3. Consequência estrutural, em três dimensões, de duas variantes patogênicas de BRCA1 que o classificador-carro-chefe pontua como deletérias — renderizadas a partir de coordenadas experimentais reais do Protein Data Bank (PyMOL open-source; sem átomos modelados ou fabricados). **(A) p.Cys61Gly — domínio RING (PDB 1JM7).** A cadeia lateral nativa da Cys61 (bastões verdes; enxofre em amarelo) coordena, pelo grupo tiol, um íon de zinco estrutural (esfera azul; ligação de coordenação tracejada), auxiliada por cisteínas vizinhas (laranja). A substituição por glicina remove o tiol coordenante: o zinco é liberado, o dobramento do RING colapsa e a atividade de E3-ubiquitina-ligase do heterodímero BRCA1–BARD1 é abolida. **(B) p.Met1775Arg — domínio BRCT.** Sobreposição estrutural verdadeira do BRCT nativo (PDB 1JNX; Met1775 em verde) e do mutante determinado experimentalmente (PDB 1N50; Arg1775 em vermelho, nitrogênios em azul), no núcleo hidrofóbico da interface entre as duas repetições (resíduos vizinhos em cinza). A metionina nativa, compacta e apolar, é substituída por uma arginina longa e positivamente carregada que não se acomoda no núcleo do domínio, desestabilizando o dobramento e comprometendo o reconhecimento de fosfopeptídeos (parceiros como BACH1/BRIP1 e CtIP). Os escores de razão de verossimilhança logarítmica do ESM-2 (LLR; Seção 2.9) — -10,9 e -12,0, respectivamente — confirmam, de forma independente e sem rótulos, o forte sinal patogênico dessas variantes. Em ambos os casos, a mutação danifica exatamente a região funcional crítica que o modelo consciente de domínio identifica.

2.5 Protocolo de validação anti-vazamento

Adotamos dois níveis de avaliação:

- **(A) Validação cruzada bloqueada por posição** (StratifiedGroupKFold, 5 *folds*), em que todas as variantes de uma mesma posição ficam no mesmo *fold*. Isso impede que o modelo "veja" a mesma posição no treino e no teste, neutralizando o vazamento posicional.
- **(B) Generalização externa**: treino no conjunto interno completo e teste em coortes externas independentes de especialistas.

Comparações de AUC entre modelos foram feitas com o **teste pareado de DeLong** (DeLong; DeLong; Clarke-Pearson, 1988). A métrica primária foi a AUC-ROC.

2.6 Modelo e implementação

Classificador *Random Forest* balanceado, com codificação apropriada por tipo de característica, em *pipeline* reproduzível (semente fixa). O sistema é implementado em Python, com testes automatizados (cobertura das características de domínio e de ingestão de escores), e disponibilizado como pacote auditável. A anotação de domínio é um módulo independente e citável (`domain_annotation.py`), e a ingestão de escores de aprendizado profundo (ESM-2) é desacoplada do treino (`esm_scores.py`), sem dependência obrigatória de GPU.

2.7 Análise de robustez (Monte Carlo)

Para além da comparação pontual de AUCs, quantificamos a incerteza e a estabilidade dos resultados por quatro procedimentos, todos executados sobre os dados reais:

- **Bootstrap não paramétrico** (B = 2000 reamostragens das coortes externas) para intervalos de confiança de 95% da AUC de cada modelo e das diferenças pareadas de AUC.
- **Teste de permutação** (N = 2000): os rótulos externos são permutados aleatoriamente para construir a distribuição da AUC sob a hipótese nula de ausência de sinal, gerando um valor-p empírico.
- **Validação cruzada repetida**: a validação bloqueada por posição é reexecutada com 12 sementes independentes, reportando média e desvio-padrão da AUC.
- **Calibração**: escore de Brier e curva de confiabilidade (probabilidade prevista versus frequência observada) nas coortes externas.

2.8 Meta-análise de generalização

Tratamos as quatro coortes externas como estudos independentes e agrupamos suas AUCs por um modelo de **efeitos aleatórios** (estimador de heterogeneidade

DerSimonian-Laird), operando sobre a AUC transformada em escala logit (com erro-padrão obtido por bootstrap e propagado pelo método delta). Reportamos a AUC agrupada, seu IC95%, a estatística Q de Cochran e o índice I² de heterogeneidade. Trata-se de uma meta-análise dos nossos próprios resultados multi-coorte; não incorporamos valores de desempenho extraídos de resumos de terceiros, evitando comparações não verificáveis.

2.9 Escore de aprendizado profundo (ESM-2) e explicabilidade (SHAP)

Cada variante foi pontuada com o modelo de linguagem de proteínas **ESM-2** (facebook/esm2_t33_650M_UR50D, 650 milhões de parâmetros; Lin et al., 2023) por razão de verossimilhança logarítmica (LLR) *masked-marginal*: para uma posição p , mascaramos o resíduo e computamos $\log P(\text{alt} \mid \text{contexto}) - \log P(\text{ref} \mid \text{contexto})$. Como BRCA1 (1.863 aa) e BRCA2 (3.418 aa) excedem o contexto do modelo, cada posição é avaliada em uma **janela** de ± 511 resíduos. Os escores são ingeridos pelo módulo reprodutível `esm_scores.py` e expostos como a característica `esm2_llr` do conjunto *domínio* + *ESM-2*. A robustez foi verificada reexecutando toda a pontuação com uma variante menor do ESM-2 (150M), obtendo LLRs fortemente correlacionados (Pearson 0,87) e conclusões idênticas. A **explicabilidade** do modelo foi quantificada por **valores de Shapley** (SHAP; estimador *TreeExplainer*) sobre a floresta aleatória treinada na coorte interna.

3. Resultados

3.1 A hipótese dos números primos foi refutada

Testamos a hipótese sob o mesmo protocolo anti-vazamento descrito na Seção 2.5 — validação cruzada bloqueada por posição e generalização em coortes externas independentes —, com o mesmo classificador para todos os conjuntos de características (Tabela 1). Sob esse protocolo, as características derivadas de primos tiveram desempenho **inferior** ao de uma codificação de identidade trivial, e **pioraram** um modelo bioquímico ao serem adicionadas.

Tabela 1. Desempenho por conjunto de características na refutação da hipótese dos primos, sob o protocolo anti-vazamento (mesmo classificador e mesma amostra de treino, $n = 869$; ver Seção 2.5).

Conjunto de características	nº de features	CV bloqueada por posição	Coortes externas
Identidade (gene + aa_ref + aa_alt + posição) ^a	4	0,871	0,882
Bioquímico (inclui gene e posição) ^a	28	0,802	0,791
Híbrido (bioquímico +	76	0,783	0,765

primos) ^a			
Identidade (gene + aa_ref + aa_alt, sem posição)	3	0,745	0,718
Apenas primos	50	0,717	0,681

^a Por definição do pipeline de características, estes três conjuntos incluem o gene e a posição bruta do resíduo. O risco de memorização associado à posição é diagnosticado na Seção 3.2 e removido explicitamente no modelo proposto (Tabela 3).

Tabela 2. Comparações pareadas pelo teste de DeLong (DeLong; DeLong; Clarke-Pearson, 1988), sob o mesmo protocolo anti-vazamento (Tabela 1).

Comparação	Protocolo	AUC A	AUC B	Δ	p
Apenas-primos vs identidade (sem posição)	CV bloqueada por posição	0,717	0,745	-0,028	0,081
Apenas-primos vs identidade (sem posição)	Coortes externas	0,681	0,718	-0,038	0,045
Híbrido vs apenas-bioquímico ^b	Coortes externas	0,765	0,791	-0,026	< 0,0001

^b Ambos os conjuntos incluem igualmente gene e posição (nota da Tabela 1); a comparação isola o efeito marginal de adicionar as características derivadas de primos. Mesmo sob o protocolo mais rigoroso, os primos não superam a identidade trivial: a diferença é uma tendência não significativa na validação cruzada interna ($p = 0,081$), mas torna-se estatisticamente significativa no teste mais decisivo — a generalização externa ($p = 0,045$). E quando adicionados a um modelo bioquímico já estabelecido, os primos **pioram** o desempenho de forma inequívoca nas coortes externas ($p < 0,0001$). A conclusão é honesta e reproduzível: **os números primos não agregam sinal preditivo útil** para esta tarefa; onde parecem contribuir, é por sobreposição com sinal já capturado por outras características, e sua adição introduz ruído que reduz o desempenho de generalização.

3.2 Diagnóstico: a armadilha do vazamento posicional

O motivo de adotarmos o protocolo anti-vazamento fica evidente ao isolar o papel da posição bruta do resíduo. Sob validação cruzada **ingênua** (sem bloqueio por grupo, ainda comum na literatura), a posição usada **isoladamente** como única característica atinge AUC de ~0,885, e o gene isolado, ~0,640 — valores artificialmente altos, pois muitas variantes de uma mesma posição compartilham rótulo e aparecem simultaneamente no treino e no teste, levando o modelo a "decorar" posições em vez de aprender biologia. Esse padrão de memorização é exatamente o que infla os

conjuntos que incluem a posição bruta na Tabela 1 (Identidade e Bioquímico), motivando o protocolo de bloqueio por posição adotado em todo este trabalho. Este é o alerta metodológico central: **benchmarks internos que não bloqueiam a posição superestimam sistematicamente o desempenho real.**

3.3 A solução: modelo consciente de domínio, validado externamente

Substituindo a posição bruta por características de **região funcional**, obtivemos um modelo que não só resiste ao bloqueio por posição como **generaliza melhor** para coortes externas independentes, como resume a Tabela 3.

Tabela 3. Consciência de domínio: validação bloqueada por posição e generalização externa (AUC-ROC).

Modelo	CV bloqueada por posição	Coortes externas
Bioquímico (sem posição)	0,743	0,717
Bioquímico + domínio (proposto)	0,818	0,847
Bioquímico + posição bruta (referência de vazamento)	0,802	0,791

DeLong (domínio vs bioquímico): $p = 3,2 \times 10^{-9}$ (interno) e $p = 1,8 \times 10^{-13}$ (externo). Decisivamente, o modelo de domínio (0,847) **supera** o de posição bruta (0,791) *justamente nas coortes externas* — ou seja, o sinal de região **transfere-se** para dados novos, enquanto a posição **memoriza** e falha ao generalizar. Este é o resultado central do trabalho.

As Figuras 4 e 5 ilustram a base biológica desse resultado. A Figura 4 mapeia as variantes observadas sobre a arquitetura de domínios de BRCA1 e BRCA2: as variantes patogênicas (riscos vermelhos, inferiores) concentram-se visivelmente nas regiões críticas — RING e repetições BRCT em BRCA1; domínio de ligação ao DNA em BRCA2 —, enquanto as benignas (superiores) espalham-se pelas regiões ligantes. A Figura 5 quantifica o padrão: a fração de variantes patogênicas é de **44,5%** ($n = 373$) dentro de domínios críticos, contra **6,8%** ($n = 146$) em domínios não críticos e **10,0%** ($n = 350$) em regiões ligantes.

Teste de permutação (N = 2000). Permutando os rótulos externos para construir a distribuição sob a hipótese nula, a AUC nula tem média 0,501; a AUC observada (0,847) situa-se muito além dela, com $p = 5 \times 10^{-4}$ (o mínimo detectável com N = 2000). O desempenho não é atribuível ao acaso (Figura 7).

Estabilidade entre sementes. Repetindo a validação cruzada bloqueada por posição em **12 sementes independentes**, a AUC média é **0,828 ± 0,005** (domínio), 0,818 ± 0,006 (posição bruta) e 0,763 ± 0,005 (bioquímico): o modelo de domínio é consistentemente superior, com variabilidade mínima (Figura 8).

Calibração. O escore de Brier do modelo consciente de domínio nas coortes externas é **0,108**, e a curva de confiabilidade acompanha a diagonal (Figura 9), indicando probabilidades bem calibradas — propriedade importante para uso como apoio à decisão, e não apenas ordenação. A Figura 10 complementa essa análise com as curvas ROC completas dos três modelos nas coortes externas, visualizando a mesma separação de desempenho já quantificada na Tabela 3.




Figura 6. Distribuição bootstrap (B = 2000) da AUC nas coortes externas para os três modelos. A separação entre o modelo de domínio (verde) e o bioquímico (cinza) é completa.




Figura 7. Teste de permutação ($N = 2000$). A AUC observada (linha verde) está muito além da distribuição sob rótulos permutados ($p = 5 \times 10^{-4}$).




Figura 8. Estabilidade da AUC em 12 sementes de validação cruzada bloqueada por posição.




Figura 9. Curva de calibração (confiabilidade) e escore de Brier do modelo consciente de domínio nas coortes externas.




Figura 10. Curvas ROC nas coortes externas para os três modelos comparados.

3.5 Meta-análise de generalização entre coortes independentes

Para quantificar a robustez de forma conservadora, tratamos cada uma das quatro coortes externas como um "estudo" independente e agrupamos suas AUCs por um modelo de **efeitos aleatórios** (estimador DerSimonian-Laird sobre a AUC em escala logit; incerteza por bootstrap). O resultado (Figura 11, Tabela 4) é honesto e informativo.

Tabela 4. Meta-análise da AUC externa por coorte (modelo consciente de domínio).

Coorte	n	AUC	IC95%
BRCA1 — painel especialista	204	0,888	0,840–0,929
BRCA2 — painel especialista	175	0,864	0,791–0,925
BRCA2 — coorte externa	289	0,772	0,617–0,910
BRCA1 — coorte externa	168	0,599	0,476–0,728
Agrupado (efeitos aleatórios)	836	0,801	0,638–0,902

A AUC agrupada é **0,801** (IC95% 0,638–0,902), com **alta heterogeneidade** ($I^2 = 88,2\%$; $Q = 25,5$; $p < 0,001$). O modelo é **excelente nas coortes de painel especialista** (0,864–0,888), precisamente onde os rótulos têm máxima confiança, e mais fraco em uma coorte externa de BRCA1 (0,599). Reportamos essa heterogeneidade de forma explícita: ela mostra que o desempenho depende da qualidade e composição da coorte,

e que a generalização, embora forte no conjunto agregado e nas coortes de especialista, **não é uniforme**. Discutimos as implicações em §4.1.




Figura 11. Forest plot da meta-análise de generalização externa. Quadrados = AUC por coorte (com IC95%); losango = estimativa agrupada por efeitos aleatórios.

3.6 Aprendizado profundo autêntico: o modelo-carro-chefe domínio + ESM-2

Como camada ortogonal e cientificamente legítima, integramos o **ESM-2** (Lin et al., 2023; Meier et al., 2021) — um modelo de linguagem de proteínas treinado de forma não supervisionada em dezenas de milhões de sequências, **sem qualquer rótulo de patogenicidade**. Cada substituição recebe um escore *zero-shot* pela razão de verossimilhança logarítmica (LLR) *masked-marginal* (Seção 2.9). Por derivar apenas da "gramática" evolutiva das sequências, o ESM-2 **não introduz circularidade** com preditores existentes nem vaza rótulos. Pontuamos as 1.680 variantes com o ESM-2 (650M) com **100% de cobertura**; o sinal é biologicamente coerente (por exemplo, a variante p.Cys61Gly, no núcleo de coordenação de zinco do RING, recebe LLR = -10,9).

Avaliado sob o mesmo protocolo anti-vazamento (Tabela 5), o ESM-2 revela-se um sinal poderoso, e sua combinação com a consciência de domínio constitui o **modelo-carro-chefe** do sistema: a AUC externa sobe de 0,847 (domínio) para **0,909** (domínio + ESM-2), uma melhora altamente significativa (DeLong $p = 1,5 \times 10^{-10}$). Os dois sinais são **complementares** — na validação bloqueada por posição, a combinação (0,882) supera tanto o domínio isolado (0,818) quanto o ESM-2 isolado (0,867).

Tabela 5. Modelo-carro-chefe (domínio + ESM-2) sob o protocolo anti-vazamento (AUC-ROC).

Modelo	CV bloqueada por posição	Coortes externas
Consciente de domínio	0,818	0,847
ESM-2 (650M) sozinho	0,867	0,907
Domínio + ESM-2 (carro-chefe)	0,882	0,909

A explicabilidade desse modelo é **demonstrada, não apenas afirmada**, por valores de Shapley (SHAP; Figura 12): as características de maior impacto são exatamente os dois pilares do método — o escore ESM-2 (`esm2_llr`) e a pertinência a domínio crítico (`in_critical_domain`) —, seguidas por severidade bioquímica e identidade do gene, com direção de efeito biologicamente correta.




Figura 12. Explicabilidade por valores de Shapley (SHAP) do modelo domínio + ESM-2 na coorte interna. Cada ponto é uma variante; a posição horizontal é a contribuição (valor SHAP) da característica para a predição de patogenicidade, e a cor codifica o valor da característica (azul = baixo, vermelho = alto). O escore ESM-2 (`esm2_LLr`) é o preditor dominante — valores baixos, isto é, LLR muito negativo (deletério), empurram a predição para patogênico —, seguido de perto pela pertinência a domínio crítico (`in_critical_domain`). O padrão confirma que o modelo raciocina sobre biologia interpretável, e não como uma caixa-preta.

4. Discussão

4.1 Biologia transferível versus memorização

O achado central deste trabalho é que **o sinal de domínio funcional generaliza para dados novos, ao passo que a posição bruta memoriza**. Em validação interna ingênua, a posição do resíduo parece um preditor forte; porém, quando avaliada em coortes externas independentes, colapsa (0,791) enquanto o modelo consciente de domínio se mantém superior (0,847). Essa inversão é diagnóstica: características que codificam **mecanismo** — a que região funcional a mutação pertence, e se essa região é crítica para a estabilidade ou a atividade da proteína — carregam biologia que se aplica a variantes nunca vistas. Já um índice numérico de posição carrega, sobretudo, a

memória de quais posições estavam rotuladas no treino. A taxa de patogenicidade de ~45% dentro de domínios críticos contra ~7–10% fora reforça que o modelo aprendeu um princípio biológico real, coerente com décadas de literatura sobre BRCA1 (RING/BRCT) e BRCA2 (domínio de ligação ao DNA) e com evidências recentes de que a restrição evolutiva em resolução de domínio melhora a priorização de variantes missense.

Cabe uma distinção honesta entre dois modos de medir a generalização. A AUC no **conjunto externo agregado** (0,847) beneficia-se, em parte, da separação *entre* coortes com composições diferentes. A **meta-análise por coorte** (§3.5) é mais conservadora e revela heterogeneidade substancial ($I^2 = 88\%$): o modelo é excelente nas coortes de painel especialista (0,86–0,89) e fraco em uma coorte externa de BRCA1 (0,60). Interpretamos isso não como fragilidade a ser escondida, mas como informação: o desempenho depende da qualidade de rotulagem e da composição da coorte, e a força real do método está na priorização de variantes com rótulos de alta confiança. Reportar essa nuance é parte do compromisso de honestidade que define o trabalho.

4.2 A honestidade metodológica como contribuição científica

É tentador, em uma competição, apresentar apenas o melhor número. Optamos pelo contrário: relatamos que nossa hipótese fundadora — os números primos — **falhou** em um teste justo, e que um preditor aparentemente forte era, na verdade, um artefato de vazamento. Defendemos que essa transparência é a contribuição mais durável do trabalho. Primeiro, porque é **reprodutível e auditável**: todo o protocolo de bloqueio por posição e validação externa pode ser reexecutado. Segundo, porque o **diagnóstico de vazamento posicional** é um alerta metodológico útil para toda a área de predição de patogenicidade, onde benchmarks internos otimistas são comuns. Ciência não é a ausência de resultados negativos; é o tratamento rigoroso deles. Um resultado negativo bem estabelecido vale mais do que um resultado positivo frágil.

4.3 Posicionamento frente a preditores estabelecidos

Preditores como AlphaMissense, REVEL e CADD são referências poderosas, mas incorporá-los como *características* de um novo modelo introduz **circularidade** — eles próprios são treinados em rótulos correlacionados, e seu uso direto infla artificialmente o desempenho. Por isso, tratamo-los como **linha de referência de comparação**, não como insumo do modelo proposto. O valor diferencial do PrimeVarClass não é superar numericamente esses preditores fechados, mas oferecer um método **aberto**,

interpretável e auditável, cujo sinal preditivo tem origem biológica explícita (região funcional) e cuja generalização é demonstrada externamente.

4.4 Limitações

Reconhecemos limites claros. **(i)** A validação concentrou-se em duas proteínas (*BRCA1/BRCA2*); a extensão a outros genes é trabalho futuro. **(ii)** As fronteiras de domínio são aproximações baseadas em literatura e no UniProt; refinamentos estruturais podem melhorar a granularidade. **(iii)** A generalização é **heterogênea** ($I^2 = 88\%$): forte nas coortes de painel especialista, mas fraca em uma coorte externa de *BRCA1*, o que exige cautela e mais coortes para caracterizar os limites de aplicabilidade. **(iv)** Não há, ainda, **confirmação funcional experimental** das priorizações — o sistema apoia pesquisa, não substitui ensaio funcional (por exemplo, *saturation genome editing*) nem julgamento clínico. Nenhuma dessas limitações compromete o achado central; todas apontam caminhos concretos de continuidade.

4.5 Trabalhos futuros

Três direções decorrem naturalmente deste trabalho. **Primeiro**, estender a anotação consciente de domínio e a pontuação ESM-2 a **outros genes** de predisposição (por exemplo, *TP53*, *PALB2*, *CHEK2*), verificando se o ganho de generalização se replica. **Segundo**, aplicar **calibração formal ACMG/AMP** (Pejaver et al., 2022) para converter as probabilidades do modelo-carro-chefe em forças de evidência utilizáveis por comissões de classificação. **Terceiro**, buscar **validação funcional** convergente com ensaios de alto rendimento — *saturation genome editing* (Findlay et al., 2014) e ensaios de reparo — para as variantes priorizadas, fechando o ciclo entre predição e evidência experimental. A heterogeneidade observada entre coortes (§3.5) torna prioritário, ainda, ampliar o número de coortes externas para caracterizar os limites de aplicabilidade do método.

5. Impacto social e aplicação

5.1 O problema brasileiro concreto

O acesso à interpretação de variantes genéticas é profundamente desigual no Brasil. A expertise concentra-se em poucos centros; laboratórios públicos, hospitais universitários e grupos de pesquisa em regiões menos assistidas frequentemente não dispõem de ferramentas abertas e adaptáveis. O resultado é que exames genéticos, quando realizados, muitas vezes retornam VUS sem suporte para conduzir a decisão — e o custo desse impasse recai desproporcionalmente sobre quem depende do sistema público.

A literatura nacional documenta essa realidade. Recomendações específicas para avançar o diagnóstico e o manejo do câncer de mama e ovário hereditário no Brasil apontam lacunas de acesso e de infraestrutura (Achatz et al., 2020). Estudos de aconselhamento genético e de perfil de risco em serviços brasileiros (Palmero et al., 2007; Fernandes et al., 2019), avaliações do conhecimento médico sobre testagem para síndrome de câncer de mama e ovário hereditário (Lasta et al., 2023) e caracterizações moleculares em serviços públicos de medicina de precisão (Ribeiro et al., 2025), bem como achados de variantes específicas em populações regionais (Noronha et al., 2026), reforçam a necessidade de ferramentas abertas, auditáveis e de baixo custo computacional — exatamente o nicho que o PrimeVarClass busca ocupar como apoio à pesquisa e à formação.

5.2 Como o PrimeVarClass contribui

O sistema é posicionado explicitamente **não como diagnóstico clínico automático**, mas como **ferramenta de aceleração de pesquisa responsável**:

- **Apoio a laboratórios públicos e universitários:** uma plataforma aberta e auditável para priorizar variantes candidatas e organizar evidência pública (ClinVar, gnomAD), reduzindo o tempo de análise inicial.
- **Formação de pesquisadores:** por ser explicável e reprodutível, serve de instrumento didático sobre boas práticas — validação externa, prevenção de vazamento, honestidade sobre limites.
- **Suporte à pesquisa translacional nacional:** geração de hipóteses funcionais rastreáveis para priorizar quais variantes merecem investigação experimental.
- **Equidade:** por ser software aberto e de baixo custo computacional (não exige GPU para o núcleo), pode ser executado em infraestrutura modesta.

5.3 O que o sistema deliberadamente ****não**** faz

Não emite laudo clínico, não substitui aconselhamento genético humano e não afirma validade terapêutica. Essa contenção é parte do design responsável e alinha o projeto ao espírito de "IA para o bem comum".

5.4 A plataforma como aplicação prática concreta

O trabalho não se limita a um resultado estatístico: entrega um **sistema funcional e reprodutível**, com resultados finais. Os componentes são: **(a)** um pacote de software aberto e auditável que implementa todo o pipeline — codificação de características, anotação consciente de domínio (`domain_annotation.py`), treino e validação, e ingestão de escores ESM-2 (`esm_scores.py`) — com **testes automatizados** garantindo reprodutibilidade; **(b)** uma **interface programática (API)** para pontuar

variantes e organizar evidência pública; **(c) um protótipo de sistema de apoio à decisão** para priorização de variantes candidatas, voltado a laboratórios de pesquisa. Todos os números e figuras deste artigo são gerados por scripts reexecutáveis incluídos no sistema, o que torna a aplicação **verificável de ponta a ponta**. Assim, o PrimeVarClass responde diretamente ao critério de aplicação prática: é uma ferramenta concreta, de baixo custo computacional, pronta para apoiar pesquisa genética responsável no Brasil.

6. Ética e uso de inteligência artificial

Em conformidade com o item 2.2.2 (Nota 4) do Edital, declaramos de forma transparente o uso de ferramentas de Inteligência Artificial neste trabalho:

- **Ferramenta utilizada:** assistente de programação e redação baseado em modelo de linguagem de grande porte (Claude, da Anthropic), operado via interface de linha de comando para desenvolvimento de software.
- **Finalidades:** (a) apoio à escrita, depuração e refatoração do código-fonte; (b) execução e organização de análises estatísticas (validação, Monte Carlo, meta-análise) sobre dados reais; (c) apoio à revisão sistemática da literatura e à formatação de referências; (d) redação e edição assistidas do texto em português.

Toda a concepção científica, a verificação dos resultados e a responsabilidade final são do(a) autor(a) humano(a).

Declaramos ainda que: **(i)** todos os dados são públicos e auditáveis, sem informação de pacientes identificáveis; **(ii) nenhum resultado, figura ou métrica deste trabalho foi fabricado ou simulado** — todos derivam de execução real sobre dados reais, com código de validação reexecutável; **(iii)** reconhecemos vieses potenciais (representatividade populacional dos bancos de dados) e a necessidade de validação experimental independente antes de qualquer uso clínico. A governança do projeto prioriza reprodutibilidade, prudência e não-maleficência, e nenhuma prática de uso antiético de IA (item 4.1 do Edital) foi empregada.

7. Conclusão

Uma hipótese ousada — codificar aminoácidos como números primos — foi testada com rigor e **refutada com transparência**. Esse resultado negativo, longe de ser um fracasso, conduziu a dois avanços concretos: o **diagnóstico da armadilha de vazamento posicional** em benchmarks de patogenicidade e a construção de um **classificador consciente de domínio funcional** que **generaliza para coortes externas independentes** (AUC 0,847; DeLong $p = 1,8 \times 10^{-13}$), superando modelos

que apenas memorizam. Combinado a um modelo de linguagem de proteínas autêntico (ESM-2), o modelo-carro-chefe alcança **AUC externa de 0,909**, com explicabilidade demonstrada por valores de Shapley. O PrimeVarClass entrega esse método de forma aberta, explicável, auditável e eticamente contida, com aplicação direta ao contexto brasileiro de saúde de precisão e formação científica. Sua maior força não é um número, mas um **compromisso com a ciência honesta** — o tipo de trabalho que a comunidade pode confiar, reproduzir e construir em cima.

Reprodutibilidade e disponibilidade de dados

Todos os resultados derivam de dados **públicos** (ClinVar, painéis de especialistas ENIGMA/ClinGen, gnomAD) e de código **aberto e reexecutável**, disponível no repositório público do projeto — <https://github.com/WesleyCapucho/primevarclass> — com testes automatizados e integração contínua (CI). Todos os números e figuras deste artigo são gerados por *scripts* versionados (anotação de domínio, pontuação ESM-2, validação anti-vazamento, robustez Monte Carlo, meta-análise, SHAP e geração de figuras), com sementes aleatórias fixadas para reprodutibilidade determinística. **Nenhum dado, figura ou métrica foi fabricado ou simulado.**

Lista de Figuras e Tabelas

- **Figura 1.** Mecanismo BRCA1/BRCA2 no reparo do DNA e o câncer hereditário de mama e ovário (HBOC).
- **Figura 2.** Estruturas 3D experimentais das proteínas-alvo (BRCA1 RING/BRCT; BRCA2 DBD–DSS1–ssDNA).
- **Figura 3.** Consequência estrutural 3D das variantes que o modelo pontua como patogênicas: Cys61Gly no sítio de zinco do RING e sobreposição nativo×mutante de Met1775Arg no BRCT.
- **Figura 4.** Arquitetura de domínios funcionais de BRCA1/BRCA2 com variantes sobrepostas.
- **Figura 5.** Fração de variantes patogênicas por região funcional.
- **Figura 6.** Distribuição bootstrap (B = 2000) da AUC externa.
- **Figura 7.** Teste de permutação (N = 2000).
- **Figura 8.** Estabilidade da AUC em 12 sementes de validação cruzada.
- **Figura 9.** Curva de calibração e escore de Brier.
- **Figura 10.** Curvas ROC nas coortes externas.
- **Figura 11.** Forest plot da meta-análise de generalização externa.
- **Figura 12.** Explicabilidade (SHAP) do modelo domínio + ESM-2.

- **Tabela 1.** Desempenho por conjunto de características (refutação dos primos).
- **Tabela 2.** Comparações pareadas (DeLong).
- **Tabela 3.** Modelo consciente de domínio: CV bloqueada por posição e generalização externa.
- **Tabela 4.** Meta-análise da AUC externa por coorte.
- **Tabela 5.** Modelo-carro-chefe domínio + ESM-2 sob o protocolo anti-vazamento.

Referências

Lista completa, em ordem alfabética (sistema autor-data, NBR 6023), de todas as referências efetivamente citadas no corpo deste artigo. Fontes primárias adicionais consultadas na revisão de literatura, mas não citadas diretamente no texto, estão disponíveis para consulta e transparência em referencias_abnt.md (52 registros, com DOIs, recuperados via PubMed/NLM).

1. ACHATZ, M. I. et al. Recommendations for advancing the diagnosis and management of hereditary breast and ovarian cancer in Brazil. **JCO Glob Oncol**, v. 6, p. 439-452, 2020. DOI: 10.1200/JGO.19.00170.
2. CHENG, J. et al. Accurate proteome-wide missense variant effect prediction with AlphaMissense. **Science**, v. 381, n. 6664, eadg7492, 2023. DOI: 10.1126/science.adg7492.
3. DELONG, E. R.; DELONG, D. M.; CLARKE-PEARSON, D. L. Comparing the areas under two or more correlated ROC curves: a nonparametric approach. **Biometrics**, v. 44, n. 3, p. 837-845, 1988.
4. DINES, J. N. et al. Systematic misclassification of missense variants in BRCA1 and BRCA2 "coldspots". **Genet Med**, v. 22, n. 5, p. 825-830, 2020. DOI: 10.1038/s41436-019-0740-6.
5. FAVALLI, V. et al. Machine learning-based reclassification of germline variants of unknown significance: the RENOVO algorithm. **Am J Hum Genet**, v. 108, n. 4, p. 682-695, 2021. DOI: 10.1016/j.ajhg.2021.03.010.
6. FERNANDES, G. C. et al. Differential profile of BRCA1 vs. BRCA2 mutated families: a characterization of the main differences and similarities in patients. **Asian Pac J Cancer Prev**, v. 20, n. 6, p. 1655-1660, 2019. DOI: 10.31557/APJCP.2019.20.6.1655.
7. FINDLAY, G. M. et al. Saturation editing of genomic regions by multiplex homology-directed repair. **Nature**, v. 513, n. 7516, p. 120-3, 2014. DOI: 10.1038/nature13695.

8. HART, S. N. et al. Prediction of the functional impact of missense variants in BRCA1 and BRCA2 with BRCA-ML. **NPJ Breast Cancer**, v. 6, 13, 2020. DOI: 10.1038/s41523-020-0159-x.
9. IOANNIDIS, N. M. et al. REVEL: an ensemble method for predicting the pathogenicity of rare missense variants. **Am J Hum Genet**, v. 99, n. 4, p. 877-885, 2016. DOI: 10.1016/j.ajhg.2016.08.016.
10. KARCZEWSKI, K. J. et al. The mutational constraint spectrum quantified from variation in 141,456 humans (gnomAD). **Nature**, v. 581, n. 7809, p. 434-443, 2020. DOI: 10.1038/s41586-020-2308-7.
11. KERNBACH, J. M.; STAARTJES, V. E. Foundations of machine learning-based clinical prediction modeling: Part II — generalization and overfitting. **Acta Neurochir Suppl**, v. 134, p. 15-21, 2022. DOI: 10.1007/978-3-030-85292-4_3.
12. LASTA, J. L.; GROTO, A. D.; BRANDALIZE, A. P. C. Assessment of medical knowledge toward genetic testing for individuals with hereditary breast and ovarian cancer syndrome in Brazil. **Prev Med Rep**, v. 35, p. 102356, 2023. DOI: 10.1016/j.pmedr.2023.102356.
13. LIN, Z. et al. Evolutionary-scale prediction of atomic-level protein structure with a language model (ESM-2). **Science**, v. 379, n. 6637, p. 1123-1130, 2023. DOI: 10.1126/science.ade2574.
14. MEIER, J. et al. Language models enable zero-shot prediction of the effects of mutations on protein function. **NeurIPS**, 2021.
15. NORONHA, M. M. et al. Beyond 1100delC: distinct CHEK2 variants and unique cancer phenotypes in Northeast Brazil. **Fam Cancer**, v. 25, n. 1, p. 8, 2026. DOI: 10.1007/s10689-025-00526-z.
16. PALMERO, E. I. et al. Clinical characterization and risk profile of individuals seeking genetic counseling for hereditary breast cancer in Brazil. **J Genet Couns**, v. 16, n. 3, p. 363-71, 2007. DOI: 10.1007/s10897-006-9073-0.
17. PARSONS, M. T. et al. Large scale multifactorial likelihood quantitative analysis of BRCA1 and BRCA2 variants: an ENIGMA resource to support clinical variant classification. **Hum Mutat**, v. 40, n. 9, p. 1557-1578, 2019. DOI: 10.1002/humu.23818.
18. PEJAVER, V. et al. Calibration of computational tools for missense variant pathogenicity classification and ClinGen recommendations for PP3/BP4 criteria. **Am J Hum Genet**, v. 109, n. 12, p. 2163-2177, 2022. DOI: 10.1016/j.ajhg.2022.10.013.

19. RENTZSCH, P. et al. CADD: predicting the deleteriousness of variants throughout the human genome. **Nucleic Acids Res**, v. 47, n. D1, p. D886-D894, 2019. DOI: 10.1093/nar/gky1016.
20. RIBEIRO, A. A. F. et al. Molecular characterization of hereditary breast and ovarian cancer patients from a public precision medicine service in the Southeast Brazilian population. **Sci Rep**, v. 15, n. 1, p. 33495, 2025. DOI: 10.1038/s41598-025-16870-0.
21. RICHARDS, S. et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of Medical Genetics and Genomics and the Association for Molecular Pathology. **Genet Med**, v. 17, n. 5, p. 405-24, 2015. DOI: 10.1038/gim.2015.30.
22. TIAN, Y. et al. REVEL and BayesDel outperform other in silico meta-predictors for clinical variant classification. **Sci Rep**, v. 9, n. 1, p. 12752, 2019. DOI: 10.1038/s41598-019-49224-8.
23. TOLAND, A. E.; ANDREASSEN, P. R. DNA repair-related functional assays for the classification of BRCA1 and BRCA2 variants: a critical review and needs assessment. **J Med Genet**, v. 54, n. 11, p. 721-731, 2017. DOI: 10.1136/jmedgenet-2017-104707.
24. TORRETTO, G. C. et al. Domain-specific computational, functional and structural methods enable interpretation of BRCT variants of uncertain significance. **Curr Oncol**, v. 33, n. 6, 2026.
25. UNIPROT CONSORTIUM, THE. UniProt: the Universal Protein Knowledgebase in 2023. **Nucleic Acids Res**, v. 51, n. D1, p. D523-D531, 2023. (BRCA1 P38398; BRCA2 P51587).
26. YANG, H. et al. BRCA2 function in DNA binding and recombination from a BRCA2–DSS1–ssDNA structure. **Science**, v. 297, n. 5588, p. 1837-1848, 2002. DOI: 10.1126/science.297.5588.1837.
27. ZHANG, X. et al. Genetic constraint at single amino acid resolution in protein domains improves missense variant prioritisation and gene discovery. **Genome Med**, v. 16, n. 1, 88, 2024. DOI: 10.1186/s13073-024-01358-9.