

PrimeVarClass: da hipótese dos números primos a um classificador de variantes BRCA1/BRCA2 consciente de domínio, validado externamente e complementar ao estado da arte

32º Prêmio Jovem Cientista — Categoria Estudante do Ensino Superior

Tema: Inteligência Artificial para o Bem Comum — Subtema: Inteligência Artificial & Saúde (item 1.4.1.b do Edital)

Autor: Wesley Felipe Capucho — graduando em Engenharia Bioquímica

Orientador(a): <a definir>

Instituição de vínculo: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP) — Estrada Municipal do Campinho, s/nº, Ponte Nova, Lorena – SP, CEP 12602-810. E-mail: wesleycapucho@usp.br. Telefone: <a definir>.

Instituição onde a pesquisa foi desenvolvida: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP), Lorena – SP, Brasil.

Palavras-chave: variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

APRESENTAÇÃO

Resumo

Parti de uma hipótese pouco convencional: codificar aminoácidos pela estrutura dos números primos revelaria padrões de patogenicidade em variantes missense? Nomeei o projeto PrimeVarClass a partir dessa aposta e a testei com rigor — validação cruzada bloqueada por posição e generalização em coortes externas nunca vistas no treino. Refutei a hipótese com transparência: a codificação por primos teve desempenho inferior ao de uma identidade trivial de aminoácidos (AUC externa 0,681 vs. 0,718; $p = 0,045$) e piorou um modelo bioquímico ao ser adicionada ($0,791 \rightarrow 0,765$; $p = 3,8 \times 10^{-8}$). No processo, diagnostiquei uma armadilha de vazamento posicional que infla benchmarks internos. A partir daí, construí um classificador consciente de domínio funcional (RING/BRCT de BRCA1; domínio de ligação ao DNA de BRCA2), que generalizou para coortes externas com AUC de 0,847 — superando o modelo com posição bruta (0,791; $p = 1,8 \times 10^{-13}$). Combinado a um modelo de linguagem de proteínas (ESM-2), o modelo-carro-chefe atingiu AUC externa de 0,909, estatisticamente equivalente aos melhores preditores publicados — AlphaMissense (0,926; $p = 0,24$), REVEL (0,930; $p = 0,14$) e CADD (0,891; $p = 0,37$) —, avaliado sob desvantagem: esses preditores carregam circularidade com os próprios rótulos de teste, e o meu modelo, não. Um meta-classificador integrando todos os sinais atingiu 0,938. Calibrei os escores em força de evidência ACMG/AMP e, entre variantes que o AlphaMissense deixa ambíguas (644 no total), resolvi 53,8% dos VUS e 64,6% das conflitantes — a prova de que complemento o AlphaMissense, não compito com ele. Validei o mecanismo estrutural contra dados funcionais reais de reparo por recombinação homóloga (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$), mitiguei uma lacuna de equidade entre ancestralidades, e simulei validação prospectiva por corte temporal (AUC de 0,892 em 2016 a 0,932 em 2021). Por fim, implementei aprendizado contínuo real e seguro: o modelo melhora com rótulos confirmados pelo uso (AUC no conjunto travado subindo de 0,895 para 0,922) sob uma trava que rejeita atualizações que pioressem o desempenho. Entrego o sistema como plataforma aberta, auditável e reproduzível. A contribuição central não é um número inflado, mas um método

honesto, generalizável e continuamente aprimorável para apoiar a interpretação responsável de variantes genéticas no Brasil.

Palavras-chave: classificação de variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

Introdução

O problema clínico e social

Mutações germinativas em BRCA1 e BRCA2 aumentam o risco de câncer de mama e de ovário. Ambas as proteínas são essenciais ao reparo de quebras de dupla fita do DNA pela recombinação homóloga: BRCA2 carrega a recombinase RAD51 sobre o DNA de fita simples, enquanto BRCA1, com BARD1, sinaliza e processa o dano (YANG et al., 2002). Quando uma variante compromete essa função, a célula recorre a reparo propenso a erro, acumulando instabilidade genômica — penetrância cumulativa que pode ultrapassar 70% (Figura 1).




Figura 1. Mecanismo BRCA1/BRCA2 no câncer hereditário de mama e ovário. Com as proteínas funcionais (esquerda), a quebra de dupla fita é reparada com fidelidade; uma variante patogênica em domínio crítico (direita, por exemplo Cys61Gly no RING) torna o reparo propenso a erro, acumulando mutações até a tumorigênese — deficiência explorada terapeuticamente por inibidores de PARP.

Ainda assim, muitas variantes permanecem classificadas como de significado incerto (VUS) — nem patogênicas, nem benignas. No Brasil, isso se agrava por desigualdade de acesso: a expertise de interpretação concentra-se em poucos centros, e laboratórios públicos frequentemente carecem de ferramentas abertas e

auditáveis (ACHATZ et al., 2020; PALMERO et al., 2007; FERNANDES et al., 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO et al., 2025; NORONHA et al., 2026). Foi para atacar esse gargalo que desenvolvi o PrimeVarClass.

A lacuna metodológica e o estado da arte

Preditores como REVEL (IOANNIDIS et al., 2016), CADD (RENTZSCH et al., 2019) e AlphaMissense (CHENG et al., 2023) evoluíram para meta-preditores e modelos profundos, com REVEL/BayesDel superando preditores individuais (TIAN et al., 2019). Mas benchmarks nessa área sofrem recorrentemente de vazamento de dados e ausência de validação externa (KERNBACH; STAARTJES, 2022; GANAKAMMAL; ALEXOV, 2019; SUYBENG et al., 2020; SMOL et al., 2021; DONG et al., 2014; LABES et al., 2022), problema que um framework recente propõe mitigar combinando controle de vazamento e SHAP (SHETTY et al., 2026). Especificamente em BRCA1/BRCA2, o BRCA-ML (HART et al., 2020), o RENOVO (FAVALLI et al., 2021), a análise ENIGMA (PARSONS et al., 2019) e ensaios funcionais de saturação genômica (FINDLAY et al., 2014; 2018) reduzem a incerteza, e a calibração ACMG/AMP é recomendação do ClinGen (PEJAVER et al., 2022; RICHARDS et al., 2015; NYKAMP et al., 2017; OZA et al., 2018; MCCORMICK et al., 2020) — inclusive com escores informados por estrutura em BRCA1 (RAMADANE-MORCHADI et al., 2025), o que corrobora a abordagem consciente de domínio deste trabalho. Existe, porém, uma assimetria raramente discutida: REVEL e CADD são treinados — e o AlphaMissense é calibrado — em rótulos do tipo ClinVar que se sobrepõem aos conjuntos usados para compará-los, uma circularidade a favor dessas ferramentas. Chamo essa assimetria de vazamento a favor de terceiros e a corrijo explicitamente nos Resultados, somando-se a "coldspots" mal classificados (DINES et al., 2020) e evidências de que restrição evolutiva por domínio melhora a priorização (ZHANG et al., 2024; CHEN et al., 2023; CHAO et al., 2024; LAKE et al., 2024; TORRETTO et al., 2026).

A jornada científica: por que "Prime"

O nome PrimeVarClass guarda a origem do projeto: uma hipótese arrojada sobre números primos, tratada não como verdade a defender, mas como hipótese a testar sob o protocolo mais rigoroso de que dispunha. O resultado foi negativo, e relato-o com a mesma transparência dos positivos. Sustento que essa trajetória —

hipótese ousada, teste rigoroso, refutação transparente, redirecionamento para o que funciona — é, em si, contribuição científica tão valiosa quanto qualquer resultado positivo isolado, e o antídoto direto contra alegações infladas de IA em saúde.

Objetivos

1. Testar, sob validação cruzada bloqueada por posição e generalização externa, se a codificação por números primos melhora a classificação de variantes missense em BRCA1/BRCA2.
2. Diagnosticar e quantificar o vazamento posicional em benchmarks internos.
3. Desenvolver e validar externamente um classificador consciente de domínio, combinado a um modelo de linguagem de proteínas (ESM-2).
4. Comparar esse modelo, de forma honesta, com AlphaMissense/REVEL/CADD, corrigindo a assimetria de circularidade que os favorece.
5. Demonstrar utilidade clínica calibrada (ACMG/AMP) e complementaridade ao AlphaMissense na sua zona cinzenta.
6. Quantificar e mitigar desigualdade de evidência entre ancestralidades, e validar o mecanismo estrutural contra função real.
7. Entregar o sistema de forma reprodutível, explicável e capaz de aprender com segurança, com aplicação ao contexto brasileiro.

DESENVOLVIMENTO

Materiais e Métodos

Fontes de dados

Utilizei dados públicos e auditáveis de BRCA1 (UniProt P38398) e BRCA2 (P51587) (UNIPROT CONSORTIUM, 2023): classificações do ClinVar, com subconjunto de alta confiança por painel de especialistas (ENIGMA/ClinGen; PARSONS et al., 2019); frequências alélicas do gnomAD por ancestralidade (KARCZEWSKI et al., 2020); estruturas do PDB e AlphaFold DB; e ensaios funcionais do MaveDB (FINDLAY et al., 2018; STARITA et al., 2015). Rótulos: patogênico (1) vs. benigno (0); conflitantes/baixa confiança excluídos. Treino interno: n = 869 (211 patogênicas); externo, estritamente separado: n = 836 (144 patogênicas).

Representação, teste dos primos e domínio funcional

Representei cada variante por características bioquímicas (massa, hidrofobicidade, carga, aromaticidade, severidade), derivadas de primos (razões, diferenças, lacunas), identidade categórica e domínio funcional. Para testar a hipótese dos primos, comparei cinco conjuntos — identidade com posição (4), identidade sem posição (3), bioquímico com posição (28), híbrido bioquímico+primos (76) e apenas primos (50) — sob o mesmo classificador e protocolo. Mapeei domínios funcionais curados do UniProt: RING (1–109) e BRCT (1642–1736, 1756–1855) em BRCA1; domínio de ligação ao DNA (2481–3186) em BRCA2, como regiões críticas, definindo `functional_domain` e `in_critical_domain` — características de região, não do índice do resíduo, portanto transferíveis.

Protocolo anti-vazamento e modelo

Adotei dois níveis de avaliação, sem exceção: (A) validação cruzada bloqueada por posição (StratifiedGroupKFold, 5 folds, agrupada por gene:posição), impedindo que a mesma posição apareça em treino e teste; e (B) generalização externa nas quatro coortes nunca tocadas. Comparações de AUC usaram o teste pareado de DeLong (DELONG; DELONG; CLARKE-PEARSON, 1988). Implementei um Random Forest balanceado em pipeline reprodutível de semente fixa, como

pacote Python auditável com testes automatizados; a anotação de domínio (domain_annotation.py) e a ingestão de escores profundos (esm_scores.py) são módulos independentes, sem dependência de GPU.

Robustez, meta-análise, ESM-2 e SHAP

Quantifiquei robustez por bootstrap ($B = 2000$), teste de permutação ($N = 2000$), validação cruzada bloqueada repetida (12 sementes) e calibração (Brier, confiabilidade). Agrupei as quatro coortes externas por efeitos aleatórios (DerSimonian-Laird, escala logit), reportando IC95%, Q de Cochran e I^2 . Pontuei cada variante com ESM-2 (facebook/esm2_t33_650M_UR50D; LIN et al., 2023) por razão de verossimilhança logarítmica masked-marginal (MEIER et al., 2021), em janelas de ± 511 resíduos. Como o ESM-2 não usa rótulos de patogenicidade, não introduz circularidade; reexecutei a pontuação com um ESM-2 de 3B parâmetros (correlação Pearson 0,83 com o de 650M, sem ganho de AUC — 0,905 vs. 0,909 —, resultado honesto de saturação que me levou a manter o 650M como principal). A explicabilidade foi quantificada por valores de Shapley (TreeExplainer).

Comparação honesta, meta-classificador e calibração ACMG/AMP

Comparei o modelo-carro-chefe com AlphaMissense, REVEL, CADD, PolyPhen-2 e SIFT nas mesmas 836 variantes externas (escores via API REST do Ensembl VEP, transcrito MANE Select). Tornei explícita a assimetria de circularidade (Seção 1.3) e tentei isolá-la recortando variantes recentes (ClinVar ≥ 2024); constatei que o recorte não separa o vazamento de forma limpa, pois last_evaluated reflete reavaliação, não submissão original. Testei um meta-modelo logístico combinando os quatro sinais, validado fora da amostra (5 folds, $n = 621$). Calibrei o escore aos limiares de razão de verossimilhança de Tavtigian/Pejaver (PEJAVER et al., 2022; RICHARDS et al., 2015): $LR \geq 18,7/4,33/2,08$ para PP3 forte/moderado/leve; $LR \leq 0,05/0,23/0,48$ para BP4, prevalência prévia de 10%.

Zona cinzenta, equidade, mecanismo e aprendizado contínuo

Identifiquei, entre variantes reais do ClinVar, as que o AlphaMissense classifica como ambíguas (644) e verifiquei quantas recebem do meu modelo uma chamada PP3/BP4 informativa. Usei frequências do gnomAD (europeias vs. não europeias) para medir equidade de resolução em variantes com $AF > 10^{-4}$.

(POPEJOY; FULLERTON, 2016; MANRAI et al., 2016; SOEWITO et al., 2022). Decompos cada variante por mecanismo estrutural (coordenação de zinco, núcleo, interface, superfície) a partir de estruturas reais (PDB 1JM7, 1T29, 1MJE, com BRCA2 realinhado de mouse para humano) e cruzei com função real de reparo por recombinação homóloga (TOLAND; ANDREASSEN, 2017; HU et al., 2022; STARITA et al., 2015; $n = 1.262$) por Kruskal-Wallis. Simulei validação prospectiva por corte temporal (last_evaluated). Por fim, implementei aprendizado contínuo real: um FeedbackStore registra classificações confirmadas (carimbo UTC, fonte, hash SHA-256); uma rotina de atualização incremental só promove o modelo reajustado se ele não piorar, além de 0,005 de AUC, em um conjunto travado (variantes ≥ 2024) — testado com feedback real e, deliberadamente, com um lote envenenado (30% de rótulos invertidos), usável hoje por linha de comando (primevarclass feedback / update).

Resultados e Discussão

A hipótese dos números primos foi refutada

Testei a hipótese sob o protocolo anti-vazamento (Tabela 1). Os primos tiveram desempenho inferior à identidade trivial e pioraram um modelo bioquímico ao serem adicionados (Tabela 2).

Tabela 1. Refutação da hipótese dos primos (n = 869 treino / n = 836 externo).

Conjunto de características	nº feat.	CV bloqueada	Externa
Identidade (com posição) ^a	4	0,871	0,882
Bioquímico (com posição) ^a	28	0,802	0,791
Híbrido (bioquímico + primos) ^a	76	0,783	0,765
Identidade (sem posição)	3	0,745	0,718
Apenas primos	50	0,717	0,681

^a Incluem gene e posição bruta — risco de memorização diagnosticado a seguir.

Tabela 2. Comparações pareadas por DeLong.

Comparação	Protocolo	AUC A	AUC B	Δ	p
Primos vs. identidade	Bloqueada	0,717	0,745	-0,028	0,081
Primos vs. identidade	Externa	0,681	0,718	-0,038	0,045
Híbrido vs. bioquímico	Bloqueada	0,783	0,802	-0,019	<0,0001
Híbrido vs. bioquímico	Externa	0,765	0,791	-0,027	<0,0001

A diferença é uma tendência não significativa na CV interna ($p = 0,081$), mas significativa na generalização externa ($p = 0,045$) — e adicionar primos a um modelo bioquímico piora o desempenho externo ($p < 0,0001$). Conclusão honesta: os primos não agregam sinal útil.

Diagnóstico: a armadilha do vazamento posicional

Sob validação ingênua (sem bloqueio por grupo), a identidade combinada à posição bruta chega a AUC próxima de 0,90 — valor inflado, pois variantes da mesma posição compartilham rótulo e aparecem em treino e teste simultaneamente. Esse é o alerta metodológico central: benchmarks que não bloqueiam a posição superestimam o desempenho — a mesma lição que apliquei para corrigir o vazamento a favor de terceiros (Seção 3.7).

A solução: modelo consciente de domínio

Substituindo a posição bruta por região funcional, obtive um modelo que generaliza melhor externamente (Tabela 3; Figura 2).

Tabela 3. Consciência de domínio: validação bloqueada e externa (AUC-ROC).

Modelo	CV bloqueada	Externa
Bioquímico (sem posição)	0,743	0,717
Bioquímico + domínio (proposto)	0,818	0,847
Bioquímico + posição bruta (vazamento)	0,802	0,791

DeLong domínio vs. bioquímico: $p = 3,2 \times 10^{-9}$ (interno), $p = 1,8 \times 10^{-13}$ (externo). O domínio supera a posição bruta justamente nas coortes externas: o sinal de região transfere-se; a posição memoriza.




Figura 2. Domínios funcionais de BRCA1/BRCA2 com variantes reais sobrepostas. Patogênicas (vermelho, abaixo) concentram-se nas regiões críticas (44,5% vs. 6,8–10,0% fora delas) — base biológica do sinal de domínio.

Prova visual: mutações patogênicas reais capturadas

Selecionei variantes já confirmadas como patogênicas no ClinVar e verifiquei a resposta do modelo-carro-chefe. A Figura 3 mostra o RING de BRCA1 (PDB 1JM7) colorido por intensidade de detecção: as zonas mais sensíveis coincidem exatamente com as cisteínas que coordenam os dois íons de zinco estruturais, sem que eu tivesse informado essa coordenação. A Figura 4 detalha seis variantes confirmadas — três no sítio de zinco (Cys39Gly, Cys64Gly, Cys61Tyr) e três no núcleo do BRCT (Met1689Arg, Leu1705Pro, Trp1837Cys) —, todas detectadas com 96,3% a 99,7% de confiança. Repeti o exercício em BRCA2 (variantes clássicas do

domínio de ligação ao DNA, como Gly2748Asp, Arg3052Trp e Trp2626Cys, detectadas com 75,3% a 96,7%) e mapeei a superfície completa dos dois domínios por intensidade de detecção — evidência de que a abordagem generaliza entre genes; ambas as figuras estão no Material Suplementar.



Figura 3. RING de BRCA1 (PDB 1JM7), colorido por intensidade de detecção (azul = tolerante; dourado = detectada). Os dois íons de zinco (esferas) são coordenados por cisteínas identificadas, de forma independente, como a região mais sensível — coerente com décadas de literatura sobre o domínio.



Figura 4. Seis variantes de BRCA1 confirmadas patogênicas no ClinVar, cada uma sobre sua estrutura real, com o veredito do ClinVar (selo verde) e a chamada do meu modelo (selo dourado) — todas detectadas com alta confiança.

Robustez, meta-análise e o modelo-carro-chefe

Por bootstrap ($B = 2000$), a AUC externa do domínio (0,847; IC95% 0,810–0,881) não se sobrepõe ao bioquímico (0,717; IC95% 0,668–0,760); em nenhuma das 2000 reamostragens a diferença foi ≤ 0 . O teste de permutação ($N = 2000$) situa a AUC observada muito além da nula (0,501; $p = 5 \times 10^{-4}$). Em 12 sementes de CV bloqueada, a AUC média foi $0,828 \pm 0,005$ (domínio), $0,818 \pm 0,006$ (posição) e $0,763 \pm 0,005$ (bioquímico); o escore de Brier externo é 0,108, com boa calibração. Tratando as quatro coortes externas como estudos independentes (efeitos aleatórios), a AUC agrupada é 0,801 (IC95% 0,638–0,902), com heterogeneidade elevada ($I^2 = 88,2\%$): excelente nas coortes de painel especialista (0,864–0,888) e mais fraca em uma coorte externa de BRCA1 (0,599) — relato essa heterogeneidade em vez de escondê-la. Combinando domínio e ESM-2, o modelo-carro-chefe atinge AUC externa de 0,909 (Tabela 4; DeLong $p = 1,5 \times 10^{-10}$ vs. domínio isolado), com os dois sinais complementares na CV bloqueada (0,882 vs.

0,818 e 0,867 isolados). A explicabilidade por SHAP (Figura 5) confirma o escore ESM-2 e a pertinência a domínio crítico como preditores dominantes, com direção de efeito biologicamente correta.

Tabela 4. Modelo-carro-chefe sob o protocolo anti-vazamento (AUC-ROC).

Modelo	CV bloqueada	Externa
Consciente de domínio	0,818	0,847
ESM-2 (650M) sozinho	0,867	0,907
Domínio + ESM-2 (carro-chefe)	0,882	0,909




Figura 5. Explicabilidade por valores de Shapley do modelo domínio + ESM-2 — escore ESM-2 e domínio crítico são os preditores dominantes.

Vazamento a favor de terceiros: a comparação honesta

No mesmo conjunto externo (n = 836), medi o modelo-carro-chefe contra preditores publicados (Figura 6; Tabela 5). REVEL e CADD são treinados — e o AlphaMissense é calibrado — em rótulos que se sobrepõem ao meu teste; o meu modelo é avaliado fora dessa distribuição. Mesmo em desvantagem, a diferença para os três líderes não é significativa (p = 0,14 a 0,37), e supero SIFT e PolyPhen-2 com clareza. Tentei isolar o vazamento por corte temporal (≥ 2024); o recorte não

separa o efeito de forma limpa — todas as ferramentas melhoram nas variantes recentes (meu modelo sobe a 0,932, ainda equivalente aos líderes, $p = 0,12\text{--}0,61$). Por isso não alego "vazamento removido": a afirmação correta é a assimetria relatada. Empatar sob avaliação mais rigorosa é um resultado mais forte do que o número cru sugere — e é por isso que meu diferencial real não é vencer no AUC bruto, mas complementar essas ferramentas onde se abstêm.




Figura 6. Comparação honesta com o estado da arte: preditores supervisionados/calibrados em ClinVar (azul) têm circularidade a favor; o modelo-carro-chefe (vermelho) é avaliado fora da distribuição.

Tabela 5. Comparação honesta com o estado da arte (n = 836).

Ferramenta	AUC	Regime	DeLong vs. mim
REVEL	0,930	supervisionado em ClinVar	p=0,14 (n.s.)
AlphaMissense	0,926	calibrado em ClinVar	p=0,24 (n.s.)
PrimeVarClass	0,909	cego ao externo	—
CADD	0,891	supervisionado em ClinVar	p=0,37 (n.s.)
SIFT	0,845	não supervisionado	p=0,001
PolyPhen-2	0,773	não supervisionado	p<0,0001

Integrando de forma calibrada os quatro sinais, o meta-classificador atingiu AUC de 0,938 (IC95% 0,901–0,969; n = 621) — a melhor marca do estudo, superando mesmo o REVEL isolado (DeLong $p = 0,43$). A mensagem: não competir, mas somar.

Calibração ACMG/AMP e o complemento na zona cinzenta

Calibrei os escores aos limiares de Tavtigian/Pejaver: nas coortes externas, PP3 forte corresponde a 94% de patogênicos reais (LR $\approx$ 76; n = 84), e BP4 moderado a apenas 3,2% (LR $\approx$ 0,16; n = 444) — evidência confiável nas duas direções. O maior diferencial deste trabalho, porém, está na zona cinzenta do AlphaMissense (Figura 7; Tabela 6): entre 644 variantes reais que ele deixa ambíguas, resolvi 53,8% dos VUS e 64,6% das conflitantes; nas 17 que já tinham diagnóstico definitivo, minha concordância foi de 100%. Forneço informação exatamente onde a melhor ferramenta atual se cala.




Figura 7. Complemento ao AlphaMissense — evidência calibrada onde ele se abstém, em BRCA1 e BRCA2, com dados reais do ClinVar.

Tabela 6. Resolução de variantes na zona cinzenta do AlphaMissense.

Categoria	BRCA1	BRCA2	Combinado
VUS na zona cinzenta (n)	98	166	264
VUS resolvidas por mim	56,1%	52,4%	53,8%
Conflitantes na zona cinzenta (n)	64	128	192
Conflitantes resolvidas por mim	76,6%	58,6%	64,6%

Mecanismo, equidade e validação temporal

Decompus cada variante pelo mecanismo estrutural afetado e cruzei com função real de reparo por recombinação homóloga (1.262 variantes; STARITA et al., 2015): as categorias diferem de forma altamente significativa (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$), com coordenação de zinco a mais deletéria (mediana $-0,844$) e superfície a mais tolerada ($-0,011$) — validação ortogonal e independente. Entre variantes com frequência apreciável ($AF > 10^{-4}$), apenas 26,2% têm classificação definitiva em

ancestralidades não europeias, contra 55,7% em europeias (Figura 8); forneço evidência calibrada para 78% das não europeias ainda não resolvidas, e 84% das europeias — de forma equitativa. Simulando implantação prospectiva por corte temporal, a AUC futura cresceu de 0,892 (corte 2016) a 0,932 (corte 2021; Tabela 7).




Figura 8. Lacuna de resolução clínica entre ancestralidades (gnomAD) e a contribuição do meu modelo para reduzi-la equitativamente.

Tabela 7. Validação temporal (quasi-prospectiva) por ano de corte.

Corte	Treino (n)	Teste futuro (n)	AUC futura
2016	176	323	0,892
2019	279	220	0,926
2021	286	213	0,932

Aprendizado contínuo e seguro

Mantendo travado um conjunto de variantes recentes (≥ 2024 , nunca vistas no treino), revelei rótulos confirmados acumulados ao longo do tempo: a AUC no conjunto travado sobe de 0,895 para 0,922 — ganho puro por mais dados reais (Figura 9). Testei a trava de segurança deliberadamente com um lote de feedback envenenado (30% de rótulos invertidos): o candidato resultante (AUC 0,727) foi corretamente rejeitado pela regra de promoção. Não é promessa: é o mesmo efeito da validação temporal, operacionalizado como recurso usável hoje.




Figura 9. Aprendizado contínuo e seguro. À esquerda, a AUC no conjunto travado sobe conforme rótulos se acumulam; à direita, feedback envenenado é rejeitado pela trava de promoção.

Discussão: honestidade metodológica como contribuição, e complemento em vez de concorrência

O achado central é que domínio funcional generaliza, enquanto posição bruta memoriza — inversão diagnóstica confirmada em três momentos distintos deste trabalho: a refutação dos primos, o diagnóstico do vazamento posicional, e a exposição da assimetria de circularidade contra mim na comparação com o estado da arte. Relatar essas três desvantagens, em vez de escondê-las, é reproduzível e auditável, e cada uma é um alerta metodológico útil para a área. Por isso escolhi não competir com o AlphaMissense no AUC bruto — comparação estruturalmente injusta a meu desfavor —, e sim demonstrar o que realmente importa: evidência calibrada exatamente onde ele se abstém. Um laboratório clínico não precisa escolher entre as duas ferramentas; precisa das duas.

Limitações e trabalhos futuros

A validação concentrou-se em BRCA1/BRCA2; as fronteiras de domínio são aproximações da literatura; a generalização é heterogênea entre coortes ($I^2 = 88\%$); o recorte temporal não isola o vazamento de forma limpa; e não há, ainda, confirmação funcional experimental prospectiva conduzida por mim, apenas convergência com ensaios publicados. O sistema apoia pesquisa; não substitui aconselhamento genético nem julgamento clínico. Como trabalhos futuros, pretendo estender a anotação de domínio e o ESM-2 a outros genes (TP53, PALB2, CHEK2), ampliar as coortes externas para caracterizar os limites de aplicabilidade, acompanhar em produção o módulo de aprendizado contínuo com laboratórios

parceiros, e explorar modelos de linguagem de proteínas com plataformas automatizadas de evolução dirigida (ZHANG et al., 2025) como fonte futura de rótulos funcionais.

Impacto social, aplicação prática e ética no uso de IA

O acesso à interpretação genética é desigual no Brasil (ACHATZ et al., 2020; PALMERO et al., 2007; FERNANDES et al., 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO et al., 2025; NORONHA et al., 2026). Posiciono o PrimeVarClass não como diagnóstico automático, mas como ferramenta de pesquisa responsável: apoio a laboratórios públicos, formação de pesquisadores em boas práticas de validação, suporte translacional e equidade por ser software aberto e de baixo custo computacional, sem exigir GPU. Entrego um sistema funcional com resultados finais — pacote auditável com testes automatizados, interface programática, protótipo de apoio à decisão e módulo de aprendizado contínuo usável por linha de comando —, com todos os números e figuras gerados por scripts reexecutáveis. Em conformidade com o item 2.2.2 (Nota 4) do Edital, declaro o uso de um assistente de programação e redação baseado em modelo de linguagem de grande porte (Claude, da Anthropic) para apoio à escrita e depuração de código, execução de análises estatísticas sobre dados reais, revisão de literatura e redação assistida em português; a concepção científica, a verificação dos resultados e a responsabilidade final são minhas. Todos os dados são públicos e auditáveis; nenhum resultado ou figura foi fabricado ou simulado; reconheço vieses potenciais de representatividade populacional e a necessidade de validação experimental independente antes de qualquer uso clínico. Nenhuma prática de uso antiético de IA foi empregada.

CONCLUSÃO

Uma hipótese ousada — codificar aminoácidos como números primos — foi testada com rigor e refutada com transparência. Esse resultado negativo conduziu ao diagnóstico da armadilha de vazamento posicional e à construção de um classificador consciente de domínio que generaliza para coortes externas (AUC 0,847; $p = 1,8 \times 10^{-13}$), superando modelos que memorizam. Combinado a um modelo de linguagem de proteínas autêntico, o modelo-carro-chefe alcançou AUC externa de 0,909 — estatisticamente equivalente aos melhores preditores publicados, mesmo avaliado sob a desvantagem que eu mesmo tornei explícita. Um meta-classificador atingiu 0,938; calibrei a evidência em critérios ACMG/AMP; e demonstrei, com dados reais, que complemento o AlphaMissense onde ele se abstém, resolvendo mais da metade dos VUS e quase dois terços das variantes conflitantes na sua zona cinzenta. Validei o mecanismo do modelo contra função medida em laboratório, mitiguei uma lacuna de equidade entre ancestralidades, simulei validação prospectiva com resultados crescentes, e entreguei um mecanismo real e seguro de aprendizado contínuo. Entrego esse método de forma aberta, explicável, auditável e eticamente contida, com aplicação direta ao contexto brasileiro de saúde de precisão. A maior força do PrimeVarClass não é um número, mas um compromisso demonstrado com a ciência honesta — do teste de uma hipótese própria até a correção de uma assimetria que me desfavorecia.

REFERÊNCIAS

- ACHATZ, M. I. et al. Recommendations for Advancing the Diagnosis and Management of Hereditary Breast and Ovarian Cancer in Brazil. *JCO Glob Oncol*, v. 6, p. 439-452, 2020. DOI: 10.1200/JGO.19.00170.
- CHAO, K. R. et al. The landscape of regional missense mutational intolerance quantified from 125,748 exomes. *bioRxiv*, 2024. DOI: 10.1101/2024.04.11.588920.
- CHEN, S. et al. A genomic mutational constraint map using variation in 76,156 human genomes. *Nature*, v. 625, n. 7993, p. 92-100, 2023. DOI: 10.1038/s41586-023-06045-0.
- CHENG, J. et al. Accurate proteome-wide missense variant effect prediction with AlphaMissense. *Science*, v. 381, n. 6664, p. eadg7492, 2023. DOI: 10.1126/science.adg7492.
- DELONG, E. R.; DELONG, D. M.; CLARKE-PEARSON, D. L. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, v. 44, n. 3, p. 837-845, 1988.
- DINES, J. N. et al. Systematic misclassification of missense variants in BRCA1 and BRCA2 "coldspots". *Genet Med*, v. 22, n. 5, p. 825-830, 2020. DOI: 10.1038/s41436-019-0740-6.
- DONG, C. et al. Comparison and integration of deleteriousness prediction methods for nonsynonymous SNVs in whole exome sequencing studies. *Hum Mol Genet*, v. 24, n. 8, p. 2125-37, 2014. DOI: 10.1093/hmg/ddu733.
- FAVALLI, V. et al. Machine learning-based reclassification of germline variants of unknown significance: The RENOVO algorithm. *Am J Hum Genet*, v. 108, n. 4, p. 682-695, 2021. DOI: 10.1016/j.ajhg.2021.03.010.
- FERNANDES, G. C. et al. Differential Profile of BRCA1 vs. BRCA2 Mutated Families: A Characterization of the Main Differences and Similarities in Patients. *Asian Pac J Cancer Prev*, v. 20, n. 6, p. 1655-1660, 2019. DOI: 10.31557/APJCP.2019.20.6.1655.
- FINDLAY, G. M. et al. Saturation editing of genomic regions by multiplex homology-directed repair. *Nature*, v. 513, n. 7516, p. 120-3, 2014. DOI: 10.1038/nature13695.
- FINDLAY, G. M. et al. Accurate classification of BRCA1 variants with saturation genome editing. *Nature*, v. 562, n. 7726, p. 217-222, 2018. DOI: 10.1038/s41586-018-0461-z.
- GANAKAMMAL, S. R.; ALEXOV, E. Evaluation of performance of leading algorithms for variant pathogenicity predictions and designing a combinatory predictor method: application to Rett syndrome variants. *PeerJ*, v. 7, p. e8106, 2019. DOI: 10.7717/peerj.8106.

HART, S. N. et al. Prediction of the functional impact of missense variants in BRCA1 and BRCA2 with BRCA-ML. NPJ Breast Cancer, v. 6, p. 13, 2020. DOI: 10.1038/s41523-020-0159-x.

HU, C. et al. Classification of BRCA2 Variants of Uncertain Significance (VUS) Using an ACMG/AMP Model Incorporating a Homology-Directed Repair (HDR) Functional Assay. Clin Cancer Res, v. 28, n. 17, p. 3742-3751, 2022. DOI: 10.1158/1078-0432.CCR-22-0203.

IOANNIDIS, N. M. et al. REVEL: An Ensemble Method for Predicting the Pathogenicity of Rare Missense Variants. Am J Hum Genet, v. 99, n. 4, p. 877-885, 2016. DOI: 10.1016/j.ajhg.2016.08.016.

KARCZEWSKI, K. J. et al. The mutational constraint spectrum quantified from variation in 141,456 humans. Nature, v. 581, n. 7809, p. 434-443, 2020. DOI: 10.1038/s41586-020-2308-7.

KERNBACH, J. M.; STAARTJES, V. E. Foundations of Machine Learning-Based Clinical Prediction Modeling: Part II-Generalization and Overfitting. Acta Neurochir Suppl, v. 134, p. 15-21, 2022. DOI: 10.1007/978-3-030-85292-4_3.

LABES, S. et al. Machine-learning of complex evolutionary signals improves classification of SNVs. NAR Genom Bioinform, v. 4, n. 2, p. lqac025, 2022. DOI: 10.1093/nargab/lqac025.

LAKE, N. J. et al. Quantifying constraint in the human mitochondrial genome. Nature, v. 635, n. 8038, p. 390-397, 2024. DOI: 10.1038/s41586-024-08048-x.

LASTA, J. L.; GROTO, A. D.; BRANDALIZE, A. P. C. Assessment of medical knowledge toward genetic testing for individuals with hereditary breast and ovarian cancer syndrome in Brazil. Prev Med Rep, v. 35, p. 102356, 2023. DOI: 10.1016/j.pmedr.2023.102356.

LIN, Z. et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. Science, v. 379, n. 6637, p. 1123-1130, 2023. DOI: 10.1126/science.ade2574.

MANRAI, A. K. et al. Genetic Misdiagnoses and the Potential for Health Disparities. N Engl J Med, v. 375, n. 7, p. 655-665, 2016. DOI: 10.1056/NEJMsa1507092.

MCCORMICK, E. M. et al. Specifications of the ACMG/AMP standards and guidelines for mitochondrial DNA variant interpretation. Hum Mutat, v. 41, n. 12, p. 2028-2057, 2020. DOI: 10.1002/humu.24107.

MEIER, J. et al. Language models enable zero-shot prediction of the effects of mutations on protein function. NeurIPS, 2021.

NORONHA, M. M. et al. Beyond 1100delC: distinct CHEK2 variants and unique cancer phenotypes in Northeast Brazil. Fam Cancer, v. 25, n. 1, p. 8, 2026. DOI: 10.1007/s10689-025-00526-z.

NYKAMP, K. et al. Sherlock: a comprehensive refinement of the ACMG-AMP variant classification criteria. *Genet Med*, v. 19, n. 10, p. 1105-1117, 2017. DOI: 10.1038/gim.2017.37.

OZA, A. M. et al. Expert specification of the ACMG/AMP variant interpretation guidelines for genetic hearing loss. *Hum Mutat*, v. 39, n. 11, p. 1593-1613, 2018. DOI: 10.1002/humu.23630.

PALMERO, E. I. et al. Clinical characterization and risk profile of individuals seeking genetic counseling for hereditary breast cancer in Brazil. *J Genet Couns*, v. 16, n. 3, p. 363-71, 2007. DOI: 10.1007/s10897-006-9073-0.

PARSONS, M. T. et al. Large scale multifactorial likelihood quantitative analysis of BRCA1 and BRCA2 variants: An ENIGMA resource to support clinical variant classification. *Hum Mutat*, v. 40, n. 9, p. 1557-1578, 2019. DOI: 10.1002/humu.23818.

PEJAVER, V. et al. Calibration of computational tools for missense variant pathogenicity classification and ClinGen recommendations for PP3/BP4 criteria. *Am J Hum Genet*, v. 109, n. 12, p. 2163-2177, 2022. DOI: 10.1016/j.ajhg.2022.10.013.

POPEJOY, A. B.; FULLERTON, S. M. Genomics is failing on diversity. *Nature*, v. 538, n. 7624, p. 161-164, 2016. DOI: 10.1038/538161a.

RAMADANE-MORCHADI, L. et al. ACMG/AMP interpretation of BRCA1 missense variants: Structure-informed scores add evidence strength granularity to the PP3/BP4 computational evidence. *Am J Hum Genet*, v. 112, n. 5, p. 993-1002, 2025. DOI: 10.1016/j.ajhg.2024.12.011.

RENTZSCH, P. et al. CADD: predicting the deleteriousness of variants throughout the human genome. *Nucleic Acids Res*, v. 47, n. D1, p. D886-D894, 2019. DOI: 10.1093/nar/gky1016.

RIBEIRO, A. A. F. et al. Molecular characterization of hereditary breast and ovarian cancer patients from a public precision medicine service in the Southeast Brazilian population. *Sci Rep*, v. 15, n. 1, p. 33495, 2025. DOI: 10.1038/s41598-025-16870-0.

RICHARDS, S. et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of Medical Genetics and Genomics and the Association for Molecular Pathology. *Genet Med*, v. 17, n. 5, p. 405-24, 2015. DOI: 10.1038/gim.2015.30.

SHETTY, A. P. et al. A leakage-controlled and SHAP driven machine learning framework for paediatric respiratory disease classification using Indian hospital EHR data. *BMC Med Inform Decis Mak*, v. 26, n. 1, 2026. DOI: 10.1186/s12911-026-03493-2.

SMOL, T. et al. Performance of meta-predictors for the classification of MED13L missense variations, implication of raw parameters. *Eur J Med Genet*, v. 65, n. 1, p. 104398, 2021. DOI: 10.1016/j.ejmg.2021.104398.

SOEWITO, S. et al. Disparities in Cancer Genetic Testing and Variants of Uncertain Significance in the Hispanic Population of South Texas. *JCO Oncol Pract*, v. 18, n. 5, p. e805-e813, 2022. DOI: 10.1200/OP.22.00090.

STARITA, L. M. et al. Massively Parallel Functional Analysis of BRCA1 RING Domain Variants. *Genetics*, v. 200, n. 2, p. 413-422, 2015. DOI: 10.1534/genetics.115.175802.

SUYBENG, V. et al. Comparison of Pathogenicity Prediction Tools on Somatic Variants. *J Mol Diagn*, v. 22, n. 12, p. 1383-1392, 2020. DOI: 10.1016/j.jmoldx.2020.08.007.

TIAN, Y. et al. REVEL and BayesDel outperform other in silico meta-predictors for clinical variant classification. *Sci Rep*, v. 9, n. 1, p. 12752, 2019. DOI: 10.1038/s41598-019-49224-8.

TOLAND, A. E.; ANDREASSEN, P. R. DNA repair-related functional assays for the classification of BRCA1 and BRCA2 variants: a critical review and needs assessment. *J Med Genet*, v. 54, n. 11, p. 721-731, 2017. DOI: 10.1136/jmedgenet-2017-104707.

TORRETTO, G. C. et al. Domain-Specific Computational, Functional and Structural Methods Enable Interpretation of BRCT Variants of Uncertain Significance. *Curr Oncol*, v. 33, n. 6, 2026. DOI: 10.3390/currenco133060354.

UNIPROT CONSORTIUM, THE. UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Res*, v. 51, n. D1, p. D523-D531, 2023.

YANG, H. et al. BRCA2 function in DNA binding and recombination from a BRCA2-DSS1-ssDNA structure. *Science*, v. 297, n. 5588, p. 1837-1848, 2002. DOI: 10.1126/science.297.5588.1837.

ZHANG, X. et al. Genetic constraint at single amino acid resolution in protein domains improves missense variant prioritisation and gene discovery. *Genome Med*, v. 16, n. 1, p. 88, 2024. DOI: 10.1186/s13073-024-01358-9.

ZHANG, Q. et al. Integrating protein language models and automatic biofoundry for enhanced protein evolution. *Nat Commun*, v. 16, n. 1, p. 1553, 2025. DOI: 10.1038/s41467-025-56751-8.