

PrimeVarClass: da hipótese dos números primos a um classificador de variantes BRCA1/BRCA2 consciente de domínio, validado externamente e complementar ao estado da arte

32º Prêmio Jovem Cientista — Categoria Estudante do Ensino Superior

Tema: Inteligência Artificial para o Bem Comum — Subtema: Inteligência Artificial & Saúde (item 1.4.1.b do Edital)

Autor: Wesley Felipe Capucho — graduando em Engenharia Bioquímica

Orientador(a): <a definir>

Instituição de vínculo: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP) — Estrada Municipal do Campinho, s/nº, Ponte Nova, Lorena – SP, CEP 12602-810. E-mail: wesleycapucho@usp.br. Telefone: <a definir>.

Instituição onde a pesquisa foi desenvolvida: Escola de Engenharia de Lorena, Universidade de São Paulo (EEL-USP), Lorena – SP, Brasil.

Palavras-chave: variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

APRESENTAÇÃO

Resumo

Este trabalho partiu de uma hipótese pouco convencional: codificar aminoácidos pela estrutura dos números primos revelaria padrões de patogenicidade em variantes missense? O projeto foi nomeado PrimeVarClass a partir dessa aposta, e a hipótese foi testada com rigor — validação cruzada bloqueada por posição e generalização em coortes externas nunca vistas no treino. A hipótese foi refutada com transparência: a codificação por primos teve desempenho inferior ao de uma identidade trivial de aminoácidos (AUC externa 0,681 vs. 0,718; $p = 0,045$) e piorou um modelo bioquímico ao ser adicionada (0,791 $\rightarrow$ 0,765; $p = 3,8 \times 10^{-8}$). No processo, foi diagnosticada uma armadilha de vazamento posicional que infla benchmarks internos. A partir daí, construiu-se um classificador consciente de domínio funcional (RING/BRCT de BRCA1; domínio de ligação ao DNA de BRCA2), que generalizou para coortes externas com AUC de 0,847 — superando o modelo com posição bruta (0,791; $p = 1,8 \times 10^{-13}$). Combinado a um modelo de linguagem de proteínas (ESM-2), o modelo-carro-chefe atingiu AUC externa de 0,909, estatisticamente equivalente aos melhores preditores publicados — AlphaMissense (0,926; $p = 0,24$), REVEL (0,930; $p = 0,14$) e CADD (0,891; $p = 0,37$) —, ainda que avaliado sob desvantagem: esses preditores carregam circularidade com os próprios rótulos de teste, e o modelo proposto, não. Um meta-classificador integrando todos os sinais atingiu 0,938. Os escores foram calibrados em força de evidência ACMG/AMP e, entre variantes que o AlphaMissense deixa ambíguas (644 no total), foram resolvidos 53,8% dos VUS e 64,6% das conflitantes — evidência de que o método complementa o AlphaMissense, em vez de competir com ele. O mecanismo estrutural foi validado contra dados funcionais reais de reparo por recombinação homóloga (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$); uma lacuna de equidade entre ancestralidades foi quantificada e parcialmente mitigada; e a validação prospectiva por corte temporal foi simulada (AUC de 0,892 em 2016 a 0,932 em 2021). Por fim, foi implementado um mecanismo real e seguro de aprendizado contínuo: o modelo melhora com rótulos confirmados pelo uso (AUC no conjunto travado subindo de 0,895 para 0,922) sob uma trava que rejeita atualizações que piorem o desempenho. O sistema é entregue como plataforma

aberta, auditável e reprodutível. A contribuição central não é um número inflado, mas um método honesto, generalizável e continuamente aprimorável para apoiar a interpretação responsável de variantes genéticas no Brasil.

Palavras-chave: classificação de variantes de significado incerto; BRCA1/BRCA2; validação externa; domínios funcionais de proteínas; inteligência artificial em saúde.

Introdução

O problema clínico e social

Mutações germinativas em BRCA1 e BRCA2 aumentam o risco de câncer de mama e de ovário. Ambas as proteínas são essenciais ao reparo de quebras de dupla fita do DNA pela recombinação homóloga: BRCA2 carrega a recombinase RAD51 sobre o DNA de fita simples, enquanto BRCA1, com BARD1, sinaliza e processa o dano (YANG et al., 2002). Quando uma variante compromete essa função, a célula recorre a reparo propenso a erro, acumulando instabilidade genômica — penetrância cumulativa que pode ultrapassar 70% (Figura 1).




Figura 1. Mecanismo BRCA1/BRCA2 no câncer hereditário de mama e ovário. Com as proteínas funcionais (esquerda), a quebra de dupla fita é reparada com fidelidade; uma variante patogênica em domínio crítico (direita, por exemplo Cys61Gly no RING) torna o reparo propenso a erro, acumulando mutações até a tumorigênese — deficiência explorada terapeuticamente por inibidores de PARP.

Ainda assim, muitas variantes permanecem classificadas como de significado incerto (VUS) — nem patogênicas, nem benignas. No Brasil, isso se agrava por desigualdade de acesso: a expertise de interpretação concentra-se em poucos

centros, e laboratórios públicos frequentemente carecem de ferramentas abertas e auditáveis (ACHATZ et al., 2020; PALMERO et al., 2007; FERNANDES et al., 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO et al., 2025; NORONHA et al., 2026). Foi para atacar esse gargalo que o PrimeVarClass foi desenvolvido.

A lacuna metodológica e o estado da arte

Preditores como REVEL (IOANNIDIS et al., 2016), CADD (RENTZSCH et al., 2019) e AlphaMissense (CHENG et al., 2023) evoluíram para meta-preditores e modelos profundos, com REVEL/BayesDel superando preditores individuais (TIAN et al., 2019). Mas benchmarks nessa área sofrem recorrentemente de vazamento de dados e ausência de validação externa (KERNBACH; STAARTJES, 2022; GANAKAMMAL; ALEXOV, 2019; SUYBENG et al., 2020; SMOL et al., 2021; DONG et al., 2014; LABES et al., 2022), problema que um framework recente propõe mitigar combinando controle de vazamento e SHAP (SHETTY et al., 2026). Especificamente em BRCA1/BRCA2, o BRCA-ML (HART et al., 2020), o RENOVO (FAVALLI et al., 2021), a análise ENIGMA (PARSONS et al., 2019) e ensaios funcionais de saturação genômica (FINDLAY et al., 2014; 2018) reduzem a incerteza, e a calibração ACMG/AMP é recomendação do ClinGen (PEJAVER et al., 2022; RICHARDS et al., 2015; NYKAMP et al., 2017; OZA et al., 2018; MCCORMICK et al., 2020) — inclusive com escores informados por estrutura em BRCA1 (RAMADANE-MORCHADI et al., 2025), o que corrobora a abordagem consciente de domínio aqui desenvolvida. Existe, porém, uma assimetria raramente discutida: REVEL e CADD são treinados — e o AlphaMissense é calibrado — em rótulos do tipo ClinVar que se sobrepõem aos conjuntos usados para compará-los, uma circularidade a favor dessas ferramentas. Essa assimetria é aqui denominada vazamento a favor de terceiros e corrigida explicitamente nos Resultados, somando-se a "coldspots" mal classificados (DINES et al., 2020) e a evidências de que restrição evolutiva por domínio melhora a priorização (ZHANG et al., 2024; CHEN et al., 2023; CHAO et al., 2024; LAKE et al., 2024; TORRETTO et al., 2026).

A jornada científica: por que "Prime"

O nome PrimeVarClass guarda a origem do projeto: uma hipótese arrojada sobre números primos, tratada não como verdade a defender, mas como hipótese a testar sob o protocolo mais rigoroso disponível. O resultado foi negativo, e é relatado

com a mesma transparência dos positivos. Sustenta-se que essa trajetória — hipótese ousada, teste rigoroso, refutação transparente, redirecionamento para o que funciona — é, em si, contribuição científica tão valiosa quanto qualquer resultado positivo isolado, e o antídoto direto contra alegações infladas de inteligência artificial em saúde.

Objetivos

1. Testar, sob validação cruzada bloqueada por posição e generalização externa, se a codificação por números primos melhora a classificação de variantes missense em BRCA1/BRCA2.
2. Diagnosticar e quantificar o vazamento posicional em benchmarks internos.
3. Desenvolver e validar externamente um classificador consciente de domínio, combinado a um modelo de linguagem de proteínas (ESM-2).
4. Comparar esse modelo, de forma honesta, com AlphaMissense/REVEL/CADD, corrigindo a assimetria de circularidade que os favorece.
5. Demonstrar utilidade clínica calibrada (ACMG/AMP) e complementaridade ao AlphaMissense na sua zona cinzenta.
6. Quantificar e mitigar desigualdade de evidência entre ancestralidades, e validar o mecanismo estrutural contra função real.
7. Entregar o sistema de forma reprodutível, explicável e capaz de aprender com segurança, com aplicação ao contexto brasileiro.

DESENVOLVIMENTO

Materiais e Métodos

Fontes de dados

Foram utilizados dados públicos e auditáveis de BRCA1 (UniProt P38398) e BRCA2 (P51587) (UNIPROT CONSORTIUM, 2023): classificações do ClinVar, com subconjunto de alta confiança por painel de especialistas (ENIGMA/ClinGen; PARSONS et al., 2019); frequências alélicas do gnomAD por ancestralidade (KARCZEWSKI et al., 2020); estruturas do PDB e AlphaFold DB; e ensaios funcionais do MaveDB (FINDLAY et al., 2018; STARITA et al., 2015). Os rótulos foram normalizados em patogênico (1) vs. benigno (0); conflitantes ou de baixa confiança foram excluídos. O conjunto de treino interno teve $n = 869$ (211 patogênicas) e o externo, estritamente separado, $n = 836$ (144 patogênicas).

Representação, teste dos primos e domínio funcional

Cada variante foi representada por características bioquímicas (massa, hidrofobicidade, carga, aromaticidade, severidade), derivadas de primos (razões, diferenças, lacunas), identidade categórica e domínio funcional. Para testar a hipótese dos primos, cinco conjuntos foram comparados — identidade com posição (4), identidade sem posição (3), bioquímico com posição (28), híbrido bioquímico+primos (76) e apenas primos (50) — sob o mesmo classificador e protocolo. Foram mapeados domínios funcionais curados do UniProt: RING (1–109) e BRCT (1642–1736, 1756–1855) em BRCA1; domínio de ligação ao DNA (2481–3186) em BRCA2, como regiões críticas, definindo-se `functional_domain` e `in_critical_domain` — características de região, não do índice do resíduo, portanto transferíveis.

Protocolo anti-vazamento e modelo

Foram adotados dois níveis de avaliação, sem exceção: (A) validação cruzada bloqueada por posição (StratifiedGroupKFold, 5 folds, agrupada por gene:posição), impedindo que a mesma posição apareça em treino e teste; e (B) generalização externa nas quatro coortes nunca tocadas. As comparações de AUC usaram o teste pareado de DeLong (DELONG; DELONG; CLARKE-PEARSON,

1988). Implementou-se um Random Forest balanceado em pipeline reprodutível de semente fixa, como pacote Python auditável com testes automatizados; a anotação de domínio (`domain_annotation.py`) e a ingestão de escores profundos (`esm_scores.py`) são módulos independentes, sem dependência de GPU.

Robustez, meta-análise, ESM-2 e SHAP

A robustez foi quantificada por bootstrap ($B = 2000$), teste de permutação ($N = 2000$), validação cruzada bloqueada repetida (12 sementes) e calibração (Brier, confiabilidade). As quatro coortes externas foram agrupadas por efeitos aleatórios (DerSimonian-Laird, escala logit), reportando-se IC95%, Q de Cochran e I^2 . Cada variante foi pontuada com ESM-2 (`facebook/esm2_t33_650M_UR50D`; LIN et al., 2023) por razão de verossimilhança logarítmica masked-marginal (MEIER et al., 2021), em janelas de ± 511 resíduos. Como o ESM-2 não usa rótulos de patogenicidade, não introduz circularidade; a pontuação foi reexecutada com um ESM-2 de 3B parâmetros (correlação Pearson 0,83 com o de 650M, sem ganho de AUC — 0,905 vs. 0,909 —, resultado honesto de saturação que levou a manter o 650M como principal). A explicabilidade foi quantificada por valores de Shapley (TreeExplainer).

Comparação honesta, meta-classificador e calibração ACMG/AMP

O modelo-carro-chefe foi comparado com AlphaMissense, REVEL, CADD, PolyPhen-2 e SIFT nas mesmas 836 variantes externas (escores via API REST do Ensembl VEP, transcrito MANE Select). A assimetria de circularidade (Seção 1.3) foi tornada explícita, e tentou-se isolá-la recortando variantes recentes ($\text{ClinVar} \geq 2024$); constatou-se que o recorte não separa o vazamento de forma limpa, pois `last_evaluated` reflete reavaliação, não submissão original. Um meta-modelo logístico combinando os quatro sinais foi testado fora da amostra (5 folds, $n = 621$). O escore foi calibrado aos limiares de razão de verossimilhança de Tavgigian/Pejaver (PEJAVER et al., 2022; RICHARDS et al., 2015): $LR \geq 18,7/4,33/2,08$ para PP3 forte/moderado/leve; $LR \leq 0,05/0,23/0,48$ para BP4, prevalência prévia de 10%.

Zona cinzenta, equidade, mecanismo e aprendizado contínuo

Entre variantes reais do ClinVar, foram identificadas as que o AlphaMissense classifica como ambíguas (644) e verificou-se quantas recebem do modelo uma

chamada PP3/BP4 informativa. Foram usadas frequências do gnomAD (europeias vs. não europeias) para medir equidade de resolução em variantes com $AF > 10^{-4}$ (POPEJOY; FULLERTON, 2016; MANRAI et al., 2016; SOEWITO et al., 2022). Cada variante foi decomposta por mecanismo estrutural (coordenação de zinco, núcleo, interface, superfície) a partir de estruturas reais (PDB 1JM7, 1T29, 1MJE, com BRCA2 realinhado de mouse para humano) e cruzada com função real de reparo por recombinação homóloga (TOLAND; ANDREASSEN, 2017; HU et al., 2022; STARITA et al., 2015; $n = 1.262$) por Kruskal-Wallis. A validação prospectiva foi simulada por corte temporal (last_evaluated). Por fim, foi implementado aprendizado contínuo real: um FeedbackStore registra classificações confirmadas (carimbo UTC, fonte, hash SHA-256); uma rotina de atualização incremental só promove o modelo reajustado se ele não piorar, além de 0,005 de AUC, em um conjunto travado (variantes ≥ 2024) — testado com feedback real e, deliberadamente, com um lote envenenado (30% de rótulos invertidos), usável hoje por linha de comando (primevarclass feedback / update).

Resultados e Discussão

A hipótese dos números primos foi refutada

A hipótese foi testada sob o protocolo anti-vazamento (Tabela 1). Os primos tiveram desempenho inferior à identidade trivial e pioraram um modelo bioquímico ao serem adicionados (Tabela 2).

Tabela 1. Refutação da hipótese dos primos (n = 869 treino / n = 836 externo).

Conjunto de características	nº feat.	CV bloqueada	Externa
Identidade (com posição) ^a	4	0,871	0,882
Bioquímico (com posição) ^a	28	0,802	0,791
Híbrido (bioquímico + primos) ^a	76	0,783	0,765
Identidade (sem posição)	3	0,745	0,718
Apenas primos	50	0,717	0,681

^a Incluem gene e posição bruta — risco de memorização diagnosticado a seguir.

Tabela 2. Comparações pareadas por DeLong.

Comparação	Protocolo	AUC A	AUC B	Δ	p
Primos vs. identidade	Bloqueada	0,717	0,745	-0,028	0,081
Primos vs. identidade	Externa	0,681	0,718	-0,038	0,045
Híbrido vs. bioquímico	Bloqueada	0,783	0,802	-0,019	<0,0001
Híbrido vs. bioquímico	Externa	0,765	0,791	-0,027	<0,0001

A diferença é uma tendência não significativa na CV interna ($p = 0,081$), mas significativa na generalização externa ($p = 0,045$) — e adicionar primos a um modelo bioquímico piora o desempenho externo ($p < 0,0001$). A conclusão é honesta: os primos não agregam sinal útil.

Diagnóstico: a armadilha do vazamento posicional

Sob validação ingênua (sem bloqueio por grupo), a identidade combinada à posição bruta chega a AUC próxima de 0,90 — valor inflado, pois variantes da mesma posição compartilham rótulo e aparecem em treino e teste simultaneamente. Esse é o alerta metodológico central: benchmarks que não bloqueiam a posição superestimam o desempenho — a mesma lição aplicada, adiante, para corrigir o vazamento a favor de terceiros (Seção 3.7).

A solução: modelo consciente de domínio

Com a substituição da posição bruta por região funcional, obteve-se um modelo que generaliza melhor externamente (Tabela 3; Figura 2).

Tabela 3. Consciência de domínio: validação bloqueada e externa (AUC-ROC).

Modelo	CV bloqueada	Externa
Bioquímico (sem posição)	0,743	0,717
Bioquímico + domínio (proposto)	0,818	0,847
Bioquímico + posição bruta (vazamento)	0,802	0,791

DeLong domínio vs. bioquímico: $p = 3,2 \times 10^{-9}$ (interno), $p = 1,8 \times 10^{-13}$ (externo). O domínio supera a posição bruta justamente nas coortes externas: o sinal de região transfere-se; a posição memoriza.




Figura 2. Domínios funcionais de BRCA1/BRCA2 com variantes reais sobrepostas. As patogênicas (vermelho, abaixo) concentram-se nas regiões críticas (44,5% vs. 6,8–10,0% fora delas) — base biológica do sinal de domínio.

Prova visual: mutações patogênicas reais capturadas

Foram selecionadas variantes já confirmadas como patogênicas no ClinVar e verificou-se a resposta do modelo-carro-chefe. A Figura 3 mostra o RING de BRCA1 (PDB 1JM7) colorido por intensidade de detecção: as zonas mais sensíveis coincidem exatamente com as cisteínas que coordenam os dois íons de zinco estruturais, sem que essa coordenação tivesse sido informada ao modelo. A Figura 4 detalha seis variantes confirmadas — três no sítio de zinco (Cys39Gly, Cys64Gly, Cys61Tyr) e três no núcleo do BRCT (Met1689Arg, Leu1705Pro, Trp1837Cys) —, todas detectadas com 96,3% a 99,7% de confiança.



Figura 3. RING de BRCA1 (PDB 1JM7), colorido por intensidade de detecção (azul = tolerante; dourado = detectada). Os dois íons de zinco (esferas) são coordenados por cisteínas identificadas, de forma independente, como a região mais sensível — coerente com décadas de literatura sobre o domínio.



Figura 4. Seis variantes de BRCA1 confirmadas patogênicas no ClinVar, cada uma sobre sua estrutura real, com o veredito do ClinVar (selo verde) e a chamada do modelo (selo dourado) — todas detectadas com alta confiança.

O mesmo exercício, repetido em BRCA2 (variantes clássicas do domínio de ligação ao DNA como Gly2748Asp, Arg3052Trp e Trp2626Cys, detectadas com 75,3% a 96,7%; painel individual no Material Suplementar), confirmou que a abordagem generaliza entre genes. A superfície molecular completa dos dois domínios, colorida por intensidade de detecção (Figura 5), torna essa generalização visível: as mesmas zonas de risco — o núcleo funcional de cada domínio — emergem, de forma independente, em BRCA1 (BRCT) e BRCA2 (DBD). Não se trata de um sinal ajustado a um único gene, mas de uma assinatura estrutural comum ao papel dessas proteínas no reparo do DNA.




Figura 5. Paisagem de detecção na superfície molecular completa do domínio BRCT de BRCA1 e do domínio de ligação ao DNA (DBD) de BRCA2. As zonas douradas — o núcleo funcional de cada domínio — concentram as detecções de patogenicidade; a mesma assinatura estrutural emerge nos dois genes de forma independente, evidência visual de que o modelo capturou mecanismo transferível, e não um artefato específico de BRCA1.

Robustez, meta-análise e o modelo-carro-chefe

Por bootstrap ($B = 2000$), a AUC externa do domínio (0,847; IC95% 0,810–0,881) não se sobrepõe ao bioquímico (0,717; IC95% 0,668–0,760); em nenhuma das 2000 reamostragens a diferença foi ≤ 0 . O teste de permutação ($N = 2000$) situa a AUC observada muito além da nula (0,501; $p = 5 \times 10^{-4}$). Em 12 sementes de CV bloqueada, a AUC média foi $0,828 \pm 0,005$ (domínio), $0,818 \pm 0,006$ (posição) e $0,763 \pm 0,005$ (bioquímico); o escore de Brier externo é 0,108, com boa calibração. Combinando domínio e ESM-2, o modelo-carro-chefe atinge AUC externa de 0,909 (Tabela 4; DeLong $p = 1,5 \times 10^{-10}$ vs. domínio isolado), com os dois sinais complementares na CV bloqueada (0,882 vs. 0,818 e 0,867 isolados). Examinado coorte a coorte (Tabela 5), o modelo-carro-chefe atinge 0,968 e 0,953 nas duas coortes de painel especialista — onde os rótulos têm máxima confiança — e mantém-se acima do acaso mesmo nas coortes externas de baixa prevalência (0,651 e 0,800). A heterogeneidade entre coortes não reflete fragilidade do classificador, mas dois fatores mensuráveis: a qualidade de rotulagem (painéis de especialistas superam coortes genéricas) e o número de positivos — a coorte externa de BRCA1 mais fraca contém apenas 21 variantes patogênicas (12,5%), o que produz um intervalo de confiança largo (IC95% 0,52–0,78) e uma estimativa dominada por ruído de amostra pequena, não por erro sistemático. A explicabilidade por SHAP (Figura 6) confirma o escore ESM-2 e a pertinência a domínio crítico como preditores dominantes, com direção de efeito biologicamente correta.

Tabela 4. Modelo-carro-chefe sob o protocolo anti-vazamento (AUC-ROC).

Modelo	CV bloqueada	Externa
Consciente de domínio	0,818	0,847
ESM-2 (650M) sozinho	0,867	0,907
Domínio + ESM-2 (carro-chefe)	0,882	0,909

Tabela 5. Desempenho do modelo-carro-chefe por coorte externa. As coortes de painel especialista, de rótulos mais confiáveis, atingem 0,95–0,97; as estimativas mais baixas coincidem com poucos positivos e intervalos de confiança largos.

Coorte externa	n	patog.	AUC (modelo)	IC95%
BRCA1 — painel especialista	204	69	0,968	0,939–0,989
BRCA2 — painel especialista	175	39	0,953	0,894–0,992
BRCA2 — coorte externa	289	15	0,800	0,649–0,936




Figura 6. Explicabilidade por valores de Shapley do modelo domínio + ESM-2 — o escore ESM-2 e o domínio crítico são os preditores dominantes.

Vazamento a favor de terceiros: a comparação honesta

No mesmo conjunto externo ($n = 836$), o modelo-carro-chefe foi medido contra preditores publicados (Figura 7; Tabela 6). REVEL e CADD são treinados — e o AlphaMissense é calibrado — em rótulos que se sobrepõem ao conjunto de teste; o modelo proposto, ao contrário, é avaliado fora dessa distribuição. Mesmo em desvantagem, a diferença para os três líderes não é significativa ($p = 0,14$ a $0,37$), e a superioridade sobre SIFT e PolyPhen-2 é clara. Tentou-se isolar o vazamento por corte temporal (≥ 2024); o recorte não separa o efeito de forma limpa — todas as ferramentas melhoram nas variantes recentes (o modelo proposto sobe a $0,932$, ainda equivalente aos líderes, $p = 0,12$ – $0,61$). Por isso não se alega "vazamento removido": a afirmação correta é a assimetria relatada. Empatar sob avaliação mais rigorosa é um resultado mais forte do que o número cru sugere — e é por isso que o diferencial real não está em vencer no AUC bruto, mas em complementar essas ferramentas onde elas se absterem.




Figura 7. Comparação honesta com o estado da arte: preditores supervisionados/calibrados em ClinVar (azul) têm circularidade a favor; o modelo-carro-chefe (vermelho) é avaliado fora da distribuição.

Tabela 6. Comparação honesta com o estado da arte (n = 836).

Ferramenta	AUC	Regime	DeLong vs. modelo
REVEL	0,930	supervisionado em ClinVar	p=0,14 (n.s.)
AlphaMissense	0,926	calibrado em ClinVar	p=0,24 (n.s.)
PrimeVarClass	0,909	cego ao externo	—
CADD	0,891	supervisionado em ClinVar	p=0,37 (n.s.)
SIFT	0,845	não supervisionado	p=0,001
PolyPhen-2	0,773	não supervisionado	p<0,0001

Integrando de forma calibrada os quatro sinais, o meta-classificador atingiu AUC de 0,938 (IC95% 0,901–0,969; n = 621) — a melhor marca do estudo, superando mesmo o REVEL isolado (DeLong p = 0,43). A mensagem é clara: não competir, mas somar.

Calibração ACMG/AMP e o complemento na zona cinzenta

Os escores foram calibrados aos limiares de Tavgitjan/Pejaver: nas coortes externas, PP3 forte corresponde a 94% de patogênicos reais (LR $\approx$ 76; n = 84), e BP4 moderado a apenas 3,2% (LR $\approx$ 0,16; n = 444) — evidência confiável nas duas direções. O maior diferencial deste trabalho, porém, está na zona cinzenta do AlphaMissense (Figura 8; Tabela 7): entre 644 variantes reais que ele deixa ambíguas, foram resolvidos 53,8% dos VUS e 64,6% das conflitantes; nas 17 que já

tinham diagnóstico definitivo, a concordância foi de 100%. Fornece-se informação exatamente onde a melhor ferramenta atual se cala.




Figura 8. Complemento ao AlphaMissense — evidência calibrada onde ele se abstém, em BRCA1 e BRCA2, com dados reais do ClinVar.

Tabela 7. Resolução de variantes na zona cinzenta do AlphaMissense.

Categoria	BRCA1	BRCA2	Combinado
VUS na zona cinzenta (n)	98	166	264
VUS resolvidas	56,1%	52,4%	53,8%
Conflitantes na zona cinzenta (n)	64	128	192
Conflitantes resolvidas	76,6%	58,6%	64,6%

Mecanismo, equidade e validação temporal

Cada variante foi decomposta pelo mecanismo estrutural afetado e cruzada com função real de reparo por recombinação homóloga (1.262 variantes; STARITA et al., 2015): as categorias diferem de forma altamente significativa (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$; Figura 9), com coordenação de zinco a mais deletéria (mediana $-0,844$) e superfície a mais tolerada ($-0,011$). Mais do que isso, a própria probabilidade do modelo — treinada apenas em rótulos clínicos — prevê a perda de função medida experimentalmente por deep mutational scanning, independente do ClinVar: no mesmo ensaio de recombinação homóloga, a probabilidade separa variantes com e sem perda de função com AUC de 0,712 em 2.749 variantes. Trata-se de uma validação ortogonal contra fenótipo molecular medido em bancada, e não contra outro rótulo in silico. Entre variantes com frequência apreciável ($AF > 10^{-4}$), apenas 26,2% têm classificação definitiva em ancestralidades não europeias, contra 55,7% em europeias (Figura 10); o modelo fornece evidência calibrada para 78%

das não europeias ainda não resolvidas, e 84% das europeias — de forma equitativa. Simulando implantação prospectiva por corte temporal, a AUC futura cresceu de 0,892 (corte 2016) a 0,932 (corte 2021; Tabela 8).




Figura 9. Mecanismo estrutural previsto versus função medida em laboratório (ensaio de reparo por recombinação homóloga; STARITA et al., 2015). As categorias de mecanismo — da coordenação de zinco à superfície — separam de forma altamente significativa os escores funcionais reais (Kruskal-Wallis $p \approx 3,5 \times 10^{-33}$), confirmando que o modelo raciocina sobre biologia real, e não sobre um proxy estatístico.




Figura 10. Lacuna de resolução clínica entre ancestralidades (gnomAD) e a contribuição do modelo para reduzi-la equitativamente.

Tabela 8. Validação temporal (quasi-prospectiva) por ano de corte.

Corte	Treino (n)	Teste futuro (n)	AUC futura
2016	176	323	0,892
2019	279	220	0,926

Aprendizado contínuo e seguro

Com um conjunto de variantes recentes mantido travado (≥ 2024 , nunca vistas no treino), rótulos confirmados foram revelados de forma acumulada ao longo do tempo: a AUC no conjunto travado sobe de 0,895 para 0,922 — ganho puro por mais dados reais (Figura 11). A trava de segurança foi testada deliberadamente com um lote de feedback envenenado (30% de rótulos invertidos): o candidato resultante (AUC 0,727) foi corretamente rejeitado pela regra de promoção. Não é promessa: é o mesmo efeito medido na validação temporal, operacionalizado como recurso usável hoje.




Figura 11. Aprendizado contínuo e seguro. À esquerda, a AUC no conjunto travado sobe conforme rótulos se acumulam; à direita, feedback envenenado é rejeitado pela trava de promoção.

Discussão: honestidade metodológica como contribuição, e complemento em vez de concorrência

O achado central é que domínio funcional generaliza, enquanto posição bruta memoriza — inversão diagnóstica confirmada em três momentos distintos: a refutação dos primos, o diagnóstico do vazamento posicional, e a exposição da assimetria de circularidade que desfavorece o modelo proposto na comparação com o estado da arte. Relatar essas três desvantagens, em vez de escondê-las, é reproduzível e auditável, e cada uma é um alerta metodológico útil para a área. Por isso optou-se por não competir com o AlphaMissense no AUC bruto — comparação estruturalmente injusta contra o modelo proposto —, e sim por demonstrar o que

realmente importa: evidência calibrada exatamente onde ele se abstém. Um laboratório clínico não precisa escolher entre as duas ferramentas; precisa das duas.

Limitações e trabalhos futuros

A validação concentrou-se em BRCA1/BRCA2; as fronteiras de domínio são aproximações da literatura; a generalização, embora atinja 0,95–0,97 nas coortes de painel especialista, é heterogênea entre coortes, em parte por diferenças de qualidade de rotulagem e por baixos números de positivos nas coortes externas de baixa prevalência; o recorte temporal não isola o vazamento de forma limpa; e a validação funcional apoiou-se na convergência retrospectiva com ensaios de deep mutational scanning publicados — validação ortogonal contra função medida (Starita HDR, AUC 0,712), não em novo experimento de bancada conduzido no âmbito deste trabalho. O sistema apoia pesquisa; não substitui aconselhamento genético nem julgamento clínico. Como trabalhos futuros, pretende-se estender a anotação de domínio e o ESM-2 a outros genes (TP53, PALB2, CHEK2), ampliar as coortes externas para caracterizar os limites de aplicabilidade, acompanhar em produção o módulo de aprendizado contínuo com laboratórios parceiros, e explorar modelos de linguagem de proteínas com plataformas automatizadas de evolução dirigida (ZHANG et al., 2025) como fonte futura de rótulos funcionais.

Impacto social, aplicação prática e ética no uso de IA

O acesso à interpretação genética é desigual no Brasil (ACHATZ et al., 2020; PALMERO et al., 2007; FERNANDES et al., 2019; LASTA; GROTO; BRANDALIZE, 2023; RIBEIRO et al., 2025; NORONHA et al., 2026). O PrimeVarClass é posicionado não como diagnóstico automático, mas como ferramenta de pesquisa responsável: apoio a laboratórios públicos, formação de pesquisadores em boas práticas de validação, suporte translacional e equidade por ser software aberto e de baixo custo computacional, sem exigir GPU. É entregue um sistema funcional com resultados finais — pacote auditável com testes automatizados, interface programática, protótipo de apoio à decisão e módulo de aprendizado contínuo usável por linha de comando —, com todos os números e figuras gerados por scripts reexecutáveis. Em conformidade com o item 2.2.2 (Nota 4) do Edital, declara-se o uso de um assistente de programação e redação baseado em modelo de linguagem de grande porte (Claude, da Anthropic) para apoio à escrita e depuração de código,

execução de análises estatísticas sobre dados reais, revisão de literatura e redação assistida em português; a concepção científica, a verificação dos resultados e a responsabilidade final são do autor. Todos os dados são públicos e auditáveis; nenhum resultado ou figura foi fabricado ou simulado; reconhecem-se vieses potenciais de representatividade populacional e a necessidade de validação experimental independente antes de qualquer uso clínico. Nenhuma prática de uso antiético de IA foi empregada.

CONCLUSÃO

Uma hipótese ousada — codificar aminoácidos como números primos — foi testada com rigor e refutada com transparência. Esse resultado negativo conduziu ao diagnóstico da armadilha de vazamento posicional e à construção de um classificador consciente de domínio que generaliza para coortes externas (AUC 0,847; $p = 1,8 \times 10^{-13}$), superando modelos que memorizam. Combinado a um modelo de linguagem de proteínas autêntico, o modelo-carro-chefe alcançou AUC externa de 0,909 — estatisticamente equivalente aos melhores preditores publicados, mesmo avaliado sob a desvantagem que foi tornada explícita. Um meta-classificador atingiu 0,938; a evidência foi calibrada em critérios ACMG/AMP; e demonstrou-se, com dados reais, que o método complementa o AlphaMissense onde ele se abstém, resolvendo mais da metade dos VUS e quase dois terços das variantes conflitantes na sua zona cinzenta. O mecanismo do modelo foi validado contra função medida em laboratório, uma lacuna de equidade entre ancestralidades foi mitigada, a validação prospectiva foi simulada com resultados crescentes, e um mecanismo real e seguro de aprendizado contínuo foi entregue. Esse método é entregue de forma aberta, explicável, auditável e eticamente contida, com aplicação direta ao contexto brasileiro de saúde de precisão. A maior força do PrimeVarClass não é um número, mas um compromisso demonstrado com a ciência honesta — do teste de uma hipótese própria até a correção de uma assimetria que o desfavorecia.

REFERÊNCIAS

- ACHATZ, M. I. et al. Recommendations for Advancing the Diagnosis and Management of Hereditary Breast and Ovarian Cancer in Brazil. *JCO Glob Oncol*, v. 6, p. 439-452, 2020. DOI: 10.1200/JGO.19.00170.
- CHAO, K. R. et al. The landscape of regional missense mutational intolerance quantified from 125,748 exomes. *bioRxiv*, 2024. DOI: 10.1101/2024.04.11.588920.
- CHEN, S. et al. A genomic mutational constraint map using variation in 76,156 human genomes. *Nature*, v. 625, n. 7993, p. 92-100, 2023. DOI: 10.1038/s41586-023-06045-0.
- CHENG, J. et al. Accurate proteome-wide missense variant effect prediction with AlphaMissense. *Science*, v. 381, n. 6664, p. eadg7492, 2023. DOI: 10.1126/science.adg7492.
- DELONG, E. R.; DELONG, D. M.; CLARKE-PEARSON, D. L. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, v. 44, n. 3, p. 837-845, 1988.
- DINES, J. N. et al. Systematic misclassification of missense variants in BRCA1 and BRCA2 "coldspots". *Genet Med*, v. 22, n. 5, p. 825-830, 2020. DOI: 10.1038/s41436-019-0740-6.
- DONG, C. et al. Comparison and integration of deleteriousness prediction methods for nonsynonymous SNVs in whole exome sequencing studies. *Hum Mol Genet*, v. 24, n. 8, p. 2125-37, 2014. DOI: 10.1093/hmg/ddu733.
- FAVALLI, V. et al. Machine learning-based reclassification of germline variants of unknown significance: The RENOV algorithm. *Am J Hum Genet*, v. 108, n. 4, p. 682-695, 2021. DOI: 10.1016/j.ajhg.2021.03.010.
- FERNANDES, G. C. et al. Differential Profile of BRCA1 vs. BRCA2 Mutated Families: A Characterization of the Main Differences and Similarities in Patients. *Asian Pac J Cancer Prev*, v. 20, n. 6, p. 1655-1660, 2019. DOI: 10.31557/APJCP.2019.20.6.1655.
- FINDLAY, G. M. et al. Saturation editing of genomic regions by multiplex homology-directed repair. *Nature*, v. 513, n. 7516, p. 120-3, 2014. DOI: 10.1038/nature13695.
- FINDLAY, G. M. et al. Accurate classification of BRCA1 variants with saturation genome editing. *Nature*, v. 562, n. 7726, p. 217-222, 2018. DOI: 10.1038/s41586-018-0461-z.
- GANAKAMMAL, S. R.; ALEXOV, E. Evaluation of performance of leading algorithms for variant pathogenicity predictions and designing a combinatory predictor method: application to Rett syndrome variants. *PeerJ*, v. 7, p. e8106, 2019. DOI: 10.7717/peerj.8106.
- HART, S. N. et al. Prediction of the functional impact of missense variants in BRCA1 and BRCA2 with BRCA-ML. *NPJ Breast Cancer*, v. 6, p. 13, 2020. DOI: 10.1038/s41523-020-0159-x.
- HU, C. et al. Classification of BRCA2 Variants of Uncertain Significance (VUS) Using an ACMG/AMP Model Incorporating a Homology-Directed Repair (HDR) Functional Assay. *Clin Cancer Res*, v. 28, n. 17, p. 3742-3751, 2022. DOI: 10.1158/1078-0432.CCR-22-0203.
- IOANNIDIS, N. M. et al. REVEL: An Ensemble Method for Predicting the Pathogenicity of Rare Missense Variants. *Am J Hum Genet*, v. 99, n. 4, p. 877-885, 2016. DOI: 10.1016/j.ajhg.2016.08.016.
- KARCZEWSKI, K. J. et al. The mutational constraint spectrum quantified from variation in 141,456 humans. *Nature*, v. 581, n. 7809, p. 434-443, 2020. DOI: 10.1038/s41586-020-2308-7.
- KERNBACH, J. M.; STAARTJES, V. E. Foundations of Machine Learning-Based Clinical Prediction Modeling: Part II-Generalization and Overfitting. *Acta Neurochir Suppl*, v. 134, p. 15-21, 2022. DOI: 10.1007/978-3-030-85292-4_3.
- LABES, S. et al. Machine-learning of complex evolutionary signals improves classification of SNVs. *NAR Genom Bioinform*, v. 4, n. 2, p. lqac025, 2022. DOI: 10.1093/nargab/lqac025.
- LAKE, N. J. et al. Quantifying constraint in the human mitochondrial genome. *Nature*, v. 635, n. 8038, p. 390-397, 2024. DOI: 10.1038/s41586-024-08048-x.

LASTA, J. L.; GROTO, A. D.; BRANDALIZE, A. P. C. Assessment of medical knowledge toward genetic testing for individuals with hereditary breast and ovarian cancer syndrome in Brazil. *Prev Med Rep*, v. 35, p. 102356, 2023. DOI: 10.1016/j.pmedr.2023.102356.

LIN, Z. et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, v. 379, n. 6637, p. 1123-1130, 2023. DOI: 10.1126/science.ade2574.

MANRAI, A. K. et al. Genetic Misdiagnoses and the Potential for Health Disparities. *N Engl J Med*, v. 375, n. 7, p. 655-665, 2016. DOI: 10.1056/NEJMs1507092.

MCCORMICK, E. M. et al. Specifications of the ACMG/AMP standards and guidelines for mitochondrial DNA variant interpretation. *Hum Mutat*, v. 41, n. 12, p. 2028-2057, 2020. DOI: 10.1002/humu.24107.

MEIER, J. et al. Language models enable zero-shot prediction of the effects of mutations on protein function. *NeurIPS*, 2021.

NORONHA, M. M. et al. Beyond 1100delC: distinct CHEK2 variants and unique cancer phenotypes in Northeast Brazil. *Fam Cancer*, v. 25, n. 1, p. 8, 2026. DOI: 10.1007/s10689-025-00526-z.

NYKAMP, K. et al. Sherloc: a comprehensive refinement of the ACMG-AMP variant classification criteria. *Genet Med*, v. 19, n. 10, p. 1105-1117, 2017. DOI: 10.1038/gim.2017.37.

OZA, A. M. et al. Expert specification of the ACMG/AMP variant interpretation guidelines for genetic hearing loss. *Hum Mutat*, v. 39, n. 11, p. 1593-1613, 2018. DOI: 10.1002/humu.23630.

PALMERO, E. I. et al. Clinical characterization and risk profile of individuals seeking genetic counseling for hereditary breast cancer in Brazil. *J Genet Couns*, v. 16, n. 3, p. 363-71, 2007. DOI: 10.1007/s10897-006-9073-0.

PARSONS, M. T. et al. Large scale multifactorial likelihood quantitative analysis of BRCA1 and BRCA2 variants: An ENIGMA resource to support clinical variant classification. *Hum Mutat*, v. 40, n. 9, p. 1557-1578, 2019. DOI: 10.1002/humu.23818.

PEJAVER, V. et al. Calibration of computational tools for missense variant pathogenicity classification and ClinGen recommendations for PP3/BP4 criteria. *Am J Hum Genet*, v. 109, n. 12, p. 2163-2177, 2022. DOI: 10.1016/j.ajhg.2022.10.013.

POPEJOY, A. B.; FULLERTON, S. M. Genomics is failing on diversity. *Nature*, v. 538, n. 7624, p. 161-164, 2016. DOI: 10.1038/538161a.

RAMADANE-MORCHADI, L. et al. ACMG/AMP interpretation of BRCA1 missense variants: Structure-informed scores add evidence strength granularity to the PP3/BP4 computational evidence. *Am J Hum Genet*, v. 112, n. 5, p. 993-1002, 2025. DOI: 10.1016/j.ajhg.2024.12.011.

RENTZSCH, P. et al. CADD: predicting the deleteriousness of variants throughout the human genome. *Nucleic Acids Res*, v. 47, n. D1, p. D886-D894, 2019. DOI: 10.1093/nar/gky1016.

RIBEIRO, A. A. F. et al. Molecular characterization of hereditary breast and ovarian cancer patients from a public precision medicine service in the Southeast Brazilian population. *Sci Rep*, v. 15, n. 1, p. 33495, 2025. DOI: 10.1038/s41598-025-16870-0.

RICHARDS, S. et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of Medical Genetics and Genomics and the Association for Molecular Pathology. *Genet Med*, v. 17, n. 5, p. 405-24, 2015. DOI: 10.1038/gim.2015.30.

SHETTY, A. P. et al. A leakage-controlled and SHAP driven machine learning framework for paediatric respiratory disease classification using Indian hospital EHR data. *BMC Med Inform Decis Mak*, v. 26, n. 1, 2026. DOI: 10.1186/s12911-026-03493-2.

SMOL, T. et al. Performance of meta-predictors for the classification of MED13L missense variations, implication of raw parameters. *Eur J Med Genet*, v. 65, n. 1, p. 104398, 2021. DOI: 10.1016/j.ejmg.2021.104398.

SOEWITO, S. et al. Disparities in Cancer Genetic Testing and Variants of Uncertain Significance in the Hispanic Population of South Texas. *JCO Oncol Pract*, v. 18, n. 5, p. e805-e813, 2022. DOI: 10.1200/OP.22.00090.

STARITA, L. M. et al. Massively Parallel Functional Analysis of BRCA1 RING Domain Variants. *Genetics*, v. 200, n. 2, p. 413-422, 2015. DOI: 10.1534/genetics.115.175802.

SUYBENG, V. et al. Comparison of Pathogenicity Prediction Tools on Somatic Variants. *J Mol Diagn*, v. 22, n. 12, p. 1383-1392, 2020. DOI: 10.1016/j.jmoldx.2020.08.007.

TIAN, Y. et al. REVEL and BayesDel outperform other in silico meta-predictors for clinical variant classification. *Sci Rep*, v. 9, n. 1, p. 12752, 2019. DOI: 10.1038/s41598-019-49224-8.

TOLAND, A. E.; ANDREASSEN, P. R. DNA repair-related functional assays for the classification of BRCA1 and BRCA2 variants: a critical review and needs assessment. *J Med Genet*, v. 54, n. 11, p. 721-731, 2017. DOI: 10.1136/jmedgenet-2017-104707.

TORRETTO, G. C. et al. Domain-Specific Computational, Functional and Structural Methods Enable Interpretation of BRCT Variants of Uncertain Significance. *Curr Oncol*, v. 33, n. 6, 2026. DOI: 10.3390/curroncol33060354.

UNIPROT CONSORTIUM, THE. UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Res*, v. 51, n. D1, p. D523-D531, 2023.

YANG, H. et al. BRCA2 function in DNA binding and recombination from a BRCA2-DSS1-ssDNA structure. *Science*, v. 297, n. 5588, p. 1837-1848, 2002. DOI: 10.1126/science.297.5588.1837.

ZHANG, X. et al. Genetic constraint at single amino acid resolution in protein domains improves missense variant prioritisation and gene discovery. *Genome Med*, v. 16, n. 1, p. 88, 2024. DOI: 10.1186/s13073-024-01358-9.

ZHANG, Q. et al. Integrating protein language models and automatic biofoundry for enhanced protein evolution. *Nat Commun*, v. 16, n. 1, p. 1553, 2025. DOI: 10.1038/s41467-025-56751-8.